Online estimation of Q-value:

$M = (\mu, S, A, \mathbb{P}, r, \gamma) \to$ SMDP, $\gamma \in (0,1]$

для удобства $r_t \in [0,1]$

$s_0 \sim \mu$

$$s_0 \xrightarrow{a_0} s_1 \xrightarrow{a_1} s_2 \to \dots \xrightarrow{a_{n-1}} s_n$$

$s_{t+1} \sim \mathbb{P}(\cdot \mid s_t, a_t)$

$\tau_n = (\underbrace{s_0, a_0, r_0, s_1}_{\text{задают переход}}, a_1, r_1, \dots, s_{n-1}, a_{n-1}, r_{n-1}, s_n)$

$r_t := r(s_t, a_t, s_{t+1})$

или $r_t := r(s_t, a_t)$

по ним можно построить эмпирический MDP и его ядро: $\hat{\mathbb{P}}(s_{t+1} = s' \mid s_t = s, a_t = a) = \dfrac{\#(s,a,s')}{\#(s,a)}$

(s_t, a_t, r_t, s_{t+1})

$$\begin{cases} \#(s,a,s') = \sum_{t=0}^{n-1} \mathbb{1}\{s_t = s, a_t = a, s_{t+1} = s'\} \\ \#(s,a) = \sum_{t=0}^{n-1} \mathbb{1}\{s_t = s, a_t = a\} \end{cases}$$

$$r_t \approx \hat{r}(s_t = s, a_t = a, s_{t+1} = s') = \frac{\sum_{t=0}^{n-1} r_t \cdot \mathbb{1}\{s_t = s, a_t = a, s_{t+1} = s'\}}{\sum_{t=0}^{n-1} \mathbb{1}\{s_t = s, a_t = a, s_{t+1} = s'\}}$$

Model Based оценивание $\mathbb{P}$, r.

SARSA (model free)

$s_t, \quad a_t, \quad s_{t+1}, \quad r_t, \quad a_{t+1}$

$$Q^{\pi_k}(s_t, a_t) = \mathbb{E}_{\mathbb{P}} \mathbb{E}_{\pi}\left[r(s_t, a_t, s_{t+1}) + \gamma \cdot Q^{\pi_k}(s_{t+1}, a_{t+1}) \right]$$

s_{t+1}, a_{t+1}

$a_{t+1} \sim \pi(\cdot \mid s_{t+1})$

$s_{t+1} \sim \mathbb{P}(\cdot \mid s_t, a_t)$

$$Q^{\pi_{k+\frac{1}{2}}}(s_t, a_t) := (1 - \alpha_k) \cdot Q^{\pi_k}(s_t, a_t) + \alpha_k \cdot \underbrace{\left[r(s_t, a_t, s_{t+1}) + \gamma \cdot Q^{\pi_k}(s_{t+1}, a_{t+1}) \right]}_{\text{оценка правой части уравнения Беллмана}} =$$

Expected SARSA

$$= Q^{\pi_k}(s_t, a_t) + \alpha_k \cdot \underbrace{\left[r_t + \gamma \cdot \mathbb{E}_{a_{t+1}} Q^{\pi_k}(s_{t+1}, a_{t+1}) - Q^{\pi_k}(s_t, a_t) \right]}_{\text{Temporal Difference (TD)}}$$

Стохастическая невязка на уравнение Беллмана

для обучения стратегии: $\pi_{k+1}(s, a) := \operatorname{argmax}_{a \in A} \{ Q^{\pi_{k+\frac{1}{2}}}(s, a) \}$

для теоретически сходящегося обучения используется ε-жадная стратегия: $\pi^{\varepsilon}_{k+1}(a \mid s) = (1 - \varepsilon) \cdot \pi_{k+1}(a \mid s) + \varepsilon \cdot \dfrac{1}{A}$

Сэмплим: $a \sim \pi^{\varepsilon}_{k+1}(\cdot \mid s) = \begin{cases} \text{равномерно из } A \ (\mathrm{Unif}(A)) \text{ с вероятностью } \varepsilon \\ \operatorname{argmax}_{a \in A} \{ Q^{\pi_{k+\frac{1}{2}}}(s, a) \} \text{ с вероятностью } 1 - \varepsilon \end{cases}$