Temporal Difference (TD). SARSA (Expected SARSA). Q-learning.

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi(a'|s)} \mathbb{E}_{P(s'|s,a)} \left[r(s,a,s') + \gamma \cdot Q^{\pi}(s',a') \right]$$

] MDP $M = (D, S, A, \mathbb{P}, r, \gamma)$

$s_0 \sim D(\cdot)$, $s_t \in S$, $a_t \in A$, $t \in \mathbb{Z}_+$, $s_{t+1} \sim \mathbb{P}(\cdot | s_t, a_t)$, $r_t = r(s_t, a_t, s_{t+1})$, $a_t \sim \pi(\cdot | s_t)$

Условия Робинса-Монро

$$\sum_{k=0}^{\infty} \alpha_k = +\infty, \quad \sum_{k=0}^{+\infty} \alpha_k^2 < +\infty$$

$\gamma \in (0,1)$

reward-to-go:

$$R_0^{\infty} := \sum_{t=0}^{\infty} \gamma^t \cdot r_t \to \max_{\pi}$$

онлайн оценивание: $\underbrace{Q_{k+1}(s,a) \leftarrow Q_k(s,a)}_{\text{оценивание } Q^{\pi} \text{ функции для фиксированной } \pi} + \alpha_k \cdot \left(r(s,a,s') + \gamma \cdot Q_k(s',a') - Q_k(s,a) \right)$

$k \in \mathbb{Z}_+$, $s' \sim \mathbb{P}(\cdot | s,a)$, $a' \sim \pi(\cdot | s)$

многошаговое онлайн оценивание: $Q_{k+1}(s,a) \leftarrow Q_k(s,a) + \alpha_k \cdot (\underbrace{y(s,a)}_{\text{целевое значение}} - Q_k(s,a))$

$$y(s,a) = r(s,a,s') + \gamma \cdot r(s',a',s'') + \gamma^2 \cdot r(s'',a'',s''') + \ldots + \gamma^n \cdot r(s^{(n)}, a^{(n)}, s^{(n+1)}) \oplus$$

$$\oplus \gamma^{n+1} \cdot Q(s^{(n+1)}, a^{(n+1)})$$

$a^{(i)} \sim \pi(\cdot | s^{(i)})$, $i = \overline{0, n+1}$

$s^{(i+1)} \sim \mathbb{P}(\cdot | s^{(i)}, a^{(i)})$, $i = \overline{0, n}$

Если $n=0$, то это случай Temporal Difference

Такое многошаговое оценивание решает m-шаговое уравнение Беллмана:

$$Q(s,a) = \mathbb{E}_{p(\tau_{0:m}|\pi)} \left[\underbrace{\sum_{i=0}^{m-1} \gamma^i \cdot r(s^{(i)}, a^{(i)}, s^{(i+1)})} + \gamma^m \cdot Q(s^{(m)}, a^{(m)}) \right]$$

$$p(\tau_{0:m}|\pi) = \left(\prod_{i=0}^{m-1} p(s^{(i+1)} | s^{(i)}, a^{(i)}) \right) \cdot \left(\prod_{i=1}^{m-1} \pi(a^{(i)} | s^{(i)}) \right), \quad \prod_{i=1}^{0} \equiv 1$$

$$\boxed{a^{(0)} \equiv a, \quad s^{(0)} \equiv s}$$

Данное отображение является сжимающим с показателем γ^m.

SARSA: (s, a, r, s', a'), $s' \sim \mathbb{P}(\cdot | s,a)$, $a' \sim \pi(\cdot | s)$

добавляется явное обновление стратегии: $\pi_{k+1}(a|s) = (1-\varepsilon) \cdot \underbrace{\mathbb{1}\{a = \arg\max_{\hat{a} \in A} \{Q_k(s,\hat{a})\}\}}_{\text{performing exploitation}} + \underbrace{\frac{\varepsilon}{|A|}}_{\text{enforcing exploration}}$; $a \sim \pi_{k+1}(\cdot | s) = \begin{cases} \arg\max_{\hat{a} \in A} \{Q_k(s,\hat{a})\}, & \text{с вероятностью } 1-\varepsilon \\ \underbrace{\text{Uniform}(A)}_{\text{равномерное распределение на множестве } A = \{a_1, a_2, \ldots, a_A\},\ A = |A|}, & \text{с вероятностью } \varepsilon \end{cases}$

после обновления стратегии идёт обновление Q-функции:

$$\boxed{\pi_{k+1}(a|s) \geq \frac{\varepsilon}{|A|} \quad \forall (a,s) \in A \times S, \ \forall k \in \mathbb{Z}_+}$$

$$Q_{k+1}(s,a) \leftarrow Q_k(s,a) + \alpha_k \cdot \left(\sum_{i=0}^{m-1} \gamma^i \cdot r(s^{(i)}, a^{(i)}, s^{(i+1)}) + \gamma^m \cdot Q_k(s^{(m)}, a^{(m)}) - Q_k(s,a) \right)$$

Policy Improvement is here $\rightarrow$ $a^{(i)} \sim \pi_{k+1}(\cdot | s^{(i)})$, $i = \overline{1, m}$.

$s^{(i+1)} \sim \mathbb{P}(\cdot | s^{(i)}, a^{(i)})$, $i = \overline{0, m-1}$

Expected SARSA: здесь выполняется взятие $\mathbb{E}$ по π_{k+1}:

$$Q_{k+1}(s,a) \leftarrow Q_k(s,a) + \alpha_k \cdot \left(\sum_{i=0}^{m-1} \gamma^i \cdot \mathbb{E}_{\pi_{k+1}(a^{(i)}|s^{(i)})} \left[r(s^{(i)}, a^{(i)}, s^{(i+1)}) \right] + \gamma^m \cdot \mathbb{E}_{\pi_{k+1}(a^{(m)}|s^{(m)})} \left[Q_k(s^{(m)}, a^{(m)}) \right] - Q_k(s,a) \right)$$

$\leftarrow$ Общая формула обновления Q_{k+1}

$\Downarrow$

$$Q_{k+1}(s,a) \leftarrow Q_k(s,a) + \alpha_k \cdot \left(\sum_{i=0}^{m-1} \gamma^i \cdot \left((1-\varepsilon) \cdot \max_{a^{(i)} \in A} \{ r(s^{(i)}, a^{(i)}, s^{(i+1)}) \} + \frac{\varepsilon}{|A|} \cdot \sum_{a^{(i)} \in A} r(s^{(i)}, a^{(i)}, s^{(i+1)}) \right) + \gamma^m \cdot \left((1-\varepsilon) \cdot \max_{a^{(m)} \in A} \{ Q_k(s^{(m)}, a^{(m)}) \} + \frac{\varepsilon}{|A|} \cdot \sum_{a^{(m)} \in A} Q_k(s^{(m)}, a^{(m)}) \right) - Q_k(s^{(m)}, a^{(m)}) \right)$$

при $\varepsilon = 0$ получаем обновление как у Q-обучения. Если $\varepsilon := 1$, то получаем оценку Q-функции для равномерной стратегии.

Другой способ решения Exploration-Exploitation дилеммы: Больцмановская стратегия.

$$\pi(a|s) := \underset{a}{\text{Softmax}} \left(\frac{Q(s,a)}{t} \right) = \frac{1}{Z} \cdot \exp\left(\frac{Q(s,a)}{t} \right), \quad Z = \sum_{\hat{a} \in A} \exp\left(\frac{Q(s,\hat{a})}{t} \right), \ t > 0.$$

Свойства функции Softmax с температурой:

$$\lim_{t \to 0+} \left\{ \underset{a}{\text{Softmax}} \left(\frac{Q(s,a)}{t} \right) \right\} = \mathbb{1}\{a = \arg\max_{\hat{a} \in A} \{Q(s,\hat{a})\}\} \leftarrow \text{"hard max"}$$

$$\lim_{t \to +\infty} \left\{ \underset{a}{\text{Softmax}} \left(\frac{Q(s,a)}{t} \right) \right\} = \frac{1}{|A|} \leftarrow \text{равномерное распределение}$$

По сравнению с ε-жадной стратегией получим семейство распределений с гиперпараметром $t > 0$, позволяющим непрерывно выбирать между предельными случаями: жадная стратегия ($t = 0$) и равномерная стратегия ($t = +\infty$)

Больцмановские стратегии являются оптимальными для задач Max Entropy Reinforcement Learning (MaxEnRL):

$r(s,a,s') \longrightarrow \underbrace{r(s,a,s') - \lambda \cdot \ln \pi(a|s)}_{\lambda > 0}$, $\lambda = 0$

$$\equiv \tilde{r}(s,a,s') - \ln \pi(a|s), \quad \tilde{r}(s,a,s') := \frac{r(s,a,s')}{\lambda} \leftarrow \text{reward shaping}$$

$$\mathbb{E}_{p(\tau_\infty|\pi)} \left[\sum_{t=0}^{\infty} \gamma^t \cdot (r_t - \lambda \cdot \ln \pi(a_t|s_t)) \right] \longrightarrow \max_{\pi}$$

(задача обучения с подкреплением с регуляризацией на энтропию стратегии)

задача MaxEnRL.

Experience Replay Buffer (Память Буфер)

Алгоритмы Q-обучения в теории слабо требовательны к тому, как собираются траектории.
Это свойство Q-обучения называется Off-policy

Настройка стратегии по Q обучению возможна на произвольном опыте π^{expert} стратегии.
Единственное требование: $\pi^{expert}(a|s) > 0 \quad \forall (s,a) \in S \times A$.

Поэтому на практике используют буфер с переходами (s, a, r, s')

Так модифицированные алгоритмы Q-обучения можно разнести во времени в отдельных процедурах: сбор переходов (s, a, r, s') в T (replay buffer); запуск Q-обучения с (равномерным) сэмплированием $(s, a, r, s') \sim T$.