


Advanced Exploration, Curiosity model.

$M := (S, A, R, P, \gamma)$, $\gamma \in (0, 1)$, S - пространство состояний, A - пространство действий
 Координатно-гексамеризация
 $R: S \times A \times S \rightarrow \mathbb{R}$
 $P: S \times A \rightarrow \Delta(S)$ пространственно вероятностное распределение на S
 $\gamma_0 \in \Delta(S)$
 $\tau := (s_0, a_0, r_0, s_1, \hat{r}_1, a_1, r_1, s_2, \hat{r}_2, \dots, s_T, \hat{r}_T)$
 объединенная траектория



взаимодействие со средой:

$$s_0 \sim \gamma_0$$

для $t = 0, 1, 2, \dots, T-1$:

- 1) $a_t \sim \pi(\cdot | s_t)$
- 2) $r_t := R(s_t, a_t)$
- 3) $s_{t+1} \sim P(\cdot | s_t, a_t)$
- 4) $\hat{r}_t := \hat{R}_t(s_t, a_t, s_{t+1})$

Целевая функция: $E_{p(\tau_t | \pi)} \left[\sum_{t=0}^{T-1} \gamma^t r_t + \sum_{t=0}^{T-1} \gamma^t \hat{r}_t \right] \rightarrow \sup_{\pi \in \Pi}$

$P \in (0, 1)$, γ может быть $\neq \gamma$

правдоподобие траектории:

$$p(\tau_T | \pi) := \gamma_0(s_0) \cdot \prod_{t=0}^{T-1} (\pi(a_t | s_t) \cdot p(s_{t+1} | s_t, a_t))$$

τ функции вероятности и функции плотности вероятности

Внутренний MDP: $\hat{M} := (S, A, R_t, P, \gamma_0, \hat{\gamma})$, $R_t: S \times A \times S \rightarrow \mathbb{R}$, $\hat{\gamma} \in (0, 1)$, $t = \overline{1, T}$.

Intrinsic Curiosity Module (ICM):

$\psi: S \rightarrow \mathbb{R}^d \leftarrow$ гомоморфизм (Embedding); $\varphi: A \rightarrow \mathbb{R}^d \leftarrow$ Embedding гомоморфизм

$f: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ - модель прямой динамики: $\psi(s') = f(\psi(s), \varphi(a))$

$g: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ - модель обратной динамики: $p(a | s, s') = \frac{p(s' | s, a) \cdot \pi(a | s)}{\int_{\mathcal{A}} p(s' | s, a) \cdot \pi(a | s) da}$; $g: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}^d$

$$\hat{r}_t := \frac{1}{2} \|\psi(s_{t+1}) - f(\psi(s_t), \varphi(a_t))\|_2^2$$

обучение гомоморфизмов: $\sum_{t=0}^{T-1} \left(\hat{r}_t + \frac{\alpha}{2} \|\psi(a_t) - g(\psi(s_t), \psi(s_{t+1}))\|_2^2 \right) \rightarrow \min_{f, g, \psi, \varphi}$, $\alpha \geq 0$ - гиперпараметр

Полученная схема ICM не зависит от того, как решается основная (внешняя) задача RL.

По ICM можно создать процедуру обучения π через аддитивно-регуляризатор:

$$h(s_t, a_t, s_{t+1}) := \frac{\lambda}{2} \|\psi(a_t) - g(\psi(s_t), \psi(s_{t+1}))\|_2^2, \lambda \geq 0$$

$$a_t \sim \pi(\cdot | s_t), s_{t+1} \sim P(\cdot | s_t, a_t)$$

Возможный способ обучения одновременно обратной динамики и стратегии:

- 1) Можно 2 режима для нейронной сети: обратная динамика, стратегия.
 $[a_t, \psi(s_{t+1}) \in \mathbb{R}^d]$ $\left[\begin{matrix} \text{negative } 0 \in \mathbb{R}^d \\ \text{вектор } \psi(s_{t+1}) \end{matrix} \right]$

- 2) обучает нейронную сеть согласно заданным режимам:

$$\sum_{t=0}^{T-1} \left(\frac{\lambda}{2} \|\psi(a_t) - g(\psi(s_t), \psi(s_{t+1}))\|_2^2 + \frac{\beta}{2} \|\psi(a_t) - g(\psi(s_t), 0)\|_2^2 \right) \rightarrow \min_{g, \varphi, \psi}$$

- 3) взаимодействие со средой согласно внутренней стратегии: $\hat{a}_t := \psi^{-1}(g(\psi(s_t), 0))$, наличие ψ^{-1} накладывает существенные ограничения на вид ψ !

В случае $a_t \in \mathbb{R}^{d_a}$ ψ можно взять тогда же, когда и отображением

В случае дискретного действия a_t в качестве ψ можно взять преобразование "One-hot-encoder", а в качестве невязки-Кросс-энтропийную функцию.

One-hot-encoder: $\exists a_t \in \mathcal{A}$, $i \in \overline{1, A}$, $|A| = A \Rightarrow \psi(a_t) = (0, \dots, 0, 1, 0, \dots, 0) \in \mathbb{R}^A$
 i-ая позиция

кросс-энтропийная невязка: $\sum_{t=0}^{T-1} \sum_{i=1}^A \mathbb{1}_{\{\psi(a_t) = e_i\}} \left(\ln(g_i(\psi(s_t), \psi(s_{t+1}))) + \beta \cdot \ln(g_i(\psi(s_t), 0)) \right)$

выход $g(\cdot) \rightarrow \text{softmax}$ / вектор из единичного симплекса

$$\hat{a}_t := a_{j_t}, j_t := \arg \max_{j \in \overline{1, A}} \{g_j(\psi(s_t), 0)\}$$