

Policy Gradient. Baseline Estimate.

$$J(\theta) := \mathbb{E}_{\theta} [V^{\pi_{\theta}}] = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t \cdot r_t \right] \rightarrow \max_{\theta \in \Theta}$$

↑ *программа действий* $\mathcal{M} := (\mathcal{S}, \mathcal{A}, P, r, \gamma, \nu)$ $s_0 \sim \nu(\cdot), s_{t+1} \sim P(\cdot | s_t, a_t), a_t \sim \pi(\cdot | s_t)$ $\gamma \in (0, 1)$, $\gamma: \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$
программа действий $\pi: \mathcal{S} \rightarrow \Delta(\mathcal{A})$ $\Delta(\mathcal{S}) \leftarrow$ *выпуклый многоугольник*
 $P: \mathcal{S} \times \mathcal{A} \rightarrow \Delta(\mathcal{S})$
 $r: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$

$$\nabla J(\theta) = \frac{1}{1-\gamma} \mathbb{E}_{\pi_{\theta}} \left[\nabla_{\theta} \ln \pi_{\theta}(a|s) \cdot (Q^{\pi_{\theta}}(s, a) - b(s)) \right]$$

$$Q^{\pi_{\theta}}(s, a) = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t \cdot r_t \mid s_0 = s, a_0 = a \right]$$

$$d_{\pi}(s) = (1-\gamma) \cdot \sum_{t=0}^{\infty} \gamma^t \cdot \mathbb{P}(s_t = s | \pi)$$

$$b(s) : \mathcal{S} \rightarrow \mathbb{R} - \text{базисная}$$

Найти градиент $\nabla_{\theta} J(\theta)$ относительно базисной функции $b(s)$ как градиентного оператора:

$$m := \mathbb{E}_{\pi_{\theta}} \left[\nabla_{\theta} \ln \pi_{\theta}(a|s) \cdot Q^{\pi_{\theta}}(s, a) \right]$$

минимизировать среднее квадратическое отклонение m от нуля:

$$\frac{1}{2} \mathbb{E}_{\pi_{\theta}} \left[\| \nabla_{\theta} \ln \pi_{\theta}(a|s) \cdot (Q^{\pi_{\theta}}(s, a) - b) - m \|^2 \right] \rightarrow \min_{b \in \mathbb{R}}$$

Применяем к b и m оператор Лагранжа (учитывая условие нормировки):

$$\mathbb{E}_{\pi_{\theta}} \left[\left(\nabla_{\theta} \ln \pi_{\theta}(a|s) \cdot (Q^{\pi_{\theta}}(s, a) - b) - m \right)^T \cdot \left(-\nabla_{\theta} \ln \pi_{\theta}(a|s) \right) \right] = 0$$

$$- \mathbb{E}_{\pi_{\theta}} \left[\left\| \nabla_{\theta} \ln \pi_{\theta}(a|s) \right\|_2^2 \cdot Q^{\pi_{\theta}}(s, a) \right] + b \cdot \mathbb{E}_{\pi_{\theta}} \left[\left\| \nabla_{\theta} \ln \pi_{\theta}(a|s) \right\|_2^2 \right] + \mathbb{E}_{\pi_{\theta}} \left[m^T \cdot \nabla_{\theta} \ln \pi_{\theta}(a|s) \right] = 0$$

$$b(s) := \frac{\mathbb{E}_{\pi_{\theta}} \left[\left\| \nabla_{\theta} \ln \pi_{\theta}(a|s) \right\|_2^2 \cdot Q^{\pi_{\theta}}(s, a) \right]}{\mathbb{E}_{\pi_{\theta}} \left[\left\| \nabla_{\theta} \ln \pi_{\theta}(a|s) \right\|_2^2 \right]}$$

$\} \theta \in \mathbb{R}^d$ $= 0 = \sum_{i=1}^d m_i \cdot \mathbb{E}_{\pi_{\theta}} \left[\nabla_{\theta_i} \ln \pi_{\theta}(a|s) \right] = \sum_{i=1}^d m_i \cdot \underbrace{\nabla_{\theta_i} \int_{\mathcal{A}} \pi_{\theta}(a|s) da}_{=1} = 0$