

Лекция 7

Обучение с подкреплением

Никита Юдин, iudin.ne@phystech.edu

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

19 марта 2026



Что делали?

Поставили проблему

В сложных средах случайное исследование плохо работает! Нужно придумать что-то получше.

Что делали?

Поставили проблему

В сложных средах случайное исследование плохо работает! Нужно придумать что-то получше.

Придумали решение

Нужно поощрять умное исследование.

Что делали?

Markov decision process

- $\mathcal{S}$ — множество состояний;
- $\mathcal{A}$ — множество действий;
- $\mathcal{S} \times \mathcal{A} \times \mathcal{S} \mapsto [0, 1]$ — функция вероятности перехода;
- $R^{\text{extr}} : \mathcal{S} \times \mathcal{A} \mapsto \mathbb{R}$ — функция наград для исходной задачи (внешняя).

Auxiliary task

- $\mathcal{S}$ — множество состояний;
- $\mathcal{A}$ — множество действий;
- $\mathcal{S} \times \mathcal{A} \times \mathcal{S} \mapsto [0, 1]$ — функция вероятности перехода;
- $R^{\text{intr}} : \mathcal{S} \times \mathcal{A} \mapsto \mathbb{R}$ — функция наград для лучшего *exploration* (внутренняя).

Что делали?

Пришли к трём решениям

- 1) Наивно: выдавать награду за посещение любого состояния, в котором за этот эпизод мы ещё не были.
- 2) Random Network Distillation: по ошибке на вспомогательной задаче регрессии оцениваем новизну состояния и идём в самые новые состояния.
- 3) Любопытство: шаг в сторону model based алгоритмов — иногда спрашиваем агента: «что будет, если из состояния s совершить действие a ?». Если агент угадывает, то тройка (s, a, s') нам неинтересна, иначе возникает любопытство.

Что делали?

Решили проблему неуправляемого шума

Встроили в агента модель, которая по двум соседним состояниям среды предсказывает действие между ними.

Не решили проблему управляемого шума

Агент очень любит залипать над объектами, на которые он может воздействовать, но не может предсказать результаты этих воздействий. Может это и к лучшему?

Напоминание

Определение

V –**функцией ценности** (или *value function*) называется функция:

$$V^{\pi}(s) = \mathbb{E}_{p(\tau_t|\pi)}[R_t | s_t = s].$$

Это есть средняя награда по политике π , если агент начинает действовать в момент времени t из состояния s .

Q –**функцией ценности** (или *quality function*) называется функция:

$$Q^{\pi}(s, a) = \mathbb{E}_{p(\tau_t|\pi)}[R_t | s_t = s, a_t = a].$$

То же, что и V функция, только теперь из состояния $s_t = s$ обязательно сначала совершается действие $a_t = a$.

Напоминание

Определение

Обозначим оптимальную политику (политику, на которой максимизируется $\mathbb{E}_{p(\tau|\pi)}[R]$) как π^* . Тогда оптимальной **V -функцией ценности** называется функция:

$$V^*(s) = \max_{\pi} \{ \mathbb{E}_{p(\tau_t|\pi)}[R_t | s_t = s] \} = \max_{\pi} \{ V^{\pi}(s) \} = V^{\pi^*}(s).$$

А оптимальной **Q -функцией ценности** называется функция:

$$Q^*(s, a) = \max_{\pi} \{ Q^{\pi}(s, a) \} = Q^{\pi^*}(s, a).$$

Опять про политику

Напоминание

- *On-policy алгоритмы* — алгоритмы, которые оценивают и улучшают ту же самую политику, которую используют для выбора действий (Target Policy = Behavior Policy).
- *Off-policy алгоритмы* — алгоритмы, которые оценивают и улучшают одну политику, а для выбора действий используют другую политику (Target Policy $\neq$ Behavior Policy).

Что получим в этой лекции

DQN

- off-policy
- одношаговое оценивание политики (смещённая)
- ϵ -жадная политика
- учим оптимальную Q -функцию Q^*

Policy Gradient

- on-policy
- оценка до конца эпизода (большая дисперсия)
- обучение явной политики как распределения $\pi(a|s)$
- учим V^π

Постановка задачи и вывод алгоритма

План

- 1) Ввести оптимизационную задачу для *Policy gradient*.
- 2) Вывести градиент оптимизируемой функции первым способом.
- 3) Вывести градиент оптимизируемой функции вторым способом.
- 4) Доказать эквивалентность двух подходов.
- 5) Продемонстрировать физический смысл.

Первый способ

Постановка задачи

Рассмотрим θ -параметризованное семейство политик $\pi(a|s, \theta)$ или $\pi_\theta(a|s)$. Тогда будем максимизировать следующую величину:

$$V^\pi := J(\theta) := \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t \geq 0} \gamma^t r_t \right] \rightarrow \max_{\theta}.$$

Первый способ

Подсчет градиента

$$V^\pi := \mathbb{E}_s \mathbb{E}_{a \sim \pi_\theta} Q^{\pi_\theta}(s, a) = \mathbb{E}_s \int_{\mathcal{A}} \pi_\theta(a|s) Q^{\pi_\theta}(s, a) da,$$

тогда

$$\begin{aligned} \nabla_\theta J(\theta) &= \nabla_\theta \mathbb{E}_s \int_{\mathcal{A}} \pi_\theta(a|s) Q^{\pi_\theta}(s, a) da = \mathbb{E}_s \int_{\mathcal{A}} \nabla_\theta [\pi_\theta(a|s) Q^{\pi_\theta}(s, a)] da = \\ &= \mathbb{E}_s \int_{\mathcal{A}} \nabla_\theta \pi_\theta(a|s) Q^\pi(s, a) da + \mathbb{E}_s \int_{\mathcal{A}} \pi(a|s) \nabla_\theta Q^{\pi_\theta}(s, a) da. \end{aligned}$$

Первый способ

Трюк производной логарифма

$$\nabla_{\theta} p_{\theta}(x) = p_{\theta}(x) \frac{\nabla_{\theta} p_{\theta}(x)}{p_{\theta}(x)} = p_{\theta}(x) \nabla_{\theta} \ln p_{\theta}(x)$$

Первое слагаемое

$$\begin{aligned} \mathbb{E}_s \int_{\mathcal{A}} \nabla_{\theta} \pi_{\theta}(a|s) Q^{\pi}(s, a) da &= \mathbb{E}_s \int_{\mathcal{A}} \pi_{\theta}(a|s) \nabla_{\theta} \ln \pi_{\theta}(a|s) Q^{\pi}(s, a) da = \\ &= \mathbb{E}_s \mathbb{E}_a \nabla_{\theta} \ln \pi_{\theta}(a|s) Q^{\pi}(s, a) \end{aligned}$$

Первый способ

Второе слагаемое

$$\mathbb{E}_s \int_{\mathcal{A}} \pi(a|s) \nabla_{\theta} Q^{\pi_{\theta}}(s, a) da = \mathbb{E}_s \mathbb{E}_a \nabla_{\theta} Q^{\pi_{\theta}}(s, a)$$

Итого

$$\nabla_{\theta} J(\theta) = \mathbb{E}_s \mathbb{E}_a [\nabla_{\theta} \ln \pi_{\theta}(a|s) Q^{\pi}(s, a) + \nabla_{\theta} Q^{\pi_{\theta}}(s, a)]$$

Замечание

Мы смогли выразить градиент V -функции через градиент Q -функции, попробуем сделать наоборот.

Первый способ

Q через V

$$\begin{aligned}\nabla_{\theta} Q^{\pi_{\theta}}(s, a) &= \nabla_{\theta} r(s, a) + \nabla_{\theta} \gamma \mathbb{E}_{s'} V^{\pi_{\theta}}(s') = \\ &= \nabla_{\theta} \gamma \int_{\mathcal{S}} V^{\pi_{\theta}}(s') p(s'|s, a) ds' = \gamma \mathbb{E}_{s'} \nabla_{\theta} V^{\pi_{\theta}}(s')\end{aligned}$$

Подставляя одно в другое

$$\nabla_{\theta} J(\theta) = \mathbb{E}_s \mathbb{E}_a \mathbb{E}_{s'} [\nabla_{\theta} \ln \pi_{\theta}(a|s) Q^{\pi}(s, a) + \gamma \nabla_{\theta} V^{\pi_{\theta}}(s')]$$

Первый способ

Замечание

Получили что-то в духе уравнения Беллмана. В правой части стоит математическое ожидание по действию a , совершаемому из состояния s , и по следующему состоянию s' . Раскроем рекурсию до бесконечности и получим:

Окончательный результат *Policy Gradient Theorem*

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) Q^{\pi}(s_t, a_t),$$

где τ — траектория согласно политике.

Второй способ

Постановка задачи

Рассмотрим θ -параметризированное семейство политик $\pi(a|s, \theta)$ или $\pi_\theta(a|s)$, которое порождает траектории τ с вероятностями $p_\theta(\tau)$. Тогда будем максимизировать следующую величину:

$$V^\pi := J(\theta) := \mathbb{E}_{\tau \sim p_\theta(\tau)} \left[\sum_{t \geq 0} \gamma^t r_t \right] \rightarrow \max_{\theta}.$$

Обозначим награду на траектории τ за $r(\tau) := \sum_{t \geq 0} \gamma^t r_t$.

Второй способ

Вычисляем градиент

По определению математического ожидания:

$$J(\theta) := \mathbb{E}_{\tau \sim p_\theta(\tau)}[r(\tau)] = \int_{\mathcal{T}} p_\theta(\tau) r(\tau) d\tau, \quad \mathcal{T} - \text{носитель траекторий},$$

тогда

$$\nabla_\theta J(\theta) = \int_{\mathcal{T}} \nabla_\theta p_\theta(\tau) r(\tau) d\tau.$$

Трюк производной логарифма

$$\nabla_\theta p_\theta(\tau) = p_\theta(\tau) \frac{\nabla_\theta p_\theta(\tau)}{p_\theta(\tau)} = p_\theta(\tau) \nabla_\theta \ln p_\theta(\tau)$$

Второй способ

Вычисляем градиент

Используем трюк

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \int_{\mathcal{T}} \nabla_{\theta} p_{\theta}(\tau) r(\tau) d\tau = \int_{\mathcal{T}} p_{\theta}(\tau) \nabla_{\theta} \ln p_{\theta}(\tau) \cdot r(\tau) d\tau = \\ &= \mathbb{E}_{\tau \sim p_{\theta}(\tau)} [\nabla_{\theta} \ln p_{\theta}(\tau) r(\tau)].\end{aligned}$$

Вероятность траектории

$$p_{\theta}(\tau) = p_{\theta}(s_0, a_0, \dots, s_{T-1}, a_{T-1}, s_T) = p(s_0) \cdot \prod_{t=0}^{T-1} (\pi_{\theta}(a_t | s_t) p(s_{t+1} | a_t, s_t))$$

Второй способ

Логарифм вероятности траектории

$$\ln p_{\theta}(\tau) = \ln p(s_0) + \sum_{t=0}^{T-1} [\ln \pi_{\theta}(a_t | s_t) + \ln p(s_{t+1} | a_t, s_t)]$$

Градиент логарифма вероятности траектории

$$\nabla_{\theta} \ln p_{\theta}(\tau) = \nabla_{\theta} \sum_{t=0}^{T-1} [\ln \pi_{\theta}(a_t | s_t)] + \underbrace{\nabla_{\theta} \sum_{t=0}^{T-1} [\ln p(s_{t+1} | a_t, s_t)]}_{\substack{\text{нулевой вектор в силу} \\ \text{отсутствия функциональной} \\ \text{зависимости}}}$$

Второй способ

Конечная формула второго способа

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \left[\sum_{t \geq 0} \nabla_{\theta} [\ln \pi_{\theta}(a_t | s_t) r(\tau)] \right]$$

Вывод

Видим, что мы более простым способом получили очень похожую формулу, но с суммарной наградой за игры вместо Q -функции из первого способа. Математически эти формы будут эквивалентны, то есть равны, как интегралы, но их Монте-Карло оценки могут начать вести себя совершенно по-разному.

Эквивалентность

Потихоньку идем к эквивалентности

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \left[\left(\sum_{t \geq 0} \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) \right) \left(\sum_{\hat{t} \geq 0} \gamma^{\hat{t}} r_{\hat{t}} \right) \right] = \\ &= \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \sum_{t \geq 0} \sum_{\hat{t} \geq 0} \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) \gamma^{\hat{t}} r_{\hat{t}},\end{aligned}$$

выпишем одно из слагаемых этой двойной суммы:

$$j_t := \sum_{\hat{t} \geq 0} \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) \gamma^{\hat{t}} r_{\hat{t}}.$$

Эквивалентность

Замечание

Видим, что на слагаемое $j_t = \sum_{\hat{t} \geq 0} \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) \gamma^{\hat{t}} r_{\hat{t}}$, отвечающее за градиент решения выбрать a_t в момент времени t , влияют не только награды после принятия этого решения ($\hat{t} \geq t$), но и награды из прошлого ($\hat{t} < t$), то есть некая величина, на которую наше только что принятое решение никак не могло повлиять.

Пример почему это плохо

До момента времени $t_{\text{near end}} \approx T$ агент мог выполнять максимально хорошие действия и $\sum_{\hat{t} < t_{\text{near end}}} \gamma^{\hat{t}} r_{\hat{t}}$ очень большая величина, а вот решение на $t_{\text{near end}}$ может быть просто ужасным и после него награда всегда минимально возможная. Но на градиенте это плохое решение мы не увидим, потому что в сумме награда всё ещё большая.

Эквивалентность

Теорема

Для произвольного распределения $\pi_\theta(a)$ верно:

$$\mathbb{E}_{a \sim \pi_\theta(a)} \nabla_\theta \ln \pi_\theta(a) = 0.$$

Доказательство

$$\begin{aligned} \mathbb{E}_{a \sim \pi_\theta(a)} \nabla_\theta \ln \pi_\theta(a) &= \mathbb{E}_{a \sim \pi_\theta(a)} \frac{\nabla_\theta \pi_\theta(a)}{\pi_\theta(a)} = \\ &= \int_{\mathcal{A}} \nabla_\theta \pi_\theta(a) da = \nabla_\theta \int_{\mathcal{A}} \pi_\theta(a) da = \nabla_\theta 1 = 0 \end{aligned}$$

Эквивалентность

Теорема — Принцип причинности

При $\hat{t} < t$:

$$\mathbb{E}_{\tau \sim \pi_\theta} \nabla_\theta \ln \pi_\theta(a_t | s_t) \gamma^{\hat{t}} r_{\hat{t}} = 0.$$

Доказательство

По теореме выше:

$$\begin{aligned} \mathbb{E}_{\tau \sim \pi_\theta} \nabla_\theta [\ln \pi_\theta(a_t | s_t) \gamma^{\hat{t}} r_{\hat{t}}] &= \\ \mathbb{E}_{s_0, a_0, s_1, \dots, s_{\hat{t}}, a_{\hat{t}}} \mathbb{E}_{s_{\hat{t}+1}, a_{\hat{t}+1}, \dots, s_t, a_t, \dots} [\nabla_\theta \ln \pi_\theta(a_t | s_t) \gamma^{\hat{t}} r_{\hat{t}}] &= \\ = \mathbb{E}_{s_0, a_0, s_1, \dots, s_{\hat{t}}, a_{\hat{t}}} [\gamma^{\hat{t}} r_{\hat{t}} \cdot \mathbb{E}_{s_{\hat{t}+1}, a_{\hat{t}+1}, \dots, s_t, a_t, \dots} \nabla_\theta \ln \pi_\theta(a_t | s_t)] &= 0. \end{aligned}$$

Эквивалентность

Вывод

В формуле, полученной вторым способом, из суммы можно убрать все слагаемые с $\hat{t} < t$, поскольку они после взятия математического ожидания обратятся в нуль. Плюс ко всему, вычеркивание этих слагаемых уменьшит дисперсию при оценке градиента, полученного вторым способом, по методу Монте-Карло.

Замечание

Дисконтирование в среде идет с самого начала, поэтому дисконтирующий фактор при слагаемых $\hat{t} \geq t$ своей степени не поменяет, а значит, его можно переписать как:

$$\sum_{\hat{t} \geq t} \gamma^{\hat{t}} r_{\hat{t}} = \gamma^t \sum_{\hat{t} \geq t} \gamma^{\hat{t}-t} r_{\hat{t}} = \gamma^t R_t(\tau).$$

Эквивалентность

Приблизились к эквивалентной форме

На данный момент имеем:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) R_t(\tau).$$

Неформальное доказательство эквивалентности

$R_t(\tau)$ — очень похож на Q -функцию, поскольку является её несмещенной Монте-Карло оценкой, а в формуле выше всё равно берется математическое ожидание, поэтому формулы из первого способа и из второго — одно и то же.

Эквивалентность

Теорема об эквивалентности

Следующие формулы эквивалентны:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) Q^{\pi}(s_t, a_t),$$

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) R_t(\tau).$$

Доказательство

$$\begin{aligned}\nabla_{\theta} J(\theta) &= \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) R_t(\tau) = \\&= \sum_{t \geq 0} \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) R_t(\tau) = \\&= \sum_{t \geq 0} \mathbb{E}_{a_0, s_1, \dots, s_t, a_t} \mathbb{E}_{s_{t+1}, a_{t+1}, \dots} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) R_t(\tau) = \\&= \sum_{t \geq 0} \mathbb{E}_{a_0, s_1, \dots, s_t, a_t} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) \mathbb{E}_{s_{t+1}, a_{t+1}, \dots} R_t(\tau) = \\&= \sum_{t \geq 0} \mathbb{E}_{a_0, s_1, \dots, s_t, a_t} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) Q^{\pi}(s_t, a_t) = \\&= \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a_t | s_t) Q^{\pi}(s_t, a_t)\end{aligned}$$

Физический смысл

Заметим

Оказывается, градиент нашего функционала имеет вид градиента взвешенных логарифмов правдоподобий. Чтобы ещё лучше увидеть это, рассмотрим **суррогатную функцию** — другой функционал, который будет иметь в точке текущих значений параметров стратегии π такой же градиент, как и $J(\theta)$:

Определение суррогатной функции

$$\mathcal{L}_{\tilde{\pi}}(\theta) := \mathbb{E}_{\tau \sim \tilde{\pi}} \sum_{t \geq 0} \gamma^t \ln \pi_{\theta}(a|s) Q^{\tilde{\pi}}(s, a)$$

Физический смысл

Что дальше?

Получили суррогатную функцию от двух стратегий: стратегии π_θ , которую мы оптимизируем, и ещё одной стратегии $\tilde{\pi}$. Давайте рассмотрим эту суррогатную функцию в точке θ такой, что эти две стратегии совпадают: $\pi_\theta = \tilde{\pi}$, и посмотрим на градиент при изменении θ , только одной из них. Буквально мы «заморозим» оценочную Q-функцию, и «заморозим» распределение, из которого приходят пары (s, a) .

Утверждение

$$\nabla_\theta \mathcal{L}_{\tilde{\pi}}(\theta)|_{\tilde{\pi}=\pi_\theta} = \nabla_\theta J(\theta)$$

Физический смысл

Доказательство

Поскольку математическое ожидание по траекториям не зависит в этой суррогатной функции от θ , то градиент просто можно пронести внутрь:

$$\nabla_{\theta} \mathcal{L}_{\tilde{\pi}}(\theta)|_{\tilde{\pi}=\pi_{\theta}} = \mathbb{E}_{\tau \sim \tilde{\pi}} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \ln \pi_{\theta}(a|s)|_{\tilde{\pi}=\pi_{\theta}} Q^{\tilde{\pi}}(s, a).$$

В точке θ такой, что $\pi_{\theta} = \tilde{\pi}$ верно, что $p(\tau|\tilde{\pi}) \equiv p(\tau|\pi_{\theta})$ и $Q^{\tilde{\pi}}(s, a) = Q^{\pi}(s, a)$; следовательно, значение градиента в этой точке совпадает со значением формулы для $\nabla_{\theta} J(\theta)$.

Вывод

Значит, направление максимизации $J(\theta)$ в текущей точке θ просто совпадает с направлением максимизации этой суррогатной функции! Таким образом, можно считать, что в текущей точке мы на самом деле «как бы» максимизируем в чистом виде логарифм правдоподобия каких-то пар (s, a) , для каждой из которых дополнительно выдан «вес» в виде значения $Q^\pi(s, a)$.

Физический смысл

Например

Если в машинном обучении в задачах регрессии и классификации мы для данной выборки (x, y) максимизировали правдоподобие:

$$\sum_{(x,y)} \ln p(y|x, \theta) \rightarrow \max_{\theta},$$

то теперь в RL, когда выборки нет, мы действуем по-другому: мы сэмплируем сами себе входные данные s и примеры выходных данных a , выдаём каждой паре какой-то «кредит доверия», некую скалярную оценку качества, выраженную в виде $Q^{\pi}(s, a)$, и идём в направлении максимизации:

$$\sum_{(s,a)} \ln p(a|s, \theta) Q^{\pi}(s, a) \rightarrow \max_{\theta}.$$