

Лекция 9

Обучение с подкреплением

Никита Юдин, iudin.ne@phystech.edu

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

2 апреля 2026



Напоминание: Policy Gradient

$$J(\pi_\theta) := \mathbb{E}_{\mathcal{T} \sim \pi_\theta} \sum_{t \geq 0} \gamma^t r_t$$

Напоминание: Policy Gradient

$$J(\pi_\theta) := \mathbb{E}_{\mathcal{T} \sim \pi_\theta} \sum_{t \geq 0} \gamma^t r_t$$

$$\nabla_\theta J(\pi_\theta) \approx \underbrace{\mathbb{E}_{\mathcal{T} \sim \pi_\theta}}_{\substack{\text{данные, порождённые } \pi_\theta \\ \text{(сэмплирование пар } (s, a) \text{ из траекторий } \mathcal{T} \sim \pi_\theta)}} \sum_{t \geq 0} \underbrace{\nabla_\theta \log \pi_\theta(a_t | s_t)}_{\text{логарифм правдоподобия}} \underbrace{(Q^{\pi_\theta}(s_t, a_t) - V^{\pi_\theta}(s_t))}_{\substack{\text{бэйзлайн} \\ A^{\pi_\theta}(s_t, a_t) \\ \text{оценка критика}}}$$

Напоминание: Policy Gradient

$$J(\pi_\theta) := \mathbb{E}_{\mathcal{T} \sim \pi_\theta} \sum_{t \geq 0} \gamma^t r_t$$

$$\nabla_\theta J(\pi_\theta) \approx \underbrace{\mathbb{E}_{\mathcal{T} \sim \pi_\theta}}_{\substack{\text{данные, порождённые } \pi_\theta \\ \text{(сэмплирование пар } (s, a) \text{ из траекторий } \mathcal{T} \sim \pi_\theta)}} \sum_{t \geq 0} \underbrace{\nabla_\theta \log \pi_\theta(a_t | s_t)}_{\text{логарифм правдоподобия}} \underbrace{(Q^{\pi_\theta}(s_t, a_t) - V^{\pi_\theta}(s_t))}_{\substack{\text{бэйзлайн} \\ A^{\pi_\theta}(s_t, a_t) \\ \text{оценка критика}}}$$

Всё бы ничего, но это оценка вида on-policy!

Существует более эффективный Policy Gradient?

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1 - \gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_{\theta}}(s)} \mathbb{E}_{a \sim \pi_{\theta}(a|s)}}_{\text{данные, порождённые } \pi_{\theta}} \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a)$$

Предположим:

- хотим оптимизировать π_{θ} (вычислить градиент для текущего θ);

Существует более эффективный Policy Gradient?

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1 - \gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_{\theta}}(s)} \mathbb{E}_{a \sim \pi_{\theta}(a|s)}}_{\text{данные, порождённые } \pi_{\theta}} \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a)$$

Предположим:

- хотим оптимизировать π_{θ} (вычислить градиент для текущего θ);
- есть данные (траектории), порождённые π^{old} ;

Существует более эффективный Policy Gradient?

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1 - \gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_{\theta}}(s)} \mathbb{E}_{a \sim \pi_{\theta}(a|s)}}_{\text{данные, порождённые } \pi_{\theta}} \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a)$$

Предположим:

- хотим оптимизировать π_{θ} (вычислить градиент для текущего θ);
- есть данные (траектории), порождённые π^{old} ;
 - т.е. можем оценить $\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)}$ и $\mathbb{E}_{a \sim \pi^{\text{old}}(a|s)}$;

Существует более эффективный Policy Gradient?

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1 - \gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_{\theta}}(s)} \mathbb{E}_{a \sim \pi_{\theta}(a|s)}}_{\text{данные, порождённые } \pi_{\theta}} \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a)$$

Предположим:

- хотим оптимизировать π_{θ} (вычислить градиент для текущего θ);
- есть данные (траектории), порождённые π^{old} ;
 - т.е. можем оценить $\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)}$ и $\mathbb{E}_{a \sim \pi^{\text{old}}(a|s)}$;
 - т.е. можем обучить $V^{\pi^{\text{old}}}(s)$ и, следовательно, оценить $A^{\pi^{\text{old}}}(s, a)$;

Существует более эффективный Policy Gradient?

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1 - \gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_{\theta}}(s)} \mathbb{E}_{a \sim \pi_{\theta}(a|s)}}_{\text{данные, порождённые } \pi_{\theta}} \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a)$$

Предположим:

- хотим оптимизировать π_{θ} (вычислить градиент для текущего θ);
- есть данные (траектории), порождённые π^{old} ;
 - т.е. можем оценить $\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)}$ и $\mathbb{E}_{a \sim \pi^{\text{old}}(a|s)}$;
 - т.е. можем обучить $V^{\pi^{\text{old}}}(s)$ и, следовательно, оценить $A^{\pi^{\text{old}}}(s, a)$;



TRPO: применить оптимизацию эффективнее SGD!

Соединяя две политики



Давайте **изменим награду** с помощью
функции ценности другой политики!

Соединяя две политики



Давайте **изменим награду** с помощью функции ценности другой политики!

Используя **телескопические суммы**: для произвольной последовательности a_t с условием $\lim_{t \rightarrow \infty} a_t = 0$:

$$\sum_{t \geq 0}^{\infty} (a_{t+1} - a_t) = -a_0.$$

Соединяя две политики



Давайте **изменим награду** с помощью функции ценности другой политики!

Используя **телескопические суммы**: для произвольной последовательности a_t с условием $\lim_{t \rightarrow \infty} a_t = 0$:

$$\sum_{t \geq 0}^{\infty} (a_{t+1} - a_t) = -a_0.$$

Для произвольной траектории $\mathcal{T} := s_0, a_0, s_1, a_1, \dots$ и произвольной политики π :

$$-V^{\pi}(s_0) = \sum_{t \geq 0} [\gamma^{t+1} V^{\pi}(s_{t+1}) - \gamma^t V^{\pi}(s_t)]. \quad (1)$$

Relative Performance Identity: доказательство

$$V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) =$$

Relative Performance Identity: доказательство

$$V^{\pi_{\theta}}(s) - V^{\pi^{\text{old}}}(s) = \mathbb{E}_{\mathcal{T} \sim \pi_{\theta} | s_0=s} \sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s) =$$

Relative Performance Identity: доказательство

$$\begin{aligned} V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s) = \\ &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s_0) \right] = \end{aligned}$$

Relative Performance Identity: доказательство

$$\begin{aligned} V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s) = \\ &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s_0) \right] = \\ \{\text{телескопические суммы (1)}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t + \sum_{t \geq 0} \left[\gamma^{t+1} V^{\pi^{\text{old}}}(s_{t+1}) - \gamma^t V^{\pi^{\text{old}}}(s_t) \right] \right] = \end{aligned}$$

Relative Performance Identity: доказательство

$$\begin{aligned} V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s) = \\ &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s_0) \right] = \\ \{\text{телескопические суммы (1)}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t + \sum_{t \geq 0} \left[\gamma^{t+1} V^{\pi^{\text{old}}}(s_{t+1}) - \gamma^t V^{\pi^{\text{old}}}(s_t) \right] \right] = \\ \{\text{перегруппировка членов}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(r_t + \gamma V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right) = \end{aligned}$$

Relative Performance Identity: доказательство

$$\begin{aligned} V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s) = \\ &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s_0) \right] = \\ \{\text{телескопические суммы (1)}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t + \sum_{t \geq 0} \left[\gamma^{t+1} V^{\pi^{\text{old}}}(s_{t+1}) - \gamma^t V^{\pi^{\text{old}}}(s_t) \right] \right] = \\ \{\text{перегруппировка членов}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(r_t + \gamma V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right) = \\ \{\text{по свойству } \mathbb{E}_x f(x) = \mathbb{E}_x \mathbb{E}_x f(x)\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(r_t + \gamma \mathbb{E}_{s_{t+1}} V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right) = \end{aligned}$$

Relative Performance Identity: доказательство

$$\begin{aligned} V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s) = \\ &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s_0) \right] = \\ \{\text{телескопические суммы (1)}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t + \sum_{t \geq 0} \left[\gamma^{t+1} V^{\pi^{\text{old}}}(s_{t+1}) - \gamma^t V^{\pi^{\text{old}}}(s_t) \right] \right] = \\ \{\text{перегруппировка членов}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(r_t + \gamma V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right) = \\ \{\text{по свойству } \mathbb{E}_x f(x) = \mathbb{E}_x \mathbb{E}_x f(x)\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(r_t + \gamma \mathbb{E}_{s_{t+1}} V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right) = \\ \{\text{по определению Q-функции}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(Q^{\pi^{\text{old}}}(s_t, a_t) - V^{\pi^{\text{old}}}(s_t) \right) \end{aligned}$$

Relative Performance Identity: доказательство

$$\begin{aligned} V^{\pi_\theta}(s) - V^{\pi^{\text{old}}}(s) &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s) = \\ &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t - V^{\pi^{\text{old}}}(s_0) \right] = \\ \{\text{телескопические суммы (1)}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \left[\sum_{t \geq 0} \gamma^t r_t + \sum_{t \geq 0} \left[\gamma^{t+1} V^{\pi^{\text{old}}}(s_{t+1}) - \gamma^t V^{\pi^{\text{old}}}(s_t) \right] \right] = \\ \{\text{перегруппировка членов}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(r_t + \gamma V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right) = \\ \{\text{по свойству } \mathbb{E}_x f(x) = \mathbb{E}_x \mathbb{E}_x f(x)\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(r_t + \gamma \mathbb{E}_{s_{t+1}} V^{\pi^{\text{old}}}(s_{t+1}) - V^{\pi^{\text{old}}}(s_t) \right) = \\ \{\text{по определению Q-функции}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t \left(Q^{\pi^{\text{old}}}(s_t, a_t) - V^{\pi^{\text{old}}}(s_t) \right) \\ \{\text{по определению advantage-функции}\} &= \mathbb{E}_{\mathcal{T} \sim \pi_\theta | s_0=s} \sum_{t \geq 0} \gamma^t A^{\pi^{\text{old}}}(s_t, a_t) \end{aligned}$$

Меняем целевую функцию

Мы можем заменить оптимизируемый функционал на:

$$J(\pi_\theta) - J(\pi^{\text{old}}) = \frac{1}{1-\gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_\theta}(s)} \mathbb{E}_{a \sim \pi_\theta(a|s)}}_{\substack{\text{собрать данные с помощью } \pi_\theta \\ \text{(плохо! политика неизвестна!)}}} \overbrace{A^{\pi^{\text{old}}}(s, a)}^{\substack{\text{старый критик!} \\ \text{(хорошо: можем обучить!)}}};$$

Меняем целевую функцию

Мы можем заменить оптимизируемый функционал на:

$$J(\pi_\theta) - J(\pi^{\text{old}}) = \frac{1}{1-\gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_\theta}(s)} \mathbb{E}_{a \sim \pi_\theta(a|s)}}_{\substack{\text{собрать данные с помощью } \pi_\theta \\ \text{(плохо! политика неизвестна!)}}} \overbrace{A^{\pi^{\text{old}}}(s, a)}^{\substack{\text{старый критик!} \\ \text{(хорошо: можем обучить!)}}}$$

✓ можно решить проблему $\mathbb{E}_{a \sim \pi_\theta(a|s)}$ с помощью **выборки по значимости**;

Меняем целевую функцию

Мы можем заменить оптимизируемый функционал на:

$$J(\pi_\theta) - J(\pi^{\text{old}}) = \frac{1}{1-\gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi_\theta}(s)} \mathbb{E}_{a \sim \pi_\theta(a|s)}}_{\substack{\text{собрать данные с помощью } \pi_\theta \\ \text{(плохо! политика неизвестна!)}}} \overbrace{A^{\pi^{\text{old}}}(s, a)}^{\substack{\text{старый критик!} \\ \text{(хорошо: можем обучить!)}}};$$

- ✓ можно решить проблему $\mathbb{E}_{a \sim \pi_\theta(a|s)}$ с помощью **выборки по значимости**;
- ✗ неизвестно, как отсэмплировать $\mathbb{E}_{s \sim d_{\pi_\theta}(s)}$!

Суррогатный функционал

Введём суррогатный функционал:

Суррогатный функционал

Введём суррогатный функционал:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta) := \frac{1}{1-\gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)}}_{\text{данные, порождённые } \pi^{\text{old}}} \overbrace{\mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \frac{\pi_\theta(a|s)}{\pi^{\text{old}}(a|s)}}^{\text{коррекция выборкой по значимости}} \underbrace{A^{\pi^{\text{old}}}(s, a)}_{\text{не требуется свежий критик}} ;$$

Суррогатный функционал

Введём суррогатный функционал:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta) := \frac{1}{1-\gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)}}_{\text{данные, порождённые } \pi^{\text{old}}} \overbrace{\frac{\pi_\theta(a|s)}{\pi^{\text{old}}(a|s)}}^{\text{коррекция выборкой по значимости}} \underbrace{A^{\pi^{\text{old}}}(s, a)}_{\text{не требуется свежий критик}};$$

- с этим можно работать;

Суррогатный функционал

Введём **суррогатный функционал**:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta) := \frac{1}{1-\gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)}}_{\text{данные, порождённые } \pi^{\text{old}}} \overbrace{\frac{\pi_\theta(a|s)}{\pi^{\text{old}}(a|s)}}^{\text{коррекция выборкой по значимости}} \underbrace{A^{\pi^{\text{old}}}(s, a)}_{\text{не требуется свежий критик}};$$

- с этим можно работать;
- указывает на улучшение политики π^{old} :
 - оптимизация θ с фиксированной π^{old} обучит $\arg\max_{a \in \mathcal{A}} A^{\pi^{\text{old}}}(s, a)$

Суррогатный функционал

Введём **суррогатный функционал**:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta) := \frac{1}{1-\gamma} \underbrace{\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)}}_{\text{данные, порождённые } \pi^{\text{old}}} \overbrace{\frac{\pi_\theta(a|s)}{\pi^{\text{old}}(a|s)}}^{\text{коррекция выборкой по значимости}} \underbrace{A^{\pi^{\text{old}}}(s, a)}_{\text{не требуется свежий критик}};$$

- с этим можно работать;
- указывает на улучшение политики π^{old} :
 - оптимизация θ с фиксированной π^{old} обучит $\operatorname{argmax}_{a \in \mathcal{A}} A^{\pi^{\text{old}}}(s, a)$
 - оптимизация θ с фиксированными *данными* обучит $\pi_\theta(a|s) = 1$, если $A(s, a)$ максимальный, $\pi_\theta(a|s) = 0$ иначе.

Теоретическая граница ошибки

$$J(\pi_{\theta}) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta)$$

Хотим оптимизировать *другой* функционал. **Насколько ошибёмся?**

Теоретическая граница ошибки

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta)$$

Хотим оптимизировать *другой* функционал. Насколько ошибёмся?

Теорема

$$|J(\pi_\theta) - J(\pi^{\text{old}}) - L_{\pi^{\text{old}}}(\theta)| \leq C \text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_\theta),$$

Теоретическая граница ошибки

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta)$$

Хотим оптимизировать *другой* функционал. **Насколько ошибёмся?**

Теорема

$$|J(\pi_\theta) - J(\pi^{\text{old}}) - L_{\pi^{\text{old}}}(\theta)| \leq C \text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_\theta),$$

где:

$$\text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_\theta) := \max_{s \in \mathcal{S}} \text{KL}(\pi^{\text{old}}(\cdot \mid s) \parallel \pi_\theta(\cdot \mid s));$$

Теоретическая граница ошибки

$$J(\pi_\theta) - J(\pi^{\text{old}}) \approx L_{\pi^{\text{old}}}(\theta)$$

Хотим оптимизировать *другой* функционал. **Насколько ошибёмся?**

Теорема

$$|J(\pi_\theta) - J(\pi^{\text{old}}) - L_{\pi^{\text{old}}}(\theta)| \leq C \text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_\theta),$$

где:

$$\text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_\theta) := \max_{s \in \mathcal{S}} \text{KL}(\pi^{\text{old}}(\cdot \mid s) \parallel \pi_\theta(\cdot \mid s));$$

$$C := \frac{4\gamma \max_{s \in \mathcal{S}, a \in \mathcal{A}} |A^{\pi^{\text{old}}}(s, a)|}{(1 - \gamma)^2}.$$

Алгоритм миноризации-максимизации



Нашли **вариационную нижнюю
оценку** для нашего функционала:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \geq L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta)$$


Алгоритм миноризации-максимизации



Нашли **вариационную нижнюю оценку** для нашего функционала:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \geq L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta)$$

- **Миноризация:** построить новую нижнюю оценку; в нашем случае использовать $\pi^{\text{old}} \leftarrow \pi_\theta$.




Алгоритм миноризации-максимизации



Нашли **вариационную нижнюю оценку** для нашего функционала:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \geq L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta)$$

- **Миноризация:** построить новую нижнюю оценку; в нашем случае использовать $\pi^{\text{old}} \leftarrow \pi_\theta$.
- **Максимизация:** оптимизация нижней оценки (произвольным способом).




Алгоритм миноризации-максимизации



Нашли **вариационную нижнюю оценку** для нашего функционала:

$$J(\pi_\theta) - J(\pi^{\text{old}}) \geq L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_\theta)$$

- **Миноризация:** построить новую нижнюю оценку; в нашем случае использовать $\pi^{\text{old}} \leftarrow \pi_\theta$.
- **Максимизация:** оптимизация нижней оценки (произвольным способом).
 - ✓ гарантия монотонного улучшения!



Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик идеален :(



Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...



Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...
- не умеем работать с KL^{max} :(



Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...
- не умеем работать с KL^{max} :(
 - меняем на $\mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s))$...



Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...
- не умеем работать с KL^{max} :(
 - меняем на $\mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s))$...
- не знаем C :(



Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...
- не умеем работать с KL^{max} :(
 - меняем на $\mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s))$...
- не знаем C :(
 - сделаем гиперпараметром...



Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\text{max}}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...
- не умеем работать с KL^{max} :(
 - меняем на $\mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s))$...
- не знаем C :(
 - сделаем гиперпараметром...
- и на деле он часто очень большой :(
 - хм...




Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...
- не умеем работать с $\text{KL}^{\max}$:(
 - меняем на $\mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s))$...
- не знаем C :(
 - сделаем гиперпараметром...
- и на деле он часто очень большой :(
 - хм...




Воспользуемся принципом "проб и ошибок"

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}^{\max}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Проблемы:

- критик неидеален :(
 - используем, что есть...
- не умеем работать с $\text{KL}^{\max}$:(
 - меняем на $\mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s))$...
- не знаем C :(
 - сделаем гиперпараметром...
- и на деле он часто очень большой :(
 - хм...



Directed by
ROBERT B. WEIDE




Оптимизировать $L_{\pi^{\text{old}}}(\theta)$ с условием, что π_θ не изменится сильно относительно π^{old} !



Оптимизировать $L_{\pi^{\text{old}}}(\theta)$ с условием, что π_θ не изменится сильно относительно π^{old} !

$$\begin{cases} L_{\pi^{\text{old}}}(\theta) \rightarrow \max_{\theta} \\ \mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_\theta(\cdot | s)) \leq \delta \end{cases}$$


$$\text{KL}(\pi^{\text{old}} \parallel \pi) \leq \delta$$





Оптимизировать $L_{\pi^{\text{old}}}(\theta)$ с условием, что π_θ не изменится сильно относительно π^{old} !

$$\text{KL}(\pi^{\text{old}} \parallel \pi) \leq \delta$$




$$\begin{cases} L_{\pi^{\text{old}}}(\theta) \rightarrow \max_{\theta} \\ \mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_\theta(\cdot | s)) \leq \delta \end{cases}$$

- $L_{\pi^{\text{old}}}(\theta)$ – модель функционала;
- условие – доверительная область этой модели.



Оптимизировать $L_{\pi^{\text{old}}}(\theta)$ с условием, что π_θ не изменится сильно относительно π^{old} !

$$\text{KL}(\pi^{\text{old}} \parallel \pi) \leq \delta$$



$$\begin{cases} L_{\pi^{\text{old}}}(\theta) \rightarrow \max_{\theta} \\ \mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_\theta(\cdot | s)) \leq \delta \end{cases}$$

- $L_{\pi^{\text{old}}}(\theta)$ – модель функционала;
- условие – доверительная область этой модели.

Алгоритм **TRPO** решает приблизительно данную задачу. Сложная имплементация.



Использовать разложение
Тейлора для модели и
условия при решении задачи!



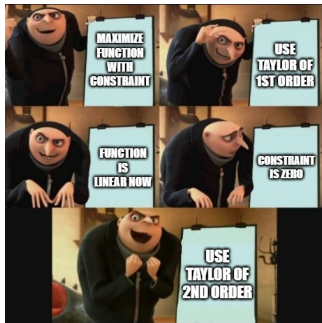
Использовать разложение
Тейлора для модели и
условия при решении задачи!

$$L_{\pi^{\text{old}}}(\theta) \approx g^T d \rightarrow \max_d,$$
$$d := \theta - \theta^{\text{old}}, \quad g := \nabla_{\theta} L_{\pi^{\text{old}}}(\theta)|_{\theta=\theta^{\text{old}}}.$$



Использовать разложение
Тейлора для модели и
условия при решении задачи!

$$L_{\pi^{\text{old}}}(\theta) \approx g^T d \rightarrow \max_d,$$
$$d := \theta - \theta^{\text{old}}, \quad g := \nabla_{\theta} L_{\pi^{\text{old}}}(\theta)|_{\theta=\theta^{\text{old}}}.$$



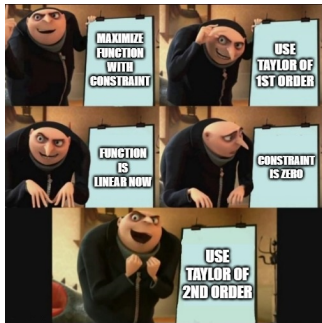


Использовать разложение
Тейлора для модели и
условия при решении задачи!

$$L_{\pi^{\text{old}}}(\theta) \approx g^T d \rightarrow \max_d,$$
$$d := \theta - \theta^{\text{old}}, \quad g := \nabla_{\theta} L_{\pi^{\text{old}}}(\theta)|_{\theta=\theta^{\text{old}}}.$$

Для KL-дивергенции, первое слагаемое 0,
используем разложение второго порядка:

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s)) \approx \frac{1}{2} d^T H d \leq \delta.$$



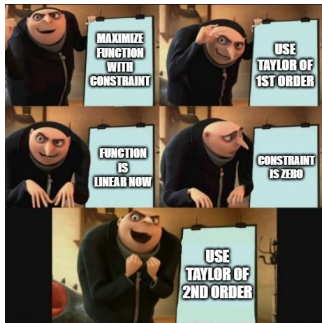


Использовать разложение
Тейлора для модели и
условия при решении задачи!

$$L_{\pi^{\text{old}}}(\theta) \approx g^T d \rightarrow \max_d, \\ d := \theta - \theta^{\text{old}}, \quad g := \nabla_{\theta} L_{\pi^{\text{old}}}(\theta)|_{\theta=\theta^{\text{old}}}.$$

Для KL-дивергенции, первое слагаемое 0,
используем разложение второго порядка:

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s)) \approx \frac{1}{2} d^T H d \leq \delta.$$



Натуральный градиентный подъём

Решение: $d \propto H^{-1}g$

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?



$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?



Решать следующую СЛАУ:



$$Hd = g$$

с помощью **метода сопряжённых градиентов**.

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?



Решать следующую СЛАУ:



$$Hd = g$$

с помощью **метода сопряжённых градиентов**.

1. вычислить g
(как в обычном градиентном спуске);

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?



Решать следующую СЛАУ:



$$Hd = g$$

с помощью **метода
сопряжённых градиентов**.

1. вычислить g
(как в обычном градиентном спуске);
2. инициализировать d_0 произвольно;
3. для $i = 0, 1, 2 \dots M$:

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?



Решать следующую СЛАУ:



$$Hd = g$$

с помощью **метода
сопряжённых градиентов**.

1. вычислить g
(как в обычном градиентном спуске);
2. инициализировать d_0 произвольно;
3. для $i = 0, 1, 2 \dots M$:
 - метод сопряжённых градиентов приближённо вычисляет d_{i+1} с помощью g и вектора Hd_i ;

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?



Решать следующую СЛАУ:



$$Hd = g$$

с помощью **метода
сопряжённых градиентов**.

1. вычислить g
(как в обычном градиентном спуске);
2. инициализировать d_0 произвольно;
3. для $i = 0, 1, 2 \dots M$:
 - метод сопряжённых градиентов приближённо вычисляет d_{i+1} с помощью g и вектора Hd_i ;
4. с помощью линейного поиска найти α_k ;

$$\theta_{k+1} = \theta_k + \alpha H^{-1} g$$

Внимание!

Натуральный градиентный подъём похож на методы второго порядка.

Допустим, h – размерность θ ...

X H – матрица $h \times h$
(гессиан
KL-дивергенции);

X Как обращаться?



Решать следующую СЛАУ:



$$Hd = g$$

с помощью **метода
сопряжённых градиентов**.

1. вычислить g
(как в обычном градиентном спуске);
2. инициализировать d_0 произвольно;
3. для $i = 0, 1, 2 \dots M$:
 - метод сопряжённых градиентов приближённо вычисляет d_{i+1} с помощью g и вектора Hd_i ;
4. с помощью линейного поиска найти α_k ;
5. $\theta_{k+1} = \theta_k + \alpha_k d_M$.

Линейный поиск

Как определить шаг α_k ?

(он связан с δ в подходах с доверительной областью)

$$\theta_{k+1} = \theta_k + \alpha_k d_k$$



Линейный поиск

Как определить шаг α_k ?

(он связан с δ в подходах с доверительной областью)

$$\theta_{k+1} = \theta_k + \alpha_k d_k$$



Использовать **бэктрекинг** для поиска α_k , так что:



$$L_{\pi^{\text{old}}}(\theta_{k+1}) > 0, \quad \mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta_{k+1}}(\cdot | s)) \leq \delta.$$

Линейный поиск

Как определить шаг α_k ?

(он связан с δ в подходах с доверительной областью)

$$\theta_{k+1} = \theta_k + \alpha_k d_k$$



Использовать **бэктрекинг** для поиска α_k , так что:



$$L_{\pi^{\text{old}}}(\theta_{k+1}) > 0, \quad \mathbb{E}_s \text{KL}(\pi^{\text{old}}(\cdot | s) \parallel \pi_{\theta_{k+1}}(\cdot | s)) \leq \delta.$$


Например, уменьшить α_k вдвое,
пока не выполняются условия.

Trust Region Policy Optimization (TRPO)

$$\begin{cases} L_{\pi^{\text{old}}}(\theta) \rightarrow \max_{\theta} \\ \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \leq \delta \end{cases}$$

- ✓ робастно: предотвращает большие изменения;


$$\text{KL}(\pi^{\text{old}} \parallel \pi) \leq \delta$$




Trust Region Policy Optimization (TRPO)

$$\begin{cases} L_{\pi^{\text{old}}}(\theta) \rightarrow \max_{\theta} \\ \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \leq \delta \end{cases}$$

$$\text{KL}(\pi^{\text{old}} \parallel \pi) \leq \delta$$




- ✓ робастно: предотвращает большие изменения;




Trust Region Policy Optimization (TRPO)

$$\begin{cases} L_{\pi^{\text{old}}}(\theta) \rightarrow \max_{\theta} \\ \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \leq \delta \end{cases}$$

$\text{KL}(\pi^{\text{old}} \parallel \pi) \leq \delta$



- ✓ робастно: предотвращает
большие изменения;



Trust Region Policy Optimization (TRPO)


$$\begin{cases} L_{\pi^{\text{old}}}(\theta) \rightarrow \max_{\theta} \\ \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \leq \delta \end{cases}$$

$$\text{KL}(\pi^{\text{old}} \parallel \pi) \leq \delta$$





✓ робастно: предотвращает большие изменения;

- ✗ актора и критика не получится архитектурно скрестить;
- ✗ вычислительно дорого;
- ✗ сложно :(





Trust region: пространство параметров или пространство распределений

Две гауссианы: $\mathcal{N}(0, 0.2)$, $\mathcal{N}(1, 0.2)$. Две гауссианы: $\mathcal{N}(0, 10)$, $\mathcal{N}(1, 10)$.



Trust region: пространство параметров или пространство распределений

Две гауссианы: $\mathcal{N}(0, 0.2)$, $\mathcal{N}(1, 0.2)$. Две гауссианы: $\mathcal{N}(0, 10)$, $\mathcal{N}(1, 10)$.



Евклидово расстояние: $\sqrt{(\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2}$.

Статистическое расстояние: например, $\text{KL}(\mathcal{N}(\mu_1, \sigma_1) \parallel \mathcal{N}(\mu_2, \sigma_2))$.

Проблема шага: скатывание с обрыва



$$\theta_{k+1} = \theta_k + \alpha \hat{g}_k$$

Если шаг слишком велик:

- широкие шаги ведут к плохой политике;
- начинаем *собирать данные* с помощью плохой политики;
- $\Rightarrow$ **качество коллапсирует**.

Проблема шага: скатывание с обрыва



$$\theta_{k+1} = \theta_k + \alpha \hat{g}_k$$

Если шаг слишком велик:

- широкие шаги ведут к плохой политике;
- начинаем *собирать данные* с помощью плохой политики;
- $\Rightarrow$ **качество коллапсирует.**



Требуется метод, измеряющий расстояние
в пространстве распределений,
а не в пространстве параметров!

Рассмотрим следующую задачу оптимизации:

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}.$$

Рассмотрим следующую задачу оптимизации:

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}.$$

Общая схема методов оптимизации с доверительной областью

- начало с произвольного θ_0 ;
- для $k = 0, 1, 2, \dots$:
 - построение **модели**, некоторой локальной аппроксимации $G(\theta)$ около θ_k :

$$m_k(\theta) \approx G(\theta);$$

Рассмотрим следующую задачу оптимизации:

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}.$$

Общая схема методов оптимизации с доверительной областью

- начало с произвольного θ_0 ;
- для $k = 0, 1, 2, \dots$:
 - построение **модели**, некоторой локальной аппроксимации $G(\theta)$ около θ_k :
$$m_k(\theta) \approx G(\theta);$$
 - выбор некоторой **области доверия**, где предполагается модель достаточно точной:
$$r(\theta, \theta_k) \leq \delta;$$

Рассмотрим следующую задачу оптимизации:

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}.$$

Общая схема методов оптимизации с доверительной областью

- начало с произвольного θ_0 ;
- для $k = 0, 1, 2, \dots$:
 - построение **модели**, некоторой локальной аппроксимации $G(\theta)$ около θ_k :
$$m_k(\theta) \approx G(\theta);$$
 - выбор некоторой **области доверия**, где предполагается модель достаточно точной:
$$r(\theta, \theta_k) \leq \delta;$$
 - поиск θ_{k+1} в качестве решения


$$\begin{cases} m_k(\theta) \rightarrow \min_{\theta}; \\ r(\theta, \theta_k) \leq \delta. \end{cases}$$

Натуральный градиентный спуск

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}$$

Градиентный спуск

$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ \|d\|_2 \leq \delta \end{cases}$$




Натуральный градиентный спуск

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}$$


Градиентный спуск

$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ \|d\|_2 \leq \delta \end{cases}$$



Натуральный градиентный спуск

$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ \text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \leq \delta \end{cases}$$




Натуральный градиентный спуск

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}$$

Градиентный спуск


$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ \|d\|_2 \leq \delta \end{cases}$$



Решение: $d \propto -\nabla_{\theta} G(\theta_k)$

Натуральный градиентный спуск

$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ \text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \leq \delta \end{cases}$$




Натуральный градиентный спуск

$$G(\theta) := G(q_\theta(x)) \rightarrow \min_{\theta}$$

Градиентный спуск


$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ \|d\|_2 \leq \delta \end{cases}$$



Решение: $d \propto -\nabla_{\theta} G(\theta_k)$

Натуральный градиентный спуск

$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ \text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \leq \delta \end{cases}$$



Решение: ?!?



Используем разложение
Тейлора для
 $KL(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \leq \delta.$



Используем разложение
Тейлора для
 $\text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \leq \delta.$

(!) Первый член в действительности равен нулю:

$$\nabla_d \text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x))|_{d=0} = 0.$$



Используем разложение
Тейлора для
 $\text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \leq \delta.$

(!) Первый член в действительности равен нулю:

$$\nabla_d \text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x))|_{d=0} = 0.$$

Информационная матрица Фишера

Пусть $F(\theta_k)$ будет **матрицей Фишера** распределения $q_\theta(x)$ в точке θ_k :

$$F(\theta_k) := -\mathbb{E}_{x \sim q_\theta(x)} \nabla_\theta^2 \log q_\theta(x).$$



Используем разложение
Тейлора для
 $\text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \leq \delta.$

(!) Первый член в действительности равен нулю:

$$\nabla_d \text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x))|_{d=0} = 0.$$

Информационная матрица Фишера

Пусть $F(\theta_k)$ будет **матрицей Фишера** распределения $q_{\theta}(x)$ в точке θ_k :


$$F(\theta_k) := -\mathbb{E}_{x \sim q_{\theta_k}(x)} \nabla_{\theta}^2 \log q_{\theta}(x).$$

Тогда приближение по Тейлору второго порядка:

$$\text{KL}(q_{\theta_k}(x) \parallel q_{\theta_k+d}(x)) \approx \frac{1}{2} d^T F(\theta_k) d.$$

Направление натурального градиента


$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ d^T F(\theta_k) d \leq \delta \end{cases}$$



Направление натурального градиента

$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ d^T F(\theta_k) d \leq \delta \end{cases}$$

Решение: $d \propto -F^{-1}(\theta_k) \nabla_{\theta} G(\theta_k)$.



Направление натурального градиента

$$\begin{cases} G(\theta_k + d) \approx G(\theta_k) + \nabla_{\theta} G(\theta_k)^T d \rightarrow \min_d \\ d^T F(\theta_k) d \leq \delta \end{cases}$$

Решение: $d \propto -F^{-1}(\theta_k) \nabla_{\theta} G(\theta_k)$.

Метод натурального градиента обновляет параметры следующим образом:

$$\theta_{k+1} = \theta_k - \alpha F^{-1}(\theta_k) \nabla_{\theta} G(\theta_k),$$

где α определяется выбором δ .

