

Лекция 10

Обучение с подкреплением

Никита Юдин, iudin.ne@phystech.edu

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

9 апреля 2026




Proximal Policy Optimization (PPO): пайплайн

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \frac{\pi_{\theta}(a | s)}{\pi^{\text{old}}(a | s)} A^{\pi^{\text{old}}}(s, a) - C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$


Proximal Policy Optimization (PPO): пайплайн

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \frac{\pi_{\theta}(a|s)}{\pi^{\text{old}}(a|s)} A^{\pi^{\text{old}}}(s, a) - C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$



Proximal Policy Optimization (PPO): пайплайн

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \frac{\pi_{\theta}(a|s)}{\pi^{\text{old}}(a|s)} A^{\pi^{\text{old}}}(s, a) - C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$



Клиппирование (ограничение) оптимизируемого функционала

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Суррогатный функционал:

$$\rho(\theta) := \frac{\pi_{\theta}(a \mid s)}{\pi^{\text{old}}(a \mid s)}$$

$$L_{\pi^{\text{old}}}(\theta) := \mathbb{E}_{s,a} \rho(\theta) A^{\pi^{\text{old}}}(s, a)$$


Клиппирование (ограничение) оптимизируемого функционала

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Суррогатный функционал:

$$\rho(\theta) := \frac{\pi_{\theta}(a \mid s)}{\pi^{\text{old}}(a \mid s)}$$

$$L_{\pi^{\text{old}}}(\theta) := \mathbb{E}_{s,a} \rho(\theta) A^{\pi^{\text{old}}}(s, a)$$



Клиппирование (ограничение) оптимизируемого функционала

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Суррогатный функционал:

$$\rho(\theta) := \frac{\pi_{\theta}(a \mid s)}{\pi^{\text{old}}(a \mid s)}$$


$$L_{\pi^{\text{old}}}(\theta) := \mathbb{E}_{s,a} \rho(\theta) A^{\pi^{\text{old}}}(s, a)$$



Клиппированный суррогатный
функционал:

$$\rho^{\text{clip}}(\theta) := \text{clip}(\rho(\theta), 1 - \epsilon, 1 + \epsilon)$$

$$L_{\pi^{\text{old}}}^{\text{clip}}(\theta) := \mathbb{E}_{s,a} \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a)$$




Клиппирование (ограничение) оптимизируемого функционала

$$L_{\pi^{\text{old}}}(\theta) - C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta}) \rightarrow \max_{\theta}$$

Суррогатный функционал:

$$\rho(\theta) := \frac{\pi_{\theta}(a \mid s)}{\pi^{\text{old}}(a \mid s)}$$


$$L_{\pi^{\text{old}}}(\theta) := \mathbb{E}_{s,a} \rho(\theta) A^{\pi^{\text{old}}}(s, a)$$



Клиппированный суррогатный
функционал:

$$\rho^{\text{clip}}(\theta) := \text{clip}(\rho(\theta), 1 - \epsilon, 1 + \epsilon)$$

$$L_{\pi^{\text{old}}}^{\text{clip}}(\theta) := \mathbb{E}_{s,a} \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a)$$



Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \min(\overbrace{\rho(\theta) A^{\pi^{\text{old}}}(s, a)}^{\text{исходный член}}, \overbrace{\rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a)}^{\text{с клиппированным весом значимости сэмпла}}) - \overbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}^{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\text{исходный член с клиппированным весом значимости сэмпла}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$			

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\substack{\text{исходный член} \\ \text{с клиппированным весом} \\ \text{значимости сэмпла}}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$		

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\substack{\text{исходный член} \\ \text{с клиппированным весом} \\ \text{значимости сэмпла}}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$	$\rho(\theta) > 1.2$	

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\substack{\text{исходный член} \\ \text{с клиппированным весом} \\ \text{значимости сэмпла}}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$	$\rho(\theta) > 1.2$	0

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\substack{\text{исходный член} \\ \text{с клиппированным весом} \\ \text{значимости сэмпла}}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	0

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\text{исходный член с клиппированным весом значимости сэмпла}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	0 тот же

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\text{исходный член}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$

с клиппированным весом
значимости сэмпла

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	0 тот же
$A^{\pi^{\text{old}}}(s, a) < 0$	$\pi_{\theta}(a s) \downarrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\text{исходный член}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{с клиппированным весом значимости сэмпла}} \rightarrow \max_{\theta}$$


Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	0 тот же
$A^{\pi^{\text{old}}}(s, a) < 0$	$\pi_{\theta}(a s) \downarrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	тот же 0

Вспоминая интуицию с нижней оценкой

$$\mathbb{E}_{s \sim d_{\pi^{\text{old}}}(s)} \mathbb{E}_{a \sim \pi^{\text{old}}(a|s)} \underbrace{\min(\rho(\theta) A^{\pi^{\text{old}}}(s, a), \rho^{\text{clip}}(\theta) A^{\pi^{\text{old}}}(s, a))}_{\text{исходный член}} - \underbrace{C \text{KL}(\pi^{\text{old}} \parallel \pi_{\theta})}_{\text{«регуляризатор»}} \rightarrow \max_{\theta}$$


с клипированным весом
значимости сэмпла

Знак Advantage	Направление	Значение веса	Градиент
$A^{\pi^{\text{old}}}(s, a) \geq 0$	$\pi_{\theta}(a s) \uparrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	0 тот же
$A^{\pi^{\text{old}}}(s, a) < 0$	$\pi_{\theta}(a s) \downarrow$	$\rho(\theta) > 1.2$ $\rho(\theta) < 0.8$	тот же 0




Клиппированная функция потерь критика

$$\text{Loss}(\phi) := (y(s, a) - V_\phi(s))^2 =$$




Клиппированная функция потерь критика

$$\begin{aligned}\text{Loss}(\phi) &:= (y(s, a) - V_\phi(s))^2 = \\ &= (y(s, a) - V^{\text{old}}(s) + \\ &+ V^{\text{old}}(s) - V_\phi(s))^2\end{aligned}$$




Клиппированная функция потерь критика

$$\begin{aligned}\text{Loss}(\phi) &:= (y(s, a) - V_\phi(s))^2 = \\ &= (y(s, a) - V^{\text{old}}(s) + \\ &+ V^{\text{old}}(s) - V_\phi(s))^2\end{aligned}$$




$$\begin{aligned}\text{Loss}^{\text{clip}}(\phi) &:= (y(s, a) - V^{\text{old}}(s) + \\ &+ \text{clip}(V^{\text{old}}(s) - V_\phi(s), -\hat{\epsilon}, \hat{\epsilon}))^2\end{aligned}$$




Клиппированная функция потерь критика


$$\begin{aligned}\text{Loss}(\phi) &:= (y(s, a) - V_\phi(s))^2 = \\ &= (y(s, a) - V^{\text{old}}(s) + \\ &+ V^{\text{old}}(s) - V_\phi(s))^2\end{aligned}$$



$$\begin{aligned}\text{Loss}^{\text{clip}}(\phi) &:= (y(s, a) - V^{\text{old}}(s) + \\ &+ \text{clip}(V^{\text{old}}(s) - V_\phi(s), -\hat{\epsilon}, \hat{\epsilon}))^2\end{aligned}$$



$$\max(\text{Loss}(\phi), \text{Loss}^{\text{clip}}(\phi))$$



Компромисс между смещением и разбросом

Дана траектория $s, r, s', r', s'', r'' \dots s^{(M)}$ по политике π и приближение $V^\pi(s)$

Компромисс между смещением и разбросом

Дана траектория $s, r, s', r', s'', r'' \dots s^{(M)}$ по политике π и приближение $V^\pi(s)$
выполним **оценку advantage (credit assignment)** для пары s, a
(хорошее ли решение принято было?)

Компромисс между смещением и разбросом

Дана траектория $s, r, s', r', s'', r'' \dots s^{(M)}$ по политике π и приближение $V^\pi(s)$

выполним **оценку advantage (credit assignment)** для пары s, a
(хорошее ли решение принято было?)

Для актора:

$$\nabla := \rho(\theta) \nabla_{\theta} \log \pi_{\theta}(a \mid s) \underbrace{\Psi(s, a)}_{\substack{\text{оценка} \\ \text{advantage}}}$$

Для критика:

$$\underbrace{y_Q}_{\substack{\text{целевое значение} \\ \text{для регрессии}}} := \Psi(s, a) + V(s)$$

Компромисс между смещением и разбросом

Дана траектория $s, r, s', r', s'', r'' \dots s^{(M)}$ по политике π и приближение $V^\pi(s)$

выполним **оценку advantage (credit assignment)** для пары s, a (хорошее ли решение принято было?)

Для актора:

$$\nabla := \rho(\theta) \nabla_{\theta} \log \pi_{\theta}(a | s) \underbrace{\Psi(s, a)}_{\substack{\text{оценка} \\ \text{advantage}}}$$

Для критика:

$$\underbrace{y_Q}_{\substack{\text{целевое значение} \\ \text{для регрессии}}} := \Psi(s, a) + V(s)$$

	$\Psi(s, a)$	Смещение	Разброс
Монте-Карло	$\Psi_{(\infty)}(s, a) := r + \gamma r' + \gamma^2 r'' + \dots - V(s)$	0	высокий
1-шаг	$\Psi_{(1)}(s, a) := r + \gamma V(s') - V(s)$	высокое	низкий

Компромисс между смещением и разбросом

Дана траектория $s, r, s', r', s'', r'' \dots s^{(M)}$ по политике π и приближение $V^\pi(s)$

выполним **оценку advantage (credit assignment)** для пары s, a (хорошее ли решение принято было?)

Для актора:

$$\nabla := \rho(\theta) \nabla_{\theta} \log \pi_{\theta}(a | s) \underbrace{\Psi(s, a)}_{\substack{\text{оценка} \\ \text{advantage}}}$$

Для критика:

$$\underbrace{y_Q}_{\substack{\text{целевое значение} \\ \text{для регрессии}}} := \Psi(s, a) + V(s)$$

	$\Psi(s, a)$	Смещение	Разброс
Монте-Карло N -шагов 1-шаг	$\Psi_{(\infty)}(s, a) := r + \gamma r' + \gamma^2 r'' + \dots - V(s)$ $\Psi_{(N)}(s, a) := r + \gamma r' + \dots + \gamma^N V(s^{(N)}) - V(s)$ $\Psi_{(1)}(s, a) := r + \gamma V(s') - V(s)$	0 промежуточное высокое	высокий промежуточный низкий

Компромисс между смещением и разбросом

Дана траектория $s, r, s', r', s'', r'' \dots s^{(M)}$ по политике π и приближение $V^\pi(s)$

выполним **оценку advantage (credit assignment)** для пары s, a (хорошее ли решение принято было?)

Для актора:

$$\nabla := \rho(\theta) \nabla_{\theta} \log \pi_{\theta}(a | s) \underbrace{\Psi(s, a)}_{\substack{\text{оценка} \\ \text{advantage}}}$$

Для критика:

$$\underbrace{y_Q}_{\substack{\text{целевое значение} \\ \text{для регрессии}}} := \Psi(s, a) + V(s)$$


	$\Psi(s, a)$	Смещение	Разброс
Монте-Карло N -шагов 1-шаг	$\Psi_{(\infty)}(s, a) := r + \gamma r' + \gamma^2 r'' + \dots - V(s)$ $\Psi_{(N)}(s, a) := r + \gamma r' + \dots + \gamma^N V(s^{(N)}) - V(s)$ $\Psi_{(1)}(s, a) := r + \gamma V(s') - V(s)$	0 промежуточное высокое	высокий промежуточный низкий

Проблема: выбор N .

Взгляд назад: идея

N -шаговое обновление:


$$V(s) \leftarrow V(s) + \alpha \Psi_{(N)}(s, a)$$



Взгляд назад: идея

N -шаговое обновление:

$$V(s) \leftarrow V(s) + \alpha \Psi_{(N)}(s, a)$$




$$V(s) \leftarrow V(s) + \alpha \overbrace{(r + \gamma V(s') - V(s))}^{\Psi_{(1)}(s, a)}$$

Взгляд назад: идея

N -шаговое обновление:

$$V(s) \leftarrow V(s) + \alpha \Psi_{(N)}(s, a)$$

Как сделать из 1-шагового обновления
2-шаговое?




$$V(s) \leftarrow V(s) + \alpha \overbrace{(r + \gamma V(s') - V(s))}^{\Psi_{(1)}(s, a)}$$

Взгляд назад: идея

N -шаговое обновление:

$$V(s) \leftarrow V(s) + \alpha \Psi_{(N)}(s, a)$$

Как сделать из 1-шагового обновления
2-шаговое?




$$V(s) \leftarrow V(s) + \alpha \overbrace{(r + \gamma V(s') - V(s))}^{\Psi_{(1)}(s,a)} + \alpha \overbrace{(\gamma r' + \gamma^2 V(s'') - \gamma V(s'))}^{\gamma \Psi_{(1)}(s',a')}$$

Взгляд назад: идея

N -шаговое обновление:

$$V(s) \leftarrow V(s) + \alpha \Psi_{(N)}(s, a)$$

Как сделать из 1-шагового обновления
2-шаговое?




$$V(s) \leftarrow V(s) + \alpha \overbrace{\left(r + \gamma V(s') - V(s) \right)}^{\Psi_{(1)}(s,a)} + \alpha \overbrace{\left(\gamma r' + \gamma^2 V(s'') - \gamma V(s') \right)}^{\gamma \Psi_{(1)}(s',a')} =$$

Взгляд назад: идея

N -шаговое обновление:

$$V(s) \leftarrow V(s) + \alpha \Psi_{(N)}(s, a)$$

Как сделать из 1-шагового обновления
2-шаговое?



$$\begin{aligned} V(s) &\leftarrow V(s) + \alpha \overbrace{\left(r + \gamma V(s') - V(s) \right)}^{\Psi_{(1)}(s,a)} + \alpha \overbrace{\left(\gamma r' + \gamma^2 V(s'') - \gamma V(s') \right)}^{\gamma \Psi_{(1)}(s',a')} = \\ &= V(s) + \alpha \Psi_{(2)}(s, a) \end{aligned}$$

Взгляд назад: идея


N -шаговое обновление:

$$V(s) \leftarrow V(s) + \alpha \Psi_{(N)}(s, a)$$

Как сделать из 1-шагового обновления
2-шаговое?

N -шаговая невязка – сумма 1-шаговых

$$\Psi_{(N)}(s, a) = \sum_{t=0}^N \gamma^t \Psi_{(1)}(s^{(t)}, a^{(t)})$$



$$\begin{aligned} V(s) &\leftarrow V(s) + \alpha \overbrace{(r + \gamma V(s') - V(s))}^{\Psi_{(1)}(s,a)} + \alpha \overbrace{(\gamma r' + \gamma^2 V(s'') - \gamma V(s'))}^{\gamma \Psi_{(1)}(s',a')} = \\ &= V(s) + \alpha \Psi_{(2)}(s, a) \end{aligned}$$

Eligibility Traces (посещаемость)




Использовать 1-шаговую TD-ошибку при обновлении $V(s)$ для **всех** состояний

Eligibility Traces (посещаемость)



Использовать 1-шаговую TD-ошибку при обновлении $V(s)$ для **всех** состояний




Eligibility Traces (посещаемость)



Использовать 1-шаговую TD-ошибку при обновлении $V(s)$ для **всех** состояний

Определить **eligibility trace** (посещаемость) $e(s)$ как скаляр в обновлении:

$$\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$$



Eligibility Traces (посещаемость)




Использовать 1-шаговую TD-ошибку при обновлении $V(s)$ для **всех** состояний

Определить **eligibility trace** (посещаемость) $e(s)$ как скаляр в обновлении:

$$\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$$

Онлайн «Монте-Карло» обновления:

- $\forall s: e(s) := 0$ в начале каждого эпизода



Eligibility Traces (посещаемость)




Использовать 1-шаговую TD-ошибку при обновлении $V(s)$ для **всех** состояний

Определить **eligibility trace** (посещаемость) $e(s)$ как скаляр в обновлении:

$$\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$$

Онлайн «Монте-Карло» обновления:

- $\forall s: e(s) := 0$ в начале каждого эпизода
- $e(s) \leftarrow e(s) + 1$ после посещения s



Eligibility Traces (посещаемость)




Использовать 1-шаговую TD-ошибку при обновлении $V(s)$ для **всех** состояний

Определить **eligibility trace** (посещаемость) $e(s)$ как скаляр в обновлении:

$$\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$$

Онлайн «Монте-Карло» обновления:

- $\forall s: e(s) := 0$ в начале каждого эпизода
- $e(s) \leftarrow e(s) + 1$ после посещения s
- $\forall s: e(s) \leftarrow \gamma e(s)$ после каждого шага



TD(1) и TD(0)

TD(1)

Ввод: политика π

Инициализировать $V(s)$

произвольно

Инициализировать $e(s) = 0$

наблюдаем s_0

для $k = 0, 1, 2 \dots$

- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}

TD(1) и TD(0)

TD(1)

Ввод: политика π

Инициализировать $V(s)$

произвольно

Инициализировать $e(s) = 0$

наблюдаем s_0

для $k = 0, 1, 2 \dots$

- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}
- $\Psi_{(1)} := r_k + \gamma V(s_{k+1}) - V(s_k)$

TD(1) и TD(0)

TD(1)

Ввод: политика π

Инициализировать $V(s)$

произвольно

Инициализировать $e(s) = 0$

наблюдаем s_0

для $k = 0, 1, 2 \dots$

- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}
- $\Psi_{(1)} := r_k + \gamma V(s_{k+1}) - V(s_k)$
- $e(s_k) \leftarrow e(s_k) + 1$

TD(1) и TD(0)

TD(1)

Ввод: политика π

Инициализировать $V(s)$

произвольно

Инициализировать $e(s) = 0$

наблюдаем s_0

для $k = 0, 1, 2 \dots$

- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}
- $\Psi_{(1)} := r_k + \gamma V(s_{k+1}) - V(s_k)$
- $e(s_k) \leftarrow e(s_k) + 1$
- $\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$

TD(1) и TD(0)

TD(1)

Ввод: политика π

Инициализировать $V(s)$

произвольно

Инициализировать $e(s) = 0$

наблюдаем s_0

для $k = 0, 1, 2 \dots$

- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}
- $\Psi_{(1)} := r_k + \gamma V(s_{k+1}) - V(s_k)$
- $e(s_k) \leftarrow e(s_k) + 1$
- $\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$
- $\forall s: e(s) \leftarrow \gamma e(s)$

TD(1) и TD(0)

TD(1)

Ввод: политика π

Инициализировать $V(s)$

произвольно

Инициализировать $e(s) = 0$

наблюдаем s_0

для $k = 0, 1, 2 \dots$

- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}
- $\Psi_{(1)} := r_k + \gamma V(s_{k+1}) - V(s_k)$
- $e(s_k) \leftarrow e(s_k) + 1$
- $\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$
- $\forall s: e(s) \leftarrow \gamma e(s)$

TD(0)

Ввод: политика π

Инициализировать $V(s)$

произвольно


Инициализировать $e(s) = 0$

наблюдаем s_0



для $k = 0, 1, 2 \dots$

- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}
- $\Psi_{(1)} := r_k + \gamma V(s_{k+1}) - V(s_k)$
- $e(s_k) \leftarrow e(s_k) + 1$
- $\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$
- $\forall s: e(s) \leftarrow 0 \cdot \gamma e(s)$




TD(λ)




TD(λ)




$TD(\lambda)$




TD(λ)



$TD(1)$



$TD(\lambda)$



$TD(0)$

$TD(\lambda)$

Ввод: политика π

Инициализировать $V(s)$ произвольно

Инициализировать $e(s) = 0$

наблюдаем s_0

для $k = 0, 1, 2 \dots$


- выбираем действие $a_k \sim \pi$,
наблюдаем r_k, s_{k+1}
- $\Psi_{(1)} := r_k + \gamma V(s_{k+1}) - V(s_k)$
- $e(s_k) \leftarrow e(s_k) + 1$
- $\forall s: V(s) \leftarrow V(s) + \alpha e(s) \Psi_{(1)}$
- $\forall s: e(s) \leftarrow \lambda \gamma e(s)$

Взгляд вперёд или взгляд назад

Взгляд вперёд

Дать оценку настоящему по известному будущему

«Хорошо ли решение или плохо на основе результата?»




Взгляд вперёд или взгляд назад

Взгляд вперёд

Дать оценку настоящему по известному будущему


«Хорошо ли решение или плохо на основе результата?»



Взгляд назад

Обновить прошлые оценки с помощью настоящей информации

«Какие решения в прошлом оказали значительное влияние на настоящие?»



Взгляд вперёд для TD(λ)

Шаг	Обновление	$\Psi_{(1)}(s, a)$	$\Psi_{(2)}(s, a)$	$\Psi_{(3)}(s, a)$	...	$\Psi_{(N)}(s, a)$
0	$\Psi_{(1)}(s, a)$	1	0	0		0

Взгляд вперёд для TD(λ)

Шаг	Обновление	$\Psi_{(1)}(s, a)$	$\Psi_{(2)}(s, a)$	$\Psi_{(3)}(s, a)$	...	$\Psi_{(N)}(s, a)$
0	$\Psi_{(1)}(s, a)$	1	0	0		0
1	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a')$	$1 - \lambda$	λ	0		0

Взгляд вперёд для TD(λ)

Шаг	Обновление	$\Psi_{(1)}(s, a)$	$\Psi_{(2)}(s, a)$	$\Psi_{(3)}(s, a)$	...	$\Psi_{(N)}(s, a)$
0	$\Psi_{(1)}(s, a)$	1	0	0		0
1	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a')$	$1 - \lambda$	λ	0		0
2	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a') + (\gamma\lambda)^2\Psi_{(1)}(s'', a'')$	$1 - \lambda$	$(1 - \lambda)\lambda$	λ^2		0

Взгляд вперёд для TD(λ)

Шаг	Обновление	$\Psi_{(1)}(s, a)$	$\Psi_{(2)}(s, a)$	$\Psi_{(3)}(s, a)$	...	$\Psi_{(N)}(s, a)$
0	$\Psi_{(1)}(s, a)$	1	0	0		0
1	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a')$	$1 - \lambda$	λ	0		0
2	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a') + (\gamma\lambda)^2\Psi_{(1)}(s'', a'')$	$1 - \lambda$	$(1 - \lambda)\lambda$	λ^2		0
$\vdots$						
N	$\sum_{t \geq 0}^N (\gamma\lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)})$	$1 - \lambda$	$(1 - \lambda)\lambda$	$(1 - \lambda)\lambda^2$		λ^N

Взгляд вперёд для TD(λ)

Шаг	Обновление	$\Psi_{(1)}(s, a)$	$\Psi_{(2)}(s, a)$	$\Psi_{(3)}(s, a)$	...	$\Psi_{(N)}(s, a)$
0	$\Psi_{(1)}(s, a)$	1	0	0		0
1	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a')$	$1 - \lambda$	λ	0		0
2	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a') + (\gamma\lambda)^2\Psi_{(1)}(s'', a'')$	$1 - \lambda$	$(1 - \lambda)\lambda$	λ^2		0
$\vdots$						
N	$\sum_{t=0}^N (\gamma\lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)})$	$1 - \lambda$	$(1 - \lambda)\lambda$	$(1 - \lambda)\lambda^2$		λ^N

Эквивалентные формы обновлений TD(λ)

$$\sum_{t=0}^{\infty} (\gamma\lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)}) =$$


Взгляд вперёд для TD(λ)

Шаг	Обновление	$\Psi_{(1)}(s, a)$	$\Psi_{(2)}(s, a)$	$\Psi_{(3)}(s, a)$	...	$\Psi_{(N)}(s, a)$
0	$\Psi_{(1)}(s, a)$	1	0	0		0
1	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a')$	$1 - \lambda$	λ	0		0
2	$\Psi_{(1)}(s, a) + \gamma\lambda\Psi_{(1)}(s', a') + (\gamma\lambda)^2\Psi_{(1)}(s'', a'')$	$1 - \lambda$	$(1 - \lambda)\lambda$	λ^2		0
$\vdots$						
N	$\sum_{t=0}^N (\gamma\lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)})$	$1 - \lambda$	$(1 - \lambda)\lambda$	$(1 - \lambda)\lambda^2$		λ^N

Эквивалентные формы обновлений TD(λ)


$$\sum_{t=0}^{\infty} (\gamma\lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)}) = (1 - \lambda) \sum_{N=1}^{\infty} \lambda^{N-1} \Psi_{(N)}(s, a)$$

Generalized Advantage Estimation (GAE)



Что, если для некоторой пары (s, a) нам известно будущее только на T шагов вперёд?


Generalized Advantage Estimation (GAE)



Что, если для некоторой пары (s, a) нам известно будущее только на T шагов вперёд?

$$\Psi^{\text{GAE}}(s, a) := \sum_{t=0}^T (\gamma \lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)})$$

Generalized Advantage Estimation (GAE)




Что, если для некоторой пары (s, a) нам известно будущее только на T шагов вперёд?

$$\Psi^{\text{GAE}}(s, a) := \sum_{t=0}^T (\gamma\lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)})$$

Используемое на практике уравнение:

$$\Psi^{\text{GAE}}(s_t, a_t) = \Psi_{(1)}(s_t, a_t) + \lambda\gamma(1 - \text{done}_{t+1})\Psi^{\text{GAE}}(s_{t+1}, a_{t+1})$$

Generalized Advantage Estimation (GAE)



Что, если для некоторой пары (s, a) нам известно будущее только на T шагов вперёд?

$$\Psi^{\text{GAE}}(s, a) := \sum_{t=0}^T (\gamma \lambda)^t \Psi_{(1)}(s^{(t)}, a^{(t)})$$

Используемое на практике уравнение:

$$\Psi^{\text{GAE}}(s_t, a_t) = \Psi_{(1)}(s_t, a_t) + \lambda \gamma (1 - \text{done}_{t+1}) \Psi^{\text{GAE}}(s_{t+1}, a_{t+1})$$

GAE в Advantage Actor-Critic




Длинные развёртки порождают богатые GAE ансамбли.

GAE в Advantage Actor-Critic




Длинные развёртки порождают богатые GAE ансамбли.



GAE в Advantage Actor-Critic



Длинные развёртки порождают богатые GAE ансамбли.



В A2C развёртки обычно короткие, поэтому часто выбирают $\lambda = 1$.
(иногда это называют **max-trace** оценкой)

RPO: особенности реализации

Ключевые элементы:

- ✓ Клиппинг функции потерь политики
- ✓ Клиппинг функции потерь критика
- ✓ GAE

Другие приёмы:

- ! Нормализация и клиппинг награды¹
- Нормализация и клиппинг наблюдений (состояний)²
- Ортогональная инициализация слоёв
- Отжиг по ϵ (параметр клиппинга)

¹ делением на скользящее стандартное отклонение собранных кумулятивных наград

² может быть критично в непрерывном управлении

RPO: особенности реализации

Детали пайплайна:

- ! Нормализация Advantage в мини-батчах
- Нет KL-регуляризации
- Энтропийная функция потерь

Стандартные приёмы:

- Оптимизатор Adam, отжиг шага
- Функция активации Tanh
- ! Клиппинг градиента

Proximal Policy Optimization (PPO)

Инициализировать $\pi(a \mid s, \theta), V_\phi(s);$

Proximal Policy Optimization (PPO)

Инициализировать $\pi(a \mid s, \theta)$, $V_\phi(s)$;

for $k = 0, 1, 2 \dots$

- собрать $s_0, a_0, r_0, s_1, \text{done}_1, a_1 \dots s_N, \text{done}_N$ по $\pi(a \mid s, \theta)$;
запомнить вероятности действий как $\pi^{\text{old}}(a_t \mid s_t) := \pi(a_t \mid s_t, \theta)$
запомнить значения критика как $V^{\text{old}}(s_t) := V_\phi(s_t)$

Proximal Policy Optimization (PPO)

Инициализировать $\pi(a \mid s, \theta)$, $V_\phi(s)$;

for $k = 0, 1, 2 \dots$

- собрать $s_0, a_0, r_0, s_1, \text{done}_1, a_1 \dots s_N, \text{done}_N$ по $\pi(a \mid s, \theta)$;
запомнить вероятности действий как $\pi^{\text{old}}(a_t \mid s_t) := \pi(a_t \mid s_t, \theta)$
запомнить значения критика как $V^{\text{old}}(s_t) := V_\phi(s_t)$
- вычислить 1-шаговые невязки:
$$\Psi_{(1)}(s_t, a_t) := r_t + \gamma(1 - \text{done}_{t+1})V_\phi(s_{t+1}) - V_\phi(s_t)$$

Proximal Policy Optimization (PPO)

Инициализировать $\pi(a \mid s, \theta), V_\phi(s)$;

for $k = 0, 1, 2 \dots$

- собрать $s_0, a_0, r_0, s_1, \text{done}_1, a_1 \dots s_N, \text{done}_N$ по $\pi(a \mid s, \theta)$;
запомнить вероятности действий как $\pi^{\text{old}}(a_t \mid s_t) := \pi(a_t \mid s_t, \theta)$
запомнить значения критика как $V^{\text{old}}(s_t) := V_\phi(s_t)$
- вычислить 1-шаговые невязки:
$$\Psi_{(1)}(s_t, a_t) := r_t + \gamma(1 - \text{done}_{t+1})V_\phi(s_{t+1}) - V_\phi(s_t)$$
- вычислить GAE advantage-оценки:
$$\Psi^{\text{GAE}}(s_{N-1}, a_{N-1}) := \Psi_{(1)}(s_{N-1}, a_{N-1})$$
- для t от $N - 2$ до 0:
 - $\Psi^{\text{GAE}}(s_t, a_t) :=$

Proximal Policy Optimization (PPO)

Инициализировать $\pi(a \mid s, \theta), V_\phi(s)$;

for $k = 0, 1, 2 \dots$

- собрать $s_0, a_0, r_0, s_1, \text{done}_1, a_1 \dots s_N, \text{done}_N$ по $\pi(a \mid s, \theta)$;
запомнить вероятности действий как $\pi^{\text{old}}(a_t \mid s_t) := \pi(a_t \mid s_t, \theta)$
запомнить значения критика как $V^{\text{old}}(s_t) := V_\phi(s_t)$
- вычислить 1-шаговые невязки:
$$\Psi_{(1)}(s_t, a_t) := r_t + \gamma(1 - \text{done}_{t+1})V_\phi(s_{t+1}) - V_\phi(s_t)$$
- вычислить GAE advantage-оценки:
$$\Psi^{\text{GAE}}(s_{N-1}, a_{N-1}) := \Psi_{(1)}(s_{N-1}, a_{N-1})$$
- для t от $N - 2$ до 0:
 - $$\Psi^{\text{GAE}}(s_t, a_t) := \Psi_{(1)}(s_t, a_t) + \lambda \gamma(1 - \text{done}_{t+1})\Psi^{\text{GAE}}(s_{t+1}, a_{t+1})$$

Proximal Policy Optimization (PPO)

Инициализировать $\pi(a \mid s, \theta)$, $V_\phi(s)$;

for $k = 0, 1, 2 \dots$

- собрать $s_0, a_0, r_0, s_1, \text{done}_1, a_1 \dots s_N, \text{done}_N$ по $\pi(a \mid s, \theta)$;
запомнить вероятности действий как $\pi^{\text{old}}(a_t \mid s_t) := \pi(a_t \mid s_t, \theta)$
запомнить значения критика как $V^{\text{old}}(s_t) := V_\phi(s_t)$
- вычислить 1-шаговые невязки:
$$\Psi_{(1)}(s_t, a_t) := r_t + \gamma(1 - \text{done}_{t+1})V_\phi(s_{t+1}) - V_\phi(s_t)$$
- вычислить GAE advantage-оценки:
$$\Psi^{\text{GAE}}(s_{N-1}, a_{N-1}) := \Psi_{(1)}(s_{N-1}, a_{N-1})$$
- для t от $N - 2$ до 0:
 - $\Psi^{\text{GAE}}(s_t, a_t) := \Psi_{(1)}(s_t, a_t) + \lambda\gamma(1 - \text{done}_{t+1})\Psi^{\text{GAE}}(s_{t+1}, a_{t+1})$
- вычислить целевые значения критика:
$$y(s_t) := \Psi^{\text{GAE}}(s_t, a_t) + V_\phi(s_t)$$

Proximal Policy Optimization (PPO)

Инициализировать $\pi(a \mid s, \theta), V_\phi(s)$;

for $k = 0, 1, 2 \dots$

- собрать $s_0, a_0, r_0, s_1, \text{done}_1, a_1 \dots s_N, \text{done}_N$ по $\pi(a \mid s, \theta)$;
запомнить вероятности действий как $\pi^{\text{old}}(a_t \mid s_t) := \pi(a_t \mid s_t, \theta)$
запомнить значения критика как $V^{\text{old}}(s_t) := V_\phi(s_t)$
- вычислить 1-шаговые невязки:
$$\Psi_{(1)}(s_t, a_t) := r_t + \gamma(1 - \text{done}_{t+1})V_\phi(s_{t+1}) - V_\phi(s_t)$$
- вычислить GAE advantage-оценки:
$$\Psi^{\text{GAE}}(s_{N-1}, a_{N-1}) := \Psi_{(1)}(s_{N-1}, a_{N-1})$$
- для t от $N - 2$ до 0:
 - $\Psi^{\text{GAE}}(s_t, a_t) := \Psi_{(1)}(s_t, a_t) + \lambda\gamma(1 - \text{done}_{t+1})\Psi^{\text{GAE}}(s_{t+1}, a_{t+1})$
- вычислить целевые значения критика:
$$y(s_t) := \Psi^{\text{GAE}}(s_t, a_t) + V_\phi(s_t)$$
- составить выборку $(s_t, a_t, \Psi^{\text{GAE}}(s_t, a_t), y(s_t), \pi^{\text{old}}(a_t \mid s_t), V^{\text{old}}(s_t))$

Proximal Policy Optimization (PPO) — продолжение

- проход по выборке n_epochs раз, сэмплируя мини-батчи размера B ; для каждого мини-батча:

Proximal Policy Optimization (PPO) — продолжение

- проход по выборке n_epochs раз, сэмплируя мини-батчи размера B ; для каждого мини-батча:
 - нормализация $\Psi^{GAE}(s, a)$ в батче вычитанием среднего и делением на стандартное отклонение

Proximal Policy Optimization (PPO) — продолжение

- проход по выборке n_epochs раз, сэмплируя мини-батчи размера B ; для каждого мини-батча:
 - нормализация $\Psi^{GAE}(s, a)$ в батче вычитанием среднего и делением на стандартное отклонение
 - вычислить веса выборки по значимости:
$$\rho(s, a, \theta) := \frac{\pi(a|s, \theta)}{\pi^{old}(a|s)}, \quad \rho^{clip}(s, a, \theta) = \text{clip}(\rho(s, a, \theta), 1 - \epsilon, 1 + \epsilon)$$

Proximal Policy Optimization (PPO) — продолжение

- проход по выборке n_epochs раз, сэмплируя мини-батчи размера B ; для каждого мини-батча:
 - нормализация $\Psi^{GAE}(s, a)$ в батче вычитанием среднего и делением на стандартное отклонение
 - вычислить веса выборки по значимости:
$$\rho(s, a, \theta) := \frac{\pi(a|s, \theta)}{\pi^{old}(a|s)}, \quad \rho^{clip}(s, a, \theta) = \text{clip}(\rho(s, a, \theta), 1 - \epsilon, 1 + \epsilon)$$
 - обновление параметров актора:
$$L_1(s, a, \theta) := \rho(s, a, \theta) \Psi^{GAE}(s, a), \quad L_2(s, a, \theta) := \rho^{clip}(s, a, \theta) \Psi^{GAE}(s, a)$$
$$\theta \leftarrow \theta + \alpha \nabla_{\theta} \frac{1}{B} \sum_{s,a} \min(L_1(s, a, \theta), L_2(s, a, \theta))$$

Proximal Policy Optimization (PPO) — продолжение

- проход по выборке n_epochs раз, сэмплируя мини-батчи размера B ; для каждого мини-батча:
 - нормализация $\Psi^{GAE}(s, a)$ в батче вычитанием среднего и делением на стандартное отклонение
 - вычислить веса выборки по значимости:
$$\rho(s, a, \theta) := \frac{\pi(a|s, \theta)}{\pi^{old}(a|s)}, \quad \rho^{clip}(s, a, \theta) = \text{clip}(\rho(s, a, \theta), 1 - \epsilon, 1 + \epsilon)$$
 - обновление параметров актора:
$$L_1(s, a, \theta) := \rho(s, a, \theta) \Psi^{GAE}(s, a), \quad L_2(s, a, \theta) := \rho^{clip}(s, a, \theta) \Psi^{GAE}(s, a)$$
$$\theta \leftarrow \theta + \alpha \nabla_{\theta} \frac{1}{B} \sum_{s,a} \min(L_1(s, a, \theta), L_2(s, a, \theta))$$
 - обновление параметров критика:
$$\text{Loss}_1(s, \phi) := (y(s) - V_{\phi}(s))^2$$
$$\text{Loss}_2(s, \phi) := \left(y(s) - V^{old}(s) - \text{clip}(V_{\phi}(s) - V^{old}(s), \hat{\epsilon}, -\hat{\epsilon}) \right)^2$$
$$\phi \leftarrow \phi - \alpha \nabla_{\phi} \frac{1}{B} \sum_s \max(\text{Loss}_1(s, \phi), \text{Loss}_2(s, \phi))$$



Источники

- Proximal Policy Optimization Algorithms;
- Implementation Matters in Deep Policy Gradients: A Case Study on PPO and TRPO;
- High-Dimensional Continuous Control Using Generalized Advantage Estimation;
- Sutton, Barto — Reinforcement Learning, an Introduction, ch. 12;

Value-based (DQN+)

✓ off-policy;

(можно использовать
реплей-буфер)

✗ обучаем $Q^*(s, a)$;
(сложный промежуточный шаг)

✗ проблемы с исследованием
среды;
(так как Value Iteration работает с
детерминистическими политиками)

✗ 1-шаговые целевые значения;
(можем ли модифицировать?)

Policy Gradient

✗ on-policy;

(данные батча бесполезны после
обновления параметров)

✓ обучаем политику напрямую;
(требует только $V^\pi(s)$, что гораздо
проще)

✓ «естественное» исследование;
(сэмплирование из $\pi(a | s)$)

✓ ∞ -шаговые целевые значения;
(можно использовать GAE и для
критика, и для актора)

Off-policy оценка advantage

Данной траектории $s_0, r_0, s_1, r_1, s_2, r_2 \dots s_M$ по политике μ и приближению $V^\pi(s)$

Off-policy оценка advantage

Данной траектории $s_0, r_0, s_1, r_1, s_2, r_2 \dots s_M$ по политике μ и приближению $V^\pi(s)$ требуется произвести **оценку advantage (credit assignment)** для пары состояние-действие (s_0, a_0) в **off-policy** режиме: $\mu \neq \pi$.

Off-policy оценка advantage

Данной траектории $s_0, r_0, s_1, r_1, s_2, r_2 \dots s_M$ по политике μ и приближению $V^\pi(s)$ требуется произвести **оценку advantage (credit assignment)** для пары состояние-действие (s_0, a_0) в **off-policy** режиме: $\mu \neq \pi$.

Было бы замечательно воспользоваться GAE:

$$\sum_{t \geq 0} (\gamma \lambda)^t \Psi_{(1)}(s_t, a_t),$$

но $\Psi_{(1)}(s_t, a_t)$ зависит от случайных величин: $a_0, s_0, a_1, s_2, \dots s_{t+1}$.

Off-policy оценка advantage

Данной траектории $s_0, r_0, s_1, r_1, s_2, r_2 \dots s_M$ по политике μ и приближению $V^\pi(s)$ требуется произвести **оценку advantage (credit assignment)** для пары состояние-действие (s_0, a_0) в **off-policy** режиме: $\mu \neq \pi$.

Было бы замечательно воспользоваться GAE:

$$\sum_{t \geq 0} (\gamma \lambda)^t \Psi_{(1)}(s_t, a_t),$$

но $\Psi_{(1)}(s_t, a_t)$ зависит от случайных величин: $a_0, s_0, a_1, s_2, \dots s_{t+1}$.

Внимание!

Если $\pi(a_0 | s_0) = 0$, то ничего не получится.



Воспользуемся коррекцией с
помощью выборки по значимости!



Воспользуемся коррекцией с помощью выборки по значимости!

$$\Psi = \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}}) p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}{\mu(a_{\hat{t}} | s_{\hat{t}}) p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})} \right) \Psi_{(1)}(s_t, a_t) =$$
$$=$$



Воспользуемся коррекцией с помощью выборки по значимости!

$$\begin{aligned}\Psi &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}}) \cancel{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}}{\mu(a_{\hat{t}} | s_{\hat{t}}) \cancel{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}} \right) \Psi_{(1)}(s_t, a_t) = \\ &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}})}{\mu(a_{\hat{t}} | s_{\hat{t}})} \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{\hat{t}=1}^0 \equiv 1.\end{aligned}$$



Воспользуемся коррекцией с помощью выборки по значимости!

$$\begin{aligned}\Psi &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}}) \cancel{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}}{\mu(a_{\hat{t}} | s_{\hat{t}}) \cancel{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}} \right) \Psi_{(1)}(s_t, a_t) = \\ &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}})}{\mu(a_{\hat{t}} | s_{\hat{t}})} \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{\hat{t}=1}^0 \equiv 1.\end{aligned}$$

Непрактично: очень высокая дисперсия!



Воспользуемся коррекцией с помощью выборки по значимости!

$$\begin{aligned}\Psi &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}}) \cancel{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}}{\mu(a_{\hat{t}} | s_{\hat{t}}) \cancel{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}} \right) \Psi_{(1)}(s_t, a_t) = \\ &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}})}{\mu(a_{\hat{t}} | s_{\hat{t}})} \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{\hat{t}=1}^0 \equiv 1.\end{aligned}$$

Непрактично: очень высокая дисперсия!

- «Затухающий» след: $\mu(a|s) \gg \pi(a|s)$:
 - типичная ситуация μ делает примитивные случайные действия, которые π редко совершает. Не лечится.



Воспользуемся коррекцией с помощью выборки по значимости!

$$\begin{aligned}\Psi &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}}) \overline{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}}{\mu(a_{\hat{t}} | s_{\hat{t}}) \overline{p(s_{\hat{t}+1} | s_{\hat{t}}, a_{\hat{t}})}} \right) \Psi_{(1)}(s_t, a_t) = \\ &= \sum_{t \geq 0} (\gamma \lambda)^t \left(\prod_{\hat{t}=1}^{\hat{t}=t} \frac{\pi(a_{\hat{t}} | s_{\hat{t}})}{\mu(a_{\hat{t}} | s_{\hat{t}})} \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{\hat{t}=1}^0 \equiv 1.\end{aligned}$$

Непрактично: очень высокая дисперсия!

- **«Затухающий»** след: $\mu(a|s) \gg \pi(a|s)$:
 - типичная ситуация μ делает примитивные случайные действия, которые π редко совершает. Не лечится.
- **«Взрывающийся»** след: $\mu(a|s) \ll \pi(a|s)$:
 - μ выбранное действие с малой $\mu(a|s)$, но *вероятное* для π .
Причина большой дисперсии.

Присвоение ценности: общий вид

Давайте перепишем ценность следующим образом:

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1,$$

где c_i коэффициенты «отжига следа»:

Название оценки	Коэффициенты c_i	Возникающая проблема
GAE	λ	только on-policy

Присвоение ценности: общий вид

Давайте перепишем ценность следующим образом:

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1,$$

где c_i коэффициенты «отжига следа»:

Название оценки	Коэффициенты c_i	Возникающая проблема
GAE	λ	только on-policy
Одношаговая	0	большое смещение

Присвоение ценности: общий вид

Давайте перепишем ценность следующим образом:

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1,$$

где c_i коэффициенты «отжига следа»:

Название оценки	Коэффициенты c_i	Возникающая проблема
GAE	λ	только on-policy
Одношаговая	0	большое смещение
Выборка по значимости	$\lambda \frac{\pi(a_i s_i)}{\mu(a_i s_i)}$	легко «взрывается»

Retrace: основная теорема

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1.$$

Теорема о Retrace

В режиме on-policy возможен выбор **произвольного** коэффициента $c_i \in [0, 1]$, в off-policy режиме можно выбрать **произвольный** коэффициент в следующем интервале

$$c_i \in \left[0, \frac{\pi(a_i | s_i)}{\mu(a_i | s_i)} \right].$$

Retrace: основная теорема

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1.$$

Теорема о Retrace

В режиме on-policy возможен выбор **произвольного** коэффициента $c_i \in [0, 1]$, в off-policy режиме можно выбрать **произвольный** коэффициент в следующем интервале

$$c_i \in \left[0, \frac{\pi(a_i | s_i)}{\mu(a_i | s_i)} \right].$$

- **«затухающий» след**: ничего не поделаешь;

Retrace: основная теорема

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1.$$


Теорема о Retrace

В режиме on-policy возможен выбор **произвольного** коэффициента $c_i \in [0, 1]$, в off-policy режиме можно выбрать **произвольный** коэффициент в следующем интервале

$$c_i \in \left[0, \frac{\pi(a_i | s_i)}{\mu(a_i | s_i)} \right].$$

- «затухающий» след: ничего не поделаешь;
- «взрывающийся» след: если вес из выборки по значимости больше 1, ПРОСТО КЛИППИРУЙ ЕГО!

Retrace: основная теорема



$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1.$$

Теорема о Retrace

В режиме on-policy возможен выбор **произвольного** коэффициента $c_i \in [0, 1]$, в off-policy режиме можно выбрать **произвольный** коэффициент в следующем интервале

$$c_i \in \left[0, \frac{\pi(a_i | s_i)}{\mu(a_i | s_i)} \right].$$

- «затухающий» след: ничего не поделаешь;
- «взрывающийся» след: если вес из выборки по значимости больше 1, ПРОСТО КЛИППИРУЙ ЕГО!

Retrace: финальный результат

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1,$$

где

$$c_i := \lambda \min \left(1, \frac{\pi(a_i | s_i)}{\mu(a_i | s_i)} \right).$$

Retrace: финальный результат

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1,$$

где

$$c_i := \lambda \min \left(1, \frac{\pi(a_i | s_i)}{\mu(a_i | s_i)} \right).$$

Используется в:

- off-policy RL алгоритмах для теоретически корректных многошаговых целевых значений;
- ($\lambda = 1$, потому что оно быстро затухает).

Retrace: финальный результат

$$\Psi = \sum_{t \geq 0} \gamma^t \left(\prod_{i=1}^{i=t} c_i \right) \Psi_{(1)}(s_t, a_t), \quad \prod_{i=1}^0 \equiv 1,$$

где

$$c_i := \lambda \min \left(1, \frac{\pi(a_i | s_i)}{\mu(a_i | s_i)} \right).$$

Используется в:

- off-policy RL алгоритмах для теоретически корректных многошаговых целевых значений;
 - ($\lambda = 1$, потому что оно быстро затухает).
- дистрибутивных on-policy RL системах, где данные о градиенте от некоторых серверов могут задерживаться на несколько итераций обновления.