

Лекция 12

Обучение с подкреплением

Никита Юдин, iudin.ne@phystech.edu

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

23 апреля 2026



Soft Actor-Critic

Определение

Энтропией распределения $\pi(a)$ называется

$$\mathcal{H}(\pi(a)) := -\mathbb{E}_{\pi(a)} [\ln \pi(a)] . \quad (1)$$

Определение

Задачей **Maximum Entropy RL** является максимизация функционала

$$J_{\text{soft}}(\pi) := \mathbb{E}_{\mathcal{T} \sim \pi} \sum_{t \geq 0} \gamma^t [r_t + \alpha \mathcal{H}(\pi(\cdot \mid s))] \rightarrow \max_{\pi}, \quad (2)$$

где α — гиперпараметр, называемый **температурой** (temperature).

Soft Actor-Critic

Утверждение


Задача (2) эквивалентна

$$J_{\text{soft}}(\pi) := \mathbb{E}_{\mathcal{T} \sim \pi} \sum_{t \geq 0} \gamma^t [r_t - \alpha \ln \pi(a_t | s_t)] \rightarrow \max_{\pi},$$

Доказательство. Следует из определения энтропии (1); ведь математическое ожидание по действиям присутствует в математическом ожидании по траекториям.



Пример 1: Представим, что у агента есть два пути, и по мере углубления награда на каждом пути одинаково растёт. Пусть первый путь заканчивается тупиком и суммарно позволяет набрать не более +100, а на втором тупик стоит чуть дальше и даёт +110. Во время обучения агент может уловить награду вдоль первого пути и учиться углубляться в него, игнорируя исследование второго пути, даже если агент умеет набирать там награду как на первом; за счёт бонуса за наиболее стохастичную стратегию агент мотивирован в течение обучения в начале эпизодов случайно выбирать между двумя путями. То есть, энтропийный бонус помогает избегать подобных «локальных максимумов» в среде.



Можно считать, что в данном фреймворке мы на самом деле лишь чуть-чуть модифицировали награду в среде:

$$r_{\text{soft}}(s, a) := r(s, a) - \alpha \ln \pi(a \mid s). \quad (3)$$

Утверждение

Оптимальной детерминированной стратегии может не существовать.

Доказательство. В MDP, где награда всегда 0, оптимальна стратегия с максимальной энтропией. ■

Теорема (Мягкие уравнения связи)

$$Q_{\text{soft}}^{\pi}(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} [V_{\text{soft}}^{\pi}(s')] \quad (4)$$

$$V_{\text{soft}}^{\pi}(s) = \mathbb{E}_{\pi(a|s)} [Q_{\text{soft}}^{\pi}(s, a) - \ln \pi(a | s)] \quad (5)$$

Доказательство. По определению с учётом договорённости. ■

Теорема (Мягкие уравнения Беллмана (soft Bellman equations))

$$Q_{\text{soft}}^{\pi}(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} \mathbb{E}_{a'} [Q_{\text{soft}}^{\pi}(s', a') - \ln \pi(a' | s')] \quad (6)$$

$$V_{\text{soft}}^{\pi}(s) = \mathbb{E}_a [r(s, a) - \ln \pi(a | s) + \gamma \mathbb{E}_{s'} V_{\text{soft}}^{\pi}(s')] \quad (7)$$

Теорема

Операторы, стоящие в правой части мягких уравнений Беллмана, являются сжимающими с коэффициентом γ по метрике

$$\rho(V_1, V_2) := \max_{s \in \mathcal{S}} \{|V_1(s) - V_2(s)|\}.$$

Доказательство. Покажем для мягкой V -функции. Пусть $\mathfrak{B}_{\text{soft}}$ — оператор, стоящий в правой части (7), и пусть даны две V -функции V_1, V_2 . Тогда:

$$|[\mathfrak{B}_{\text{soft}} V_1](s) - [\mathfrak{B}_{\text{soft}} V_2](s)| = \gamma |\mathbb{E}_a \mathbb{E}_{s'} [V_1(s') - V_2(s')]|,$$

поскольку энтропия стратегии π вместе с наградой за шаг одинакова для V_1 и V_2 и потому сокращается. Дальше, как и для обычных V -функций, можно просто оценить это выражение сверху $\gamma \rho(V_1, V_2)$, заканчивая доказательство. ■

Утверждение

Метод простой итерации сходится к единственному решению мягких уравнений Беллмана из любого начального приближения.

Итак, мы уже можем сразу построить процедуру обучения критика. Рассмотрим обучение $Q_\omega(s, a) \approx Q_{\text{soft}}^\pi(s, a)$ с одношаговых оценок в off-policy режиме, то есть будем просто решать мягкое уравнение Беллмана (6). Тогда для заданного перехода $\mathbb{T} = (s, a, r, s')$ целевая переменная строится как

$$y(\mathbb{T}) := r + \gamma \mathbb{E}_{a' \sim \pi(a' | s')} [Q_\omega(s', a') - \ln \pi(a' | s')].$$

В таком варианте таргеты для критика (Q-функция с параметрами ω) и для вспомогательной V-функции выглядят следующим образом: для заданного перехода $\mathbb{T} = (s, a, r, s')$, взятого из буфера, генерируем a_π из текущей версии стратегии π и запоминаем вероятность $\pi(a_\pi | s)$, после чего вычисляем несмещённые оценки правых частей уравнений связи (5) и (4):

$$y_Q(\mathbb{T}) := r + \gamma V_\psi(s'),$$

$$y_V(\mathbb{T}) := Q_\omega(s, a_\pi) - \ln \pi(a_\pi | s).$$

Теорема 1 — Soft Policy Improvement: Пусть стратегии π_1 и π_2 таковы, что для всех состояний $s \in \mathcal{S}$ выполняется:

$$\mathbb{E}_{\pi_2(a|s)} [Q_{\text{soft}}^{\pi_1}(s, a)] + \mathcal{H}(\pi_2(\cdot | s)) \geq V_{\text{soft}}^{\pi_1}(s),$$

тогда $\pi_2 \succeq \pi_1$ с учётом энтропийного бонуса; если хотя бы для одного $s \in \mathcal{S}$ неравенство выполнено строго, то $\pi_2 \succ \pi_1$.

Доказательство. Полностью аналогично доказательству в обычном случае. Покажем, что $V_{\text{soft}}^{\pi_2}(s) \geq V_{\text{soft}}^{\pi_1}(s)$ для любого $s \in \mathcal{S}$:

$$\begin{aligned}
 V_{\text{soft}}^{\pi_1}(s) &\leq \{\text{по построению } \pi_2\} \leq \mathbb{E}_{\pi_2(a|s)} [Q_{\text{soft}}^{\pi_1}(s, a)] + \mathcal{H}(\pi_2(\cdot | s)) = \\
 &= \{\text{связь QV (4)}\} = \mathbb{E}_{\pi_2(a|s)} [r + \mathcal{H}(\pi_2(\cdot | s)) + \gamma \mathbb{E}_{s'} [V_{\text{soft}}^{\pi_1}(s')]] \leq \\
 &\leq \{\text{применяем это же неравенство рекурсивно}\} = \mathbb{E}_{\pi_2(a|s)} [r + \mathcal{H}(\pi_2(\cdot | s)) + \\
 &\quad + \mathbb{E}_{s'} \mathbb{E}_{\pi_2(a'|s')} [\gamma r' + \gamma \mathcal{H}(\pi_2(\cdot | s')) + \gamma^2 \mathbb{E}_{s''} [V_{\text{soft}}^{\pi_1}(s'')]]] \\
 &\leq \{\text{раскручиваем цепочку далее}\} \leq \dots \leq \mathbb{E}_{\mathcal{T} \sim \pi_2|s_0=s} \sum_{t \geq 0} [\gamma^t r_t + \gamma^t \mathcal{H}(\pi_2(\cdot | s_t))] = \\
 &= \{\text{по определению мягкой V-функции}\} = V_{\text{soft}}^{\pi_2}(s)
 \end{aligned}$$

Если для какого-то $s \in \mathcal{S}$ неравенство из условия теоремы было выполнено строго, то для него первое неравенство в этой цепочке рассуждений выполняется строго, и, значит, $V_{\text{soft}}^{\pi_2}(s) > V_{\text{soft}}^{\pi_1}(s)$. ■

Таким образом, аналог общей схемы Generalized Policy Iteration в задаче Maximum Entropy RL выглядит так:

- **Soft Policy Evaluation** заключается в обучении аппроксимации мягкой оценочной функции $Q_\omega \approx Q_{\text{soft}}^\pi$ для текущей стратегии π ;
- **Soft Policy Improvement** заключается в оптимизации следующего функционала (для разных состояний s):

$$\mathbb{E}_{\pi(a|s)} [Q_\omega(s, a)] + \mathcal{H}(\pi(\cdot | s)) \rightarrow \max_{\pi}. \quad (8)$$

Теорема 2: Задача (8) эквивалентна задаче

$$\text{KL}(\pi_\theta(\cdot | s) \parallel \exp Q_\omega(s, \cdot)) \rightarrow \min_\theta,$$

где $\exp Q_\omega(s, \cdot)$ — ненормированное распределение над действиями.

Доказательство. Обозначим нормировочную константу распределения $\exp Q_\omega(s, \cdot)$ как $Z_\omega(s) := \int_{\mathcal{A}} \exp Q_\omega(s, a) da$. Тогда:

$$\text{KL}(\pi_\theta(\cdot | s) \parallel \exp Q_\omega(s, \cdot)) = \mathbb{E}_{a \sim \pi_\theta(a|s)} [\ln \pi_\theta(a | s) - Q_\omega(s, a) + \ln Z_\omega(s)].$$

Осталось заметить, что при домножении на минус получим (8): первое слагаемое есть энтропия, а третье слагаемое не зависит от оптимизируемых параметров θ :

$$\mathbb{E}_{a \sim \pi_\theta(a|s)} [\ln Z_\omega(s)] = \ln Z_\omega(s) = \text{const}(\theta).$$



Теорема (Вид жадной стратегии)

Максимальное значение (8) достигается на стратегии

$$\pi(a \mid s) \propto \exp Q_{\omega}(s, a). \quad (9)$$

Доказательство. Следует из теоремы 2, поскольку минимум KL-дивергенции достигается в нуле на совпадающих распределениях.



Пример 2: Пусть наша стратегия параметризована гауссианой. Для неё можно проводить репараметризационный трюк и также можно аналитически посчитать энтропию:

$$\mathcal{H}(\mathcal{N}(\mu, \sigma^2 I)) = \sum_{i=1}^A \ln \sigma_i.$$

Итого, формула (8) в таком случае получается следующей:

$$\mathbb{E}_{\varepsilon \sim \mathcal{N}(0, I)} [Q_{\omega}(s, \mu_{\theta}(s) + \sigma_{\theta}(s) \odot \varepsilon)] + \sum_{i=1}^A \ln \sigma_i(s, \theta) \rightarrow \max_{\theta}.$$

Пример 3: Пусть наша стратегия параметризована смесью гауссиан. Тогда для неё не применим репараметризационный трюк, и сложно аналитически посчитать энтропию. Тогда придётся применять REINFORCE, и формула градиента (8) получается следующей:

$$\nabla_{\theta} = \mathbb{E}_{a \sim \pi_{\theta}(a|s)} \nabla_{\theta} \ln \pi_{\theta}(a | s) [Q_{\omega}(s, a) - \ln \pi_{\theta}(a | s) - b(s)],$$

где $b(s)$ — бэйзлайн, произвольная функция от состояний. Имеет смысл делать её близкой к среднему значению $Q_{\omega}(s, a) - \ln \pi_{\theta}(a | s)$, то есть хорошо выбирать $b(s) := V_{\omega}(s) = \mathbb{E}_a [Q_{\omega}(s, a) - \ln \pi_{\theta}(a | s)]$.

Алгоритм 1: Soft Actor-Critic (SAC)

Гиперпараметры: B — размер мини-батчей, β — параметр экспоненциального сглаживания таргет-сети, α — температура, $\pi_\theta(a \mid s) := \mathcal{N}(\mu_\theta(s), \sigma_\theta(s)^2 I)$ — гауссова стратегия с параметрами θ , $Q_{\omega_1}(s, a), Q_{\omega_2}(s, a)$ — две нейросети с параметрами ω_1 и ω_2 , $V_\psi(s)$ — нейросетка с параметрами ψ , SGD-оптимизаторы.

Инициализировать $\theta, \omega_1, \omega_2, \psi$ произвольно

Инициализировать таргет-сеть $\psi^- := \psi$

Пронаблюдать s_0

На очередном шаге t :

- 1 выбрать $a_t \sim \pi_\theta(a_t \mid s_t)$
- 2 пронаблюдать $r_t, s_{t+1}, \text{done}_{t+1}$
- 3 добавить пятёрку $(s_t, a_t, r_t, s_{t+1}, \text{done}_{t+1})$ в реплей буфер
- 4 засэмплировать мини-батч размера B из буфера
- 5 для каждого s из батча засэмплировать шума $\varepsilon(s) \sim \mathcal{N}(0, I)$ и посчитать $\mu(s, \theta), \sigma(s, \theta)$ стратегии π_θ

6 посчитать оценку градиента по параметрам стратегии:

$$\nabla_{\theta} := \frac{1}{B} \sum_{s \in B} \nabla_{\theta} \left[\alpha \sum_{i=1}^A \ln \sigma_i(s, \theta) + \min_{i=1,2} \{ Q_{\omega_i}(s, \mu_{\theta}(s) + \sigma_{\theta}(s) \odot \varepsilon(s)) \} \right]$$

7 делаем шаг градиентного подъёма по θ , используя ∇_{θ}

8 для каждого перехода $\mathbb{T} := (s, a, r, s', \text{done})$ засэмплировать $a_{\pi} \sim \pi_{\theta}(a_{\pi} \mid s)$ и сохранить вероятности $\pi_{\theta}(a_{\pi} \mid s)$

9 посчитать таргеты:

$$y_V(\mathbb{T}) := \min_{i=1,2} \{ Q_{\omega_i}(s, a_{\pi}) \} - \alpha \ln \pi_{\theta}(a_{\pi} \mid s)$$

$$y_Q(\mathbb{T}) := r + \gamma V_{\psi^{-}}(s')$$

10 посчитать лоссы:

$$\text{Loss}_V(\psi) := \frac{1}{B} \sum_{\mathbb{T}} (V_\psi(s') - y_V(\mathbb{T}))^2$$

$$\text{Loss}_{Q1}(\omega_1) := \frac{1}{B} \sum_{\mathbb{T}} (Q_{\omega_1}(s, a) - y_Q(\mathbb{T}))^2$$

$$\text{Loss}_{Q2}(\omega_2) := \frac{1}{B} \sum_{\mathbb{T}} (Q_{\omega_2}(s, a) - y_Q(\mathbb{T}))^2$$

11 делаем шаг градиентного спуска по ψ , ω_1 и ω_2 , используя $\nabla_\psi \text{Loss}_V(\psi)$, $\nabla_\omega \text{Loss}_{Q1}(\omega_1)$ и $\nabla_{\omega_2} \text{Loss}_{Q2}(\omega_2)$ соответственно

12 обновляем таргет-сеть: $\psi^- \leftarrow (1 - \beta)\psi^- + \beta\psi$

Сформулируем критерий оптимальности Беллмана в задаче Maximum Entropy RL. По аналогии с обычным случаем, введём оптимальные оценочные функции:

$$V_{\text{soft}}^*(s) := \max_{\pi} \{ V_{\text{soft}}^{\pi}(s) \}$$

$$Q_{\text{soft}}^*(s, a) := \max_{\pi} \{ Q_{\text{soft}}^{\pi}(s, a) \}$$

Теорема (Вид оптимальной стратегии для Maximum Entropy RL)

Оптимальной является единственная стратегия

$$\pi(a \mid s) \propto \exp Q_{\text{soft}}^*(s, a)$$

Доказательство. Откажемся от стационарности и будем рассматривать задачу поиска оптимальной стратегии $\pi_t(a \mid s_0)$ в предположении, что в будущем мы сможем набрать максимально возможную награду $Q_{\text{soft}}^*(s, a, t)$:

$$\mathbb{E}_{\pi_t(a|s)} [Q_{\text{soft}}^*(s, a, t) - \ln \pi_t(a \mid s)] \rightarrow \max_{\pi_t(a|s)}$$

Аналогично теореме 2 про soft policy improvement, можно заметить, что с точностью до константы, не зависящей от π_t , оптимизируемое выражение есть:

$$- \text{KL} \left(\pi_t(a \mid s) \parallel \frac{\exp Q_{\text{soft}}^*(s, a, t)}{Z(s, t)} \right) \rightarrow \max_{\pi_t(a|s)},$$

где $Z(s, t)$ — нормировочная константа $\exp Q_{\text{soft}}^*(s, a, t)$. Понятно, что оптимум достигается в нуле на $\pi_t(a \mid s)$, совпадающей с этим распределением.

Дальнейшее рассуждение строится как раньше: Q_{soft}^* от времени не зависит по определению, поэтому оптимальная стратегия получается стационарной, следовательно

$$\pi(a \mid s) \propto \exp Q_{\text{soft}}^*(s, a)$$

Заметим, что в силу однозначного определения $Q_{\text{soft}}^*(s, a)$, такая стратегия в принципе единственна в отличие от обычной задачи RL.



Теорема

$$V_{\text{soft}}^*(s) = \ln \int_{\mathcal{A}} \exp Q_{\text{soft}}^*(s, a) da \quad (10)$$

Доказательство. Мы знаем, что оптимальная стратегия имеет вид $\pi^*(a | s) = \frac{\exp Q_{\text{soft}}^*(s, a)}{Z(s)}$, где

$$Z(s) := \int_{\mathcal{A}} \exp Q_{\text{soft}}^*(s, a) da$$

является нормировочной константой. Посчитаем энтропию такого распределения:

$$\begin{aligned} -\mathbb{E}_{\pi^*(a|s)} [\ln \pi^*(a | s)] &= \int_{\mathcal{A}} \frac{\exp Q_{\text{soft}}^*(s, a)}{Z(s)} (\ln Z(s) - Q_{\text{soft}}^*(s, a)) da = \\ &= \ln Z(s) - \mathbb{E}_{\pi^*(a|s)} [Q_{\text{soft}}^*(s, a)]. \end{aligned}$$

Подставим оптимальную стратегию в мягкое VQ уравнение (5), которое справедливо в том числе и для оптимальной стратегии:

$$\begin{aligned} V_{\text{soft}}^*(s) &= \mathbb{E}_{\pi^*(a|s)} [Q_{\text{soft}}^*(s, a) - \ln \pi^*(a | s)] = \\ &= \mathbb{E}_{\pi^*(a|s)} [Q_{\text{soft}}^*(s, a)] - \mathbb{E}_{\pi^*(a|s)} [Q_{\text{soft}}^*(s, a)] + \ln Z(s) = \\ &= \ln Z(s) \end{aligned}$$

Вспоминая определение $Z(s)$, получаем доказываемое.



Утверждение

$$Q_{\text{soft}}^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} [V_{\text{soft}}^*(s')]$$

Утверждение (Мягкое уравнение оптимальности Беллмана (soft Bellman optimality equations))

$$Q_{\text{soft}}^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} \left[\ln \int_{\mathcal{A}} \exp Q_{\text{soft}}^*(s', a') da' \right] \quad (11)$$

Теорема

Оператор, стоящий в правой части уравнения (11), является сжимающим с коэффициентом γ , и, следовательно, метод простой итерации решения этой системы уравнений сходится из любого начального приближения к единственной неподвижной точке.

Доказательство. Пусть даны две Q-функции, Q_1, Q_2 , и пусть

$$\rho(Q_1, Q_2) := \max_{s \in \mathcal{S}, a \in \mathcal{A}} \{|Q_1(s, a) - Q_2(s, a)|\} \leq \varepsilon.$$

Тогда:

$$\ln \int_{\mathcal{A}} \exp Q_1(s, a) da \leq \ln \int_{\mathcal{A}} \exp(Q_2(s, a) + \varepsilon) da = \varepsilon + \ln \int_{\mathcal{A}} \exp Q_2(s, a) da.$$

Аналогично можно показать, что

$$\ln \int_{\mathcal{A}} \exp Q_1(s, a) da \geq -\varepsilon + \ln \int_{\mathcal{A}} \exp Q_2(s, a) da$$

Пусть $\mathfrak{B}_{\text{soft}}$ — оператор, стоящий в правой части (11). Тогда:

$$\begin{aligned} & |[\mathfrak{B}_{\text{soft}} Q_1](s, a) - [\mathfrak{B}_{\text{soft}} Q_2](s, a)| = \\ & = \gamma \left| \mathbb{E}_{s'} \left[\ln \int_{\mathcal{A}} \exp Q_1(s', a') da' - \ln \int_{\mathcal{A}} \exp Q_2(s', a') da' \right] \right| \leq \gamma \varepsilon. \end{aligned}$$

Таким образом, $\rho(\mathcal{B}_{\text{soft}} Q_1, \mathcal{B}_{\text{soft}} Q_2)$ уменьшилось по крайней мере в γ раз по сравнению с $\rho(Q_1, Q_2)$.



Утверждение

Если $\pi(a | s) \propto \exp Q_{\text{soft}}^{\pi}(s, a)$, то она оптимальна.

Доказательство. Q-функция такой стратегии удовлетворяет мягкому уравнению оптимальности Беллмана (11) и в силу единственности его решения совпадает с $Q_{\text{soft}}^(s, a)$.*



Теперь можно построить аналог DQN для задачи Maximum Entropy RL, называемым **Soft Q-learning**. В нём нет отдельной модели актёра, и текущая стратегия просто полагается жадной по отношению к текущему критику. Это также можно интерпретировать как моделирование **Soft Value Iteration** — решение мягкого уравнения оптимальности (11). Тогда таргет для перехода $\mathbb{T} := (s, a, r, s')$ строится как

$$y(\mathbb{T}) := r + \gamma \ln \int_{\mathcal{A}} \exp Q_{\theta^-}(s', a') da',$$

где θ^- — параметры таргет-сети.

Теорема (Soft Policy Gradient)

$$\nabla_{\theta} J_{\text{soft}}(\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi_{\theta}}(s)} \mathbb{E}_{a \sim \pi_{\theta}(a|s)} [\nabla_{\theta} \ln \pi_{\theta}(a | s) Q_{\text{soft}}^{\pi}(s, a)] + \alpha \nabla_{\theta} \mathcal{H}(\pi_{\theta}(\cdot | s)).$$

Доказательство. Аналогично доказательству в обычном случае. ■