

# Лекция 13

## Обучение с подкреплением

Никита Юдин, [iudin.ne@phystech.edu](mailto:iudin.ne@phystech.edu)

Московский физико-технический институт  
Физтех-школа прикладной математики и информатики

30 апреля 2026



Если уж мы рассматриваем задачу RL как попытку создания алгоритма «искусственного интеллекта», то мы должны дополнительно учесть следующие три факта:

- понятно, что в одной и той же среде агент может ставить себе совершенно разные задачи; интеллектуальное обучение должно позволять обобщать решения одних задач на другие, решать сложные задачи, состоящие из составных частей, и, наконец, уметь самостоятельно ставить самому себе «промежуточные» задачи.
- в общем случае, текущее наблюдение среды не описывает её состояние полностью, и агент, во-первых, должен обладать модулем памяти для запоминания предыдущих наблюдений, во-вторых, действовать в условиях неопределённости.
- наконец, в среде могут присутствовать другие агенты, которые могут иметь как схожие, так и противоположные цели, передавать вспомогательную информацию или, в частности, играть роль эксперта, демонстрирующих оптимальное (или полезное) поведение.


# Клонирование поведения

## Пример

*Чтобы обучить self-driving car, проще посадить реального водителя за руль и попросить собрать примеры траекторий, чем описать функцию награды, описывающую правила движения.*

## Пример

*Чтобы обучить робота переливать воду из стакана в стакан, проще не придумать функцию награды, описывающую такую задачу, а взять руку робота и несколько раз, «держа его за ручку», перелить воду из стакана в стакан.*



### Определение

**Клонированием поведения** (*behavioral cloning*) называется обучение стратегии воспроизводить действия эксперта:

$$\sum_{\mathcal{T}} \sum_{(s,a) \in \mathcal{T}} \ln \pi_{\theta}(a \mid s) \rightarrow \max_{\theta}. \quad (1)$$

## Пример (DAgger)

*Одна из универсальных идей звучит так: после клонирования поведения запустить полученную стратегию в среду, собрать набор тех состояний, которые она посетила, и попросить эксперта «разметить» их: выбрать оптимальные действия. Но такой алгоритм предполагает, что у нас есть подобное «средство разметки», за счёт которого задача и сводится к обучению с учителем.*

**Пример 1 — Quadcopter Navigation in the Forest:** Иногда возможно придумать какое-нибудь ухищрение, как всё-таки получить в RL «правильные ответы». Например, **в одном примере (ссылка)** квадрокоптер учится лететь вдоль лесной тропинки, выбирая на каждом шаге из трёх действий: влево, вперёд или вправо. Чтобы собрать «обучающую выборку» для него, человек надел шлем с тремя камерами, смотрящими вправо, вперёд и влево, и пошёл по центру лесной тропинки. Собирается такой датасет: для камеры, смотрящей влево, правильный ответ — действие «вправо», для центральной — «вперёд», для правой — «влево». Всё свелось к обучению классификатора.


# Обратное обучение с подкреплением (Inverse RL)

## Определение

Задачей **обратного обучения с подкреплением** (*inverse reinforcement learning, IRL*) называется задача по набору траекторий ( $\mathcal{T}$ ) оптимального агента восстановить функцию награды, которую он максимизирует.


## Пример

Рассмотрим клеточный мир, в котором агент может ходить вправо-влево-вниз-вверх. Для простоты также допустим, что функция награды — детерминированная, зависит только от состояний, и на клетках одного цвета её значения совпадают. Что мы тогда можем о ней сказать, имея на руках одну экспертную траекторию, порождённую оптимальной стратегией?






## Пример




На самом деле, не так много. Агент, видимо, стремился в зелёную клетку; наверное, за неё полагается положительная награда. Через красную клетку агент прошёл, хотя мог бы обойти за счёт более позднего попадания в зелёную клетку; видимо, это того не стоило, и за красную клетку награда, если и отрицательная, то совсем маленькая.

## Пример



Могла ли она быть положительной? Тогда бы эксперт, наверное, походил бы по красным клеткам; видимо, награда за зелёную сильно выгоднее. Синие клетки агент избегал; видимо, они или дают штраф, или ноль, поскольку если бы они давали бонус, то было бы выгодно добираться до зелёной клетки-цели через них.

## Пример



Наконец, про жёлтые клетки сказать почти ничего нельзя: агенту пришлось бы в любом случае пройти через них, чтобы добраться до зелёной клетки, и поэтому в них может быть как штраф (но не очень большой), так и бонус (но тоже не очень большой).

Для упрощения формул будем везде далее полагать  $\gamma = 1$ . Введём следующее предположение: оптимальная стратегия  $\pi^*$  стохастична и генерирует такие траектории, что:

$$p(\mathcal{T} \mid \pi^*) \propto e^{R(\mathcal{T})} \prod_{t \geq 0} p(s_{t+1} \mid s_t, a_t). \quad (2)$$

Откуда это предположение свалилось? На самом деле, это уже знакомый нам Maximum Entropy RL. Действительно: рассмотрим задачу поиска стратегии, которая порождает траектории из распределения (2):

$$\text{KL}(p(\mathcal{T} \mid \pi) \parallel p(\mathcal{T} \mid \pi^*)) \rightarrow \min_{\pi}. \quad (3)$$

**Теорема 1:** Задача (3) эквивалентна задаче Maximum Entropy RL.

*Доказательство.* Распишем (3):

$$\begin{aligned} \text{KL}(p(\mathcal{T} \mid \pi) \parallel p(\mathcal{T} \mid \pi^*)) &= \mathbb{E}_{\mathcal{T} \sim \pi} \overbrace{\sum_{t \geq 0} [\ln \pi(a_t \mid s_t) + \ln p(s_{t+1} \mid s_t, a_t)]}^{\ln p(\mathcal{T} \mid \pi)} - \\ &\quad - \underbrace{\mathbb{E}_{\mathcal{T} \sim \pi} \sum_{t \geq 0} [\ln p(s_{t+1} \mid s_t, a_t) + r_t]}_{\ln p(\mathcal{T} \mid \pi^*) \text{ из (2)}} + \text{const}(\pi), \end{aligned}$$

где  $\text{const}(\pi)$  — нормировочная константа распределения (2). Убирая сокращающиеся логарифмы вероятностей переходов и домножая на минус единицу, получаем:

$$\mathbb{E}_{\mathcal{T} \sim \pi} \sum_{t \geq 0} [r_t - \ln \pi(a_t \mid s_t)] \rightarrow \max_{\pi},$$

что есть в точности Maximum Entropy RL. ■

## Утверждение

Ноль в задаче (3) не обязательно достижим.

*Контрпример. Рассмотрим MDP с единственным состоянием, в котором от действий ничего не зависит, но с вероятностью 0.5 агент получает  $+\ln 2$ , а с вероятностью 0.5 агент получает  $+0$ , после чего игра заканчивается. Распределение (2) говорит, что оптимальная стратегия так выбирает действия, что траектория с наградой  $+\ln 2$  встречается с вероятностью  $\frac{2}{3}$ , а с наградой  $+0$  — с вероятностью  $\frac{1}{3}$ , однако это невозможно: любая стратегия будет получать их с вероятностями 0.5.*

# Guided Cost Learning

Аппроксимируем функцию награды нейросетью  $r_\theta(s, a)$ . Тогда правдоподобие одной траектории в предположении (2) равно:

$$p_\theta(\mathcal{T} \mid \pi^*) = \frac{e^{R_\theta(\mathcal{T})} \prod_{t \geq 0} p(s_{t+1} \mid s_t, a_t)}{Z(\theta)},$$

где  $R_\theta(\mathcal{T}) := \sum_{(s,a) \in \mathcal{T}} r_\theta(s, a)$  — текущая аппроксимация кумулятивной награды, а нормировочная константа, внимание, зависит от параметров нейросети  $\theta$ :

$$Z(\theta) := \int_{\mathcal{T}} e^{R_\theta(\mathcal{T})} \prod_{t \geq 0} p(s_{t+1} \mid s_t, a_t) d\mathcal{T}. \quad (4)$$

Рассмотрим логарифм правдоподобия:

$$\ln p_{\theta}(\mathcal{T} \mid \pi^*) = R_{\theta}(\mathcal{T}) + \underbrace{\sum_{t \geq 0} \ln p(s_{t+1} \mid s_t, a_t)}_{\text{const}(\theta)} - \ln Z(\theta). \quad (5)$$

Пусть у нас есть некоторая функция награды с параметрами  $\theta$ . Пусть  $\pi_{[\theta]}^*$  — стратегия, которая оптимально (в терминах Maximum Entropy фреймворка, в рамках предположения (2)) оптимизирует вот эту награду, которую мы предлагаем с текущими параметрами  $\theta$ . Такая стратегия по определению будет в среде генерировать траектории из распределения:

$$p(\mathcal{T} \mid \pi_{[\theta]}^*) := \frac{e^{R_{\theta}(\mathcal{T})} \prod_{t \geq 0} p(s_{t+1} \mid s_t, a_t)}{Z(\theta)}. \quad (6)$$



## Theorem (Guided Cost Learning)

*Градиент для оптимизации правдоподобия (5) траекторий эксперта по параметрам функции награды  $\theta$  равен:*

$$\mathbb{E}_{\mathcal{T} \sim \pi^*} [\nabla_{\theta} R_{\theta}(\mathcal{T})] - \mathbb{E}_{\mathcal{T} \sim \pi_{[\theta]}^*} [\nabla_{\theta} R_{\theta}(\mathcal{T})]. \quad (7)$$

*Доказательство.* Рассмотрим градиент логарифма правдоподобия одной траектории:

$$\nabla \ln p_{\theta}(\mathcal{T} \mid \pi^*) = \nabla R_{\theta}(\mathcal{T}) - \nabla \ln Z(\theta).$$

Мы хотим оптимизировать правдоподобие в среднем по траекториям эксперта, однако нам нужен градиент нормировочной константы (общий для всех траекторий эксперта, поэтому из мат.ожидания по ним эту константу можно вынести). Рассмотрим дифференцирование нормировочной константы отдельно:

$$\begin{aligned}
\nabla \ln Z(\theta) &= \{\text{градиент логарифма}\} = \frac{1}{Z(\theta)} \nabla Z(\theta) = \\
&= \{\text{определение } Z(\theta) \text{ (4)}\} = \\
&= \frac{1}{Z(\theta)} \int_{\mathcal{T}} \nabla_{\theta} e^{R_{\theta}(\mathcal{T})} \prod_{t \geq 0} p(s_{t+1} \mid s_t, a_t) d\mathcal{T} = \\
&= \{\text{дифференцируем экспоненту}\} = \\
&= \frac{1}{Z(\theta)} \int_{\mathcal{T}} e^{R_{\theta}(\mathcal{T})} \prod_{t \geq 0} p(s_{t+1} \mid s_t, a_t) \nabla_{\theta} R_{\theta}(\mathcal{T}) d\mathcal{T} = \\
&= \{\text{определение } \pi_{[\theta]}^* \text{ (6)}\} = \mathbb{E}_{\mathcal{T} \sim p(\mathcal{T} \mid \pi_{[\theta]}^*)} [\nabla R_{\theta}(\mathcal{T})]. \quad \blacksquare
\end{aligned}$$

# Generative Adversarial Imitation Learning (GAIL)

## Утверждение

Оптимизация функции награды по формуле (7) соответствует оптимизации следующего функционала:

$$\mathbb{E}_{\mathcal{T} \sim \pi^*} [R(\mathcal{T})] - \max_{\pi} \left\{ \mathbb{E}_{\mathcal{T} \sim \pi} \sum_{t \geq 0} [r(s_t, a_t) + \mathcal{H}(\pi(\cdot \mid s_t))] \right\} \rightarrow \max_r. \quad (8)$$

Пояснение. Градиент максимума от функции есть градиент этой функции в точке максимума, а энтропия  $\mathcal{H}(\pi(\cdot \mid s_t))$  не зависит от  $r$ , поэтому градиент второго слагаемого совпадает со вторым слагаемым (7). ■

# Generative Adversarial Imitation Learning (GAIL)

## Определение

*Occupancy measure* для стратегии  $\pi$  будем называть

$$\rho_{\pi}(s, a) := \pi(a \mid s) d_{\pi}(s), \quad (9)$$

где  $d_{\pi}(s)$  — частоты посещения состояний.

По определению, мат.ожидания по траектории с таким обозначением можно записывать как

$$\mathbb{E}_{\mathcal{T} \sim \pi} \left[ \sum_{t \geq 0} f(s_t, a_t) \right] = \mathbb{E}_{\rho_\pi} [f(s, a)].$$

Давайте воспользуемся этим обозначением в (8). Раскрывая определение мат.ожидания и переписывая оптимизацию по  $\pi$  как минимизацию, получаем такую «игру» (читать — поиск седловой точки):

$$\min_r \max_\pi \left\{ \mathbb{E}_{\rho_\pi} [r(s, a)] - \mathbb{E}_{\rho_{\pi^*}} [r(s, a)] + \mathbb{E}_{\mathcal{T} \sim \pi} \left[ \sum_{t \geq 0} \mathcal{H}(\pi(\cdot | s_t)) \right] \right\}. \quad (10)$$

Утверждение

$$\pi(a | s) = \frac{\rho_\pi(s, a)}{\int_{\mathcal{A}} \rho_\pi(s, a) da} \quad (11)$$

Значит, можно поиск стратегии интерпретировать как поиск осцирансу measure: действительно, в (10) последнее слагаемое — суммарный энтропийный бонус стратегии  $\pi$  — тоже можно переписать в терминах  $\rho_\pi(s, a)$ . Обозначим его как

$$\begin{aligned}\tilde{\mathcal{H}}(\rho_\pi) &:= \mathbb{E}_{\mathcal{T} \sim \pi} \left[ \sum_{t \geq 0} \mathcal{H}(\pi(\cdot \mid s_t)) \right] = \mathbb{E}_{\rho_\pi} [-\ln \pi(a \mid s)] = \{(11)\} = \\ &= -\mathbb{E}_{\rho_\pi} \left[ \ln \left( \frac{\rho_\pi(s, a)}{\int_{\mathcal{A}} \rho_\pi(s, a) \, da} \right) \right].\end{aligned}$$

Получаем такой взгляд на процесс обучения:

$$\min_r \max_{\rho_\pi} \left\{ \mathbb{E}_{\rho_\pi} [r(s, a)] - \mathbb{E}_{\rho_{\pi^*}} [r(s, a)] + \tilde{\mathcal{H}}(\rho_\pi) \right\}. \quad (12)$$

Но как GAN-ы связаны с обратным обучением с подкреплением, с обучением награды? Оказывается, это одно и то же. Чтобы увидеть это в чистом виде, сделаем следующий важный шаг: мы добавим регуляризатор и для оптимизации по  $r$ . Это можно мотивировать тем, что, как мы обсуждали ранее, задача обратного обучения с подкреплением «некорректна» и может иметь много разных решений. Итак, добавим некоторое слагаемое  $\psi(r)$ , которое будет смотреть на нашу выдаваемую функцию награды и некоторым образом её дополнительно штрафовать:

$$\min_r \max_{\rho_\pi} \{ \psi(r) + \mathbb{E}_{\rho_\pi} [r(s, a)] - \mathbb{E}_{\rho_{\pi^*}} [r(s, a)] + \tilde{\mathcal{H}}(\rho_\pi) \}. \quad (13)$$

Оказывается, ванильный GAN, различающий сэмплы пар  $s, a$  из распределений  $p(\mathcal{T} \mid \pi^*)$  и  $p(\mathcal{T} \mid \pi)$ , соответствует просто определённому выбору регуляризатора!

## Теорема

Выберем в (13) следующий регуляризатор:

$$\psi(r) := \mathbb{E}_{\rho_{\pi^*}} \left[ r(s, a) + \ln(1 - e^{-r(s, a)}) \right], \quad (14)$$

где штраф полагается бесконечно большим, если  $r(s, a) \leq 0$ . Тогда задача (13) примет вид:

$$\min_D \max_{\pi} \left\{ -\mathbb{E}_{\rho_{\pi^*}} [\ln(1 - D(s, a))] - \mathbb{E}_{\rho_{\pi}} [\ln D(s, a)] + \tilde{\mathcal{H}}(\rho_{\pi}) \right\}, \quad (15)$$

где  $D(s, a) \in (0, 1)$ .

*Доказательство.* Подставим в (13) выбранный регуляризатор:

$$\begin{aligned} & \min_r \max_{\pi} \left\{ \psi(r) + \mathbb{E}_{\rho_{\pi}} [r(s, a)] - \mathbb{E}_{\rho_{\pi^*}} [r(s, a)] + \tilde{\mathcal{H}}(\rho_{\pi}) \right\} = \\ & = \min_r \max_{\pi} \left\{ \mathbb{E}_{\rho_{\pi^*}} \left[ \ln(1 - e^{-r(s, a)}) \right] + \mathbb{E}_{\rho_{\pi}} [r(s, a)] + \tilde{\mathcal{H}}(\rho_{\pi}) \right\}. \end{aligned}$$



Сделаем замену переменных: вместо оптимизации по  $r(s, a) > 0$  будем оптимизировать по  $D(s, a)$ , где  $D(s, a) := e^{-r(s, a)}$  — произвольное число в диапазоне  $(0, 1)$ . Тогда  $r(s, a) = -\ln(D(s, a))$  и

$$\min_D \max_{\pi} \left\{ -\mathbb{E}_{\rho_{\pi^*}} [\ln(1 - D(s, a))] - \mathbb{E}_{\rho_{\pi}} [\ln D(s, a)] + \tilde{\mathcal{H}}(\rho_{\pi}) \right\}. \quad \blacksquare$$

Итак, что мы получили в формуле (15): вместо награды будем обучать дискриминатор, решающий задачу бинарной классификации, где пары  $s, a$  из  $\rho_{\pi^*}$  образуют класс 1, а пары  $s, a$  из  $\rho_{\pi}$  — класс 0. Действительно, оптимизация (15) по  $D$  при фиксированной  $\pi$  выглядит так:

$$\mathbb{E}_{\rho_{\pi^*}} [\ln(1 - D(s, a))] + \mathbb{E}_{\rho_{\pi}} [\ln D(s, a)] \rightarrow \max_D,$$

то есть мы просто учимся отличать пары  $s, a$ , порождённые (встреченные) экспертом от тех, что встречает наша текущая стратегия. Оптимизация же по  $\pi$  (давайте вернёмся к оптимизации по стратегии) при фиксированном «дискриминаторе»  $D$  выглядит так:

$$\mathbb{E}_{\mathcal{T} \sim \pi} \sum_{t \geq 0} [-\ln D(s_t, a_t) + \mathcal{H}(\pi(\cdot \mid s_t))] \rightarrow \max_{\pi}.$$

# Generative Adversarial Imitation from Observation (GAIfO)

Часто эксперт предоставляет нам траектории, в которых отсутствует информация о совершённых агентом действиях: есть лишь цепочки состояний  $s_0, s_1, s_2, \dots$ , которые посещал эксперт. Такая задача называется **имитационным обучением по наблюдениям** (imitation learning from observations).

# Generative Adversarial Imitation from Observation (GAIfO)

## Пример

*Допустим, у вас есть покадровые анимации того, как персонаж делает сальто. Вы хотите научить робота с такими же конечностями делать тоже самое. В анимациях понятно, в каких координатах находились все конечности персонажа в каждый момент времени, и можно считать, что робот при выполнении задачи должен «посещать» те же цепочки состояний. Однако в анимации действий нету — вы не знаете, как нужно управлять роботом, чтобы получить ту же траекторию в реальной среде.*

Мы просто хотим попадать в те же состояния, в которые попадал эксперт, поэтому дискриминатором  $D(s) \in (0, 1)$  теперь будем пытаться различать состояния — порождены ли они экспертом  $s \sim d_{\pi^*}(s)$  или же нашей текущей стратегией  $s \sim d_{\pi}(s)$ :

$$\min_D \max_{\pi} \left\{ -\mathbb{E}_{d_{\pi^*}(s)} [\ln(1 - D(s))] - \mathbb{E}_{d_{\pi}(s)} [\ln D(s)] + \mathbb{E}_{d_{\pi}(s)} [\mathcal{H}(\pi(\cdot | s))] \right\}.$$

В методе Generative Adversarial Imitation from Observation (GAIfo) предлагается сделать хитрость, и различать не состояния, а пары «состояние-следующее состояние»  $(s, s')$ . Другими словами, награда полагается зависящей от пары состояний  $r(s, s')$ , а дискриминатор  $D(s, s')$  учится различать именно пары  $(s, s')$  из экспертных траекторий и из порождаемых траекторий.

Формально говоря, вводится альтернативное определение осцилляции как вероятность встретить ту или иную пару  $(s, s')$  в траекториях из стратегии  $\pi$ :

$$v_{\pi}(s, s') := d_{\pi}(s) \int_{\mathcal{A}} p(s' \mid s, a) \pi(a \mid s) da.$$

Тогда минимаксная задача оптимизации принимает следующий вид:

$$\min_D \max_{\pi} \left\{ -\mathbb{E}_{v_{\pi^*}} [\ln(1 - D(s, s'))] - \mathbb{E}_{v_{\pi}} [\ln D(s, s')] + \mathbb{E}_{d_{\pi}(s)} [\mathcal{H}(\pi(\cdot \mid s))] \right\}.$$