

Вводная лекция

Обучение с подкреплением

Никита Юдин, iudin.ne@phystech.edu

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

5 февраля 2026



Команда курса

- лектор: Никита Юдин
- ассистенты:
 - Георгий Акиндинов
 - Дмитрий Былинкин
 - Варвара Руденко
 - Иван Янко

Telegram беседа



Ссылка на беседу: <https://t.me/+AV4p7VeGGGw0N2Uy>

Правила игры

В курсе предусмотрено не менее пяти лабораторных работ (с жёсткими дедлайнами) в формате ноутбуков и устный экзамен. Итоговая оценка по курсу в 10-балльной шкале рассчитывается по формуле:

$$\text{Итоговая оценка} = \text{Округл.вверх} (0.3 * \text{Экз} + 0.7 * \text{Лаб})$$

Оценке «отлично» соответствует оценка 8 и выше, оценке «хорошо» — оценка [5, 8), оценке «удовлетворительно» — промежуток [3, 5). Помимо баллов необходимо также выполнить следующие условия:


- на «отлично» — оценка за экзамен не меньше 5;
- на «хорошо» — оценка за экзамен не меньше 4;
- на «удовлетворительно» — оценка за экзамен не меньше 3.

Обучение с учителем

- дано объекты и ответы (x, y)
- семейство алгоритмов $a_\theta(x) \mapsto y$
- функция потерь $L(y, a_\theta(x))$
- найти $\hat{\theta} \in \underset{\theta}{\operatorname{Arg\,min}} \{L(y, a_\theta(x))\}$

Как раз «ответов» в обучении с подкреплением (reinforcement learning) в чистом виде нет. Зато у нас есть **среда-симулятор (environment)**, её **состояния (states)**, **действия (actions)**, влияющие на состояния среды и **награды (rewards)** за совершённые действия. Основной принцип обучения **агента** (стратегии) для оптимального выбора действий — «метод проб и ошибок».

Примеры предметных областей: онлайн реклама




Дано:

- сервис видеохостинга;
- метаданные потоковой трансляции (баннеры, видео, клики);
- признаки, применимые для задачи обучения по прецедентам.

Хотим показывать релевантную рекламу (на странице, пользователю онлайн).

Примеры предметных областей: робототехника



Дано:

- робот;
- неограниченное количество запчастей;
- показания датчиков.

Хотим научить робота ходить.

Примеры предметных областей: видеоигровые среды



Дано:

- дешёвый симулятор;
- неограниченное количество попыток;
- фрейм игры и сопутствующая ему метainформация.

Хотим научить бота выигрывать.

Примеры предметных областей

- диалоговые системы
- количественные финансы (оптимизация портфеля)
- глубокое обучение: оптимизация негладких функций, поиск оптимальной архитектуры нейронной сети
- персонализированная терапия

Возникающие проблемы


Что значит «оптимальное действие»

- повысить доход с одного пользователя или
- сделать пользователя счастливым, чтобы он пришёл снова

Возникающие проблемы

- следуя исключительно оптимальной в «данный момент» стратегией есть шанс никогда не найти стратегию лучше (при условии её наличия)
- например, невозможно оценить влияние других баннеров, показывая один и тот же баннер


Пример модели: многорукий бандит (multi-armed bandit)



примеры применения


- рекламные баннеры
- системы рекомендаций
- разработка лекарств

Пример модели: многорукий бандит (multi-armed bandit)




Основное действие: выбор «рычага» и «нажатие» на него. В контекстном бандите (contextual bandit) используется состояние бандита для хранения дополнительной информации, которая влияет на награду за действие, что приближает взаимодействие с ним к обучению с подкреплением.

Пример модели: многорукий бандит (multi-armed bandit)



Contextual Bandit



Reinforcement Learning

Замечание: над агентом у нас полный контроль, среда/бандит для нас – «чёрный ящик».

с учителем

- обучаемся аппроксимировать данные ответы
- требуются корректные ответы
- настраиваемая модель не влияет на входные данные

с подкреплением

- обучаемся оптимальной стратегии по принципу «проб и ошибок»
- требуется отклик на собственные действия агента
- агент может влиять на входные наблюдения


без учителя

- учим структуру данных
- отклик не требуется
- настраиваемая модель не влияет на входные данные

с подкреплением


- обучаемся оптимальной стратегии по принципу «проб и ошибок»
- требуется отклик на собственные действия агента
- агент может влиять на входные наблюдения

Постановка задачи



- s_t — состояние среды в момент t
 - a_t — действие, выбранное в момент t
 - r_t — награда, полученная в момент t
- $\pi(a|s, \theta)$ — политика — вероятность совершить a из s при параметрах политики θ
 - $\tau = \{(s_0, a_0, r_0), \dots, (s_T, a_T, r_T)\}$ — траектория агента согласно политике
 - $\gamma \in (0, 1]$ — дисконтирующий фактор
 - $p(s'|s, a)$ — вероятность попасть в состояние s' из состояния s с помощью действия a

Постановка задачи



- $p(\tau|\pi) = p(s_0) \prod_{t=0}^T (\pi(a_t|s_t)p(s_{t+1}|s_t, a_t))$ — вероятность реализации траектории τ при фиксированной политике π
- $R := \sum_{t=0}^T \gamma^t r_t$ — суммарная награда на момент времени T , с учетом дисконтирования, на произвольной тректории
- $\mathbb{E}_{p(\tau|\theta)} [R] \rightarrow \max_{\theta}$ — общая оптимизационная задача, θ — параметры π ; по умолчанию, $T \rightarrow \infty$

Марковский процесс принятия решений

Markov Decision Process (MDP)

Марковский процесс принятия решений — кортеж из $(\mathcal{S}, \mathcal{A}, R, \mathcal{T}, \gamma)$, где:

$\mathcal{A}$ — множество действий,

$\mathcal{S}$ — множество состояний,

$R : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ — функция наград,

$\mathcal{T} : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow [0, 1]$ — функция вероятности перехода,

для которого $\mathcal{T}(s, a, s') = \mathbb{P}(s_{t+1} = s' | s_t = s, a_t = a)$, то есть вероятность оказаться в следующем состоянии зависит только от предыдущего состояния и действия из него.

Метод кросс-энтропии [1], [ссылка на конспект](#), стр. 32-35

Идея: сэмплением оценить вероятность редкого события

$$\mathbb{E}_{p(x)}[f(x) \geq \hat{\gamma}] \approx \frac{1}{M} \sum_{j=1}^M [f(x_j) \geq \hat{\gamma}] \cdot \frac{p(x_j)}{q(x_j|\lambda_k)},$$

M — кол-во сэмплов, $x_j \sim q(x|\lambda_k)$, λ_k — фиксированный параметр. Оптимальное распределение $q_{opt}(x) \propto [f(x) \geq \hat{\gamma}]p(x)$ (его нужно найти)

Замечание

Полученная задача есть задача максимума правдоподобия на параметр λ_k

Схема метода кросс-энтропии [2]

- 1) Инициализация $\lambda_0, M, \rho \in [0, 1], k := 0$
- 2) Сэмплирование $x_1, \dots, x_M \sim q(x|\lambda_k)$
- 3) Вычисляем редкое событие $f_j = f(x_j)$ и сортируем их по возрастанию $f_{(1)} \leq \dots \leq f_{(M)}$
- 4) $\hat{\gamma}_k := \min(f_{(\max\{\lfloor \rho M \rfloor, 1\})}, \hat{\gamma})$
- 5) $\lambda_{k+1} := \arg \max_{\lambda} \left\{ \frac{1}{M} \sum_{j=1}^M [f(x_j) \geq \hat{\gamma}_k] \cdot \frac{p(x_j)}{q(x_j|\lambda_k)} \ln q(x_j|\lambda) \right\}$
- 6) Критерий останова: $\hat{\gamma}_k = \hat{\gamma}$, иначе переходим на шаг 2 с $k := k + 1$

Получение итоговой оценки:

- 1) Сэмплируем $x_1, \dots, x_M \sim q(x|\lambda_k)$
- 2) Вычисляем $\frac{1}{M} \sum_{j=1}^M [f(x_j) \geq \hat{\gamma}_k] \cdot \frac{p(x_j)}{q(x_j|\lambda_k)}$

Применение метода кросс-энтропии

Вывод

Полученный метод ищет то распределение $q(x|\lambda)$, на котором в среднем $f(x)$ больше некоего порога чаще всего. Что является безградиентным методом решения задачи оптимизации

$$f(x) \rightarrow \max_x \Leftrightarrow \mathbb{E}_{p(x)}[f(x) \geq \hat{\gamma}], \hat{\gamma} \approx \max_x \{f(x)\}, p(x) := q(x|\lambda)$$


Оптимизационный метод кросс-энтропии

1) - 3) Как и раньше

$$4) \hat{\gamma}_k := f_{(\max\{\lfloor \rho M \rfloor, 1\})}$$

$$5) \lambda_{k+1} := \arg \max_{\lambda} \left\{ \frac{1}{M} \sum_{j=1}^M [f(x_j) \geq \hat{\gamma}_k] \ln q(x_j|\lambda) \right\}$$

Оптимизационный метод кросс-энтропии



Динамика кросс-энтропийного метода при оптимизации функции, точки-кандидаты на экстремум генерируются из нормального распределения.

Метод кросс-энтропии в терминах RL

- 1) Инициализация $\theta_0, M, \rho \in [0, 1], k = 0$
- 2) Сэмплирование $\tau_1, \dots, \tau_M \sim p(\tau|\theta_k)$ — получаем M траекторий по политике $\pi(a|s, \theta)$
- 3) Вычисляем $R_j = R(\tau_j)$ и сортируем их по возрастанию $R_{(1)} \leq \dots \leq R_{(M)}$
- 4) $\hat{\gamma}_k := R_{(\max\{\lfloor \rho M \rfloor, 1\})}$
- 5) $\theta_{k+1} := \arg \max_{\theta} \left\{ \frac{1}{M} \sum_{j=1}^M [R(\tau_j) \geq \hat{\gamma}_k] \ln p(\tau_j|\theta) \right\}$, где

$$\ln p(\tau_j|\theta) = \sum_{i=0}^{|\tau_j|-1} [(s_i, a_i, r_i) \in \tau_j] \ln \pi(a_i|s_i, \theta)$$
- 6) $k := k + 1$, переход на шаг 2, если не выполнен критерий останова

Метод кросс-энтропии в терминах RL

Интерпретация алгоритма

На каждом шаге алгоритм смотрит на самые успешные, согласно награде, траектории и повышает вероятность совершения действий из этих траекторий. То есть алгоритм учится совершать действия из лучших траекторий.

Замечание

Алгоритм почти ничего не использует из структуры задачи: как и когда начисляется награда и прочее.

Источники I

- [1] S. Ivanov, “Reinforcement learning textbook,” arXiv preprint arXiv:2201.09746, настольная книга по данному курсу, 2022.
- [2] Z. I. Botev, D. P. Kroese, R. Y. Rubinstein, and P. L’Ecuyer, “The cross-entropy method for optimization,” in Handbook of statistics, vol. 31, pp. 35–59, Elsevier, 2013.