

Лекция 8

Обучение с подкреплением

Никита Юдин, iudin.ne@phystech.edu

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

26 марта 2026



Способ получения оценки на Policy Gradient

Monte-Carlo

Воспользуемся первой формулой для подсчета *Policy Gradient*:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) Q^{\pi}(s_t, a_t),$$

в которой заменим всё неизвестное на оценку по Монте-Карло.

Способ получения оценки на Policy Gradient

Что будем заменять?

- $\mathbb{E}_{\tau \sim \pi} \rightarrow$ сыграем несколько полных игр при помощи текущей стратегии π — алгоритм будет *on-policy*.
- $Q^{\pi}(s_t, a_t) \rightarrow R_t(\tau)$ — можно сказать, что мы воспользовались вторым способом подсчета *Policy Gradient* с Монте-Карло оценкой $\mathbb{E}_{\tau \sim \pi}$, что не удивляет, ведь подходы, как мы уже показали, эквиваленты.

Итоговый алгоритм оптимизации средней дисконтированной награды

REINFORCE

Гиперпараметры: N — количество игр, $\pi(a|s, \theta)$ — стратегия с параметрами θ , SGD -оптимизатор.

0. Произвольно инициализируем θ .

На очередном шаге k

1. Играем N игр $\tau_1, \tau_2, \dots, \tau_N \sim \pi$.
2. Для каждого t в каждом τ_i считаем $R_t(\tau) := \sum_{\hat{t} \geq t} \gamma^{\hat{t}-t} r_{\hat{t}}$.
3. Считаем оценку градиента:

$$\nabla_{\theta} J(\pi) := \frac{1}{N} \sum_{\tau} \sum_{t \geq 0} \gamma^t \nabla_{\theta} \log \pi(a_t | s_t, \theta) R_t(\tau).$$

4. Делаем шаг градиентного подъёма по θ , используя $\nabla_{\theta} J(\pi)$.

Итоговый алгоритм оптимизации средней дисконтированной награды

Недостатки

1. Для одного шага градиентного подъёма нам необходимо играть несколько игр **до конца** при помощи текущей стратегии.
2. Колоссальная дисперсия нашей оценки градиента — на практике дожидаться каких-то результатов от такого алгоритма в сколько-то сложных задачах не получится.

Два типа стохастики

Мотивация

До этого мы часто работали с функционалами вида $\mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} \gamma^t f(s_t, a_t)$, где f — какая-то функция от пар состояние-действие.

Стохастика

В MDP есть два вида стохастики:

- 1) **внешняя**, связанная со случайностью в самой среде и неподконтрольная агенту; она заложена в функции переходов $p(s'|s, a)$;
- 2) **внутренняя**, связанная со случайностью в стратегии самого агента; она заложена в $\pi(a|s)$. Это стохастика нам подконтрольна при обучении.

Два типа стохастики

Мотивация

Математическое ожидание $\mathbb{E}_{\tau \sim \pi}$ плохо тем, что математические ожидания по внешней и внутренней стохастике чередуются. При этом во время обучения из внешней стохастики мы можем только получать сэмплы, поэтому было бы здорово переписать наш функционал как-то так, чтобы он имел вид математического ожидания по всей внешней стохастике.

Два типа стохастики

Утверждение

Состояния, которые встречается агент со стратегией π , приходят из некоторой стационарной марковской цепи.

Доказательство

Выпишем вероятность оказаться на очередном шаге в состоянии s' , если мы используем стратегию π :

$$p(s'|s) = \int_A \pi(a|s)p(s'|s, a)da.$$

Эта вероятность не зависит от времени и от истории, следовательно, цепочка состояний образует марковскую цепь.

Два типа стохастики

Допустим, начальное состояние s_0 фиксировано. Обозначим вероятность оказаться в состоянии s в момент времени t при использовании стратегии π как $p(s_t = s | \pi)$.

Определение

Для данного MDP и политики π **state visitation frequency** называется:

$$\mu_\pi(s) := \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t \geq 0}^T p(s_t = s | \pi).$$

Введём ещё один, «дисконтированный счётчик посещения состояний» для стратегии взаимодействия π . При дисконтировании отпадают проблемы с нормировкой.

Два типа стохастики

Определение

Для данного MDP и политики π **discounted state visitation distribution** называется

$$d_{\pi}(s) := (1 - \gamma) \sum_{t \geq 0} \gamma^t p(s_t = s | \pi).$$

Утверждение

State visitation distribution есть распределение на множестве состояний, то есть:

$$\int_S d_{\pi}(s) ds = 1.$$

Два типа стохастики

Доказательство

$$\begin{aligned} &= \int_S d\pi(s) ds = \int_S (1 - \gamma) \sum_{t \geq 0} \gamma^t p(s_t = s | \pi) ds = \\ &= (1 - \gamma) \sum_{t \geq 0} \gamma^t \int_S p(s_t = s | \pi) ds = 1 \end{aligned}$$

Два типа стохастики

Теорема

Для произвольной функции $f(s, a)$:

$$\mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} \gamma^t f(s_t, a_t) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_\pi(s)} \mathbb{E}_{a \sim \pi(a|s)} f(s, a).$$

Начало доказательства

$$\begin{aligned} \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} \gamma^t f(s_t, a_t) &= \sum_{t \geq 0} \gamma^t \mathbb{E}_{\tau \sim \pi} f(s_t, a_t) = \\ &= \sum_{t \geq 0} \gamma^t \int \int_S \int_A p(s_t = s, a_t = a | \pi) f(s, a) da ds = \end{aligned}$$

Два типа стохастики

Продолжение доказательства

$$\begin{aligned} &= \sum_{t \geq 0} \gamma^t \int_S \int_A p(s_t = s | \pi) \pi(a | s) f(s, a) da ds = \\ &= \sum_{t \geq 0} \gamma^t \int_S p(s_t = s | \pi) \mathbb{E}_{\pi(a|s)} f(s, a) ds = \\ &= \int_S \sum_{t \geq 0} \gamma^t p(s_t = s | \pi) \mathbb{E}_{\pi(a|s)} f(s, a) ds = \\ &= \int_S \frac{d\pi(s)}{1 - \gamma} \mathbb{E}_{\pi(a|s)} f(s, a) ds = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_\pi(s)} \mathbb{E}_{\pi(a|s)} f(s, a) \end{aligned}$$

Два типа стохастики

Пример

$$J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_\pi(s)} \mathbb{E}_{\pi(a|s)} r(s, a)$$

Пример

$$\nabla_\theta J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_\pi(s)} \mathbb{E}_{\pi(a|s)} \nabla_\theta \log \pi_\theta(a|s) Q^\pi(s, a)$$

Уменьшаем дисперсию Reinforce. Baseline.

Мотивация

При стохастической оптимизации ключевым фактором является дисперсия оценки градиента. Когда мы заменяем математические ожидания на Монте-Карло оценки, дисперсия увеличивается. Понятно, что замена Q -функции — выинтегрированных будущих наград — на её Монте-Карло оценку в REINFORCE повышало дисперсию. Однако, в текущем виде основной источник дисперсии заключается в другом.

Уменьшаем дисперсию Reinforce. Baseline.

Причина большой дисперсии

Градиент логарифма правдоподобия в среднем равен нулю. Это значит, что если для данного s мы выдаём некоторое распределение $\pi(a|s)$, для увеличения вероятностей в одной области A нужно данный вес θ ; параметризации увеличивать, а в другой области — уменьшать. В среднем «магнитуда изменения» равна нулю. Но у нас в Монте-Карло оценке только $a \sim \pi(a|s)$, и для него направление изменения домножится на кредит: на нашу оценку $Q^\pi(s, a)$. Если эта оценка в одной области 100, а в другой 1000 — дисперсия получаемых значений $\nabla_\theta \log \pi_\theta(a|s) Q^\pi(s, a)$ становится колоссальной.

Вывод

Кредит надо центрировать нулем!

Уменьшаем дисперсию Reinforce. Baseline.

Утверждение

Для произвольной функции $b(s) : S \rightarrow \mathbb{R}$, называемой бэйзлайном, верно:

$$\nabla_{\theta} J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi}(s)} \mathbb{E}_{\pi(a|s)} \nabla_{\theta} \log \pi_{\theta}(a|s) (Q^{\pi}(s, a) - b(s)).$$

Доказательство

Добавленное слагаемое есть ноль в силу формулы теоремы о среднем градиента логарифма правдоподобия.

Уменьшаем дисперсию Reinforce. Baseline.

Замечание

Это верно для произвольной функции от состояний и становится неверно, если вдруг бэйзлайн $b(s)$ начинает зависеть от a . Мы вольны выбрать бэйзлайн произвольно; он не меняет среднего значения оценок градиента, но изменяет дисперсию.

Уменьшаем дисперсию Reinforce. Baseline.

Теорема

Бэйзлайном, максимально снижающим дисперсию Монте-Карло оценок формулы градиентов, является

$$b^*(s) := \frac{\mathbb{E}_a \|\nabla_\theta \log \pi(a, s)\|_2^2 Q^\pi(s, a)}{\mathbb{E}_a \|\nabla_\theta \log \pi(a, s)\|_2^2}$$

Проблема

Практическая ценность результата невысока. Знать норму градиента для всех действий a вычислительно будет труднозатратно даже в дискретных пространствах действий.

Уменьшаем дисперсию Reinforce. Baseline.

На практике предполагаем слабую вариацию по действию нормы градиента

$$\begin{aligned} b^*(s) &:= \frac{\mathbb{E}_a \|\nabla_{\theta} \log \pi(a, s)\|_2^2 Q^{\pi}(s, a)}{\mathbb{E}_a \|\nabla_{\theta} \log \pi(a, s)\|_2^2} = \\ &= [\|\nabla_{\theta} \log \pi(a, s)\|_2^2 \approx \text{const}(a)] \approx \mathbb{E}_a Q^{\pi}(s, a) = V^{\pi}(s) \end{aligned}$$

Итого

$$\nabla_{\theta} J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi}(s)} \mathbb{E}_{\pi(a|s)} \nabla_{\theta} \log \pi_{\theta}(a|s) A^{\pi}(s, a)$$

Уменьшаем дисперсию Reinforce. Baseline.

Итого

$$\nabla_{\theta} J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi}(s)} \mathbb{E}_{\pi(a|s)} \nabla_{\theta} \log \pi_{\theta}(a|s) A^{\pi}(s, a)$$

Определение

Для данного MDP **Advantage-функцией** политики π называется

$$A^{\pi}(s, a) := Q^{\pi}(s, a) - V^{\pi}(s).$$

Схемы «актор-критик»

- Хотим оптимизировать параметры стратегии при помощи формулы градиента, не доигрывая эпизоды до конца.
- Введём вторую нейронную сеть, которая будет «оценивать» наши собственные решения — критика (critic). Нейросеть, моделирующую стратегию, соответственно будем называть актёром или актором (actor), и такие алгоритмы, в которых обучается как модель критика, так и модель актора, называются Actor-Critic.

Схемы «актор-критик»

- В качестве критика обычно учат именно V -функцию.
- Возможность не обучать сложную Q^* является одним из преимуществ подхода прямой оптимизации $J(\theta)$.
- Из соображений эффективности:

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s') \approx r(s, a) + \gamma V_\phi(s'), \quad s' \sim p(s' | s, a).$$

Схемы «актор-критик». Bias-variance trade-off

Собираемся вместо честного advantage подставить некоторую его оценку (advantage estimator) и провести таким образом credit assingment:

$$\nabla_{\theta} J(\pi) \approx \frac{1}{1 - \gamma} \mathbb{E}_{d_{\pi}(s)} \mathbb{E}_{a \sim \pi(a|s)} \nabla_{\theta} \log \pi_{\theta}(a | s) \underbrace{\Psi(s, a)}_{\approx A^{\pi}(s, a)}.$$

В контексте policy gradient, речь напрямую идёт о дисперсии и смещении оценок градиента.

$\Psi(s, a)$	Дисперсия	Смещение
$R_t - V_{\phi}(s)$	высокая	нет
$r(s, a) + \gamma V_{\phi}(s') - V_{\phi}(s)$	низкая	большое

Схемы «актор-критик». Построение оценки Q-функции

$$Q^\pi(s, a) \approx \sum_{t=0}^{N-1} \gamma^t r^{(t)} + \gamma^N V_\phi(s^{(N)}).$$

Для credit assingment-а N -шаговой оценкой Advantage, или N -шаговой временной разностью:

$$\Psi_{(N)}(s, a) := \sum_{t=0}^{N-1} \gamma^t r^{(t)} + \gamma^N V_\phi(s^{(N)}) - V_\phi(s).$$

С ростом N дисперсия такой оценки увеличивается: всё больший фрагмент траектории мы оцениваем по Монте-Карло, нам становятся нужны сэмплы $a_{t+1} \sim \pi(a_{t+1} \mid s_{t+1})$, $s_{t+2} \sim p(s_{t+2} \mid s_{t+1}, a_{t+1})$, $\dots$, $s_{t+N} \sim p(s_{t+N} \mid s_{t+N-1}, a_{t+N-1})$.

Схемы «актор-критик». Построение оценки Q-функции

Определение

Для пар s_t, a_t из роллаута $s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_N$ длины N будем называть оценкой максимальной длины (max trace estimation) оценку с максимальным заглядыванием в будущее: для Q-функции

$$y^{\text{MaxTrace}}(s_t, a_t) := \sum_{\hat{t}=t}^{N-1} \gamma^{\hat{t}-t} r_{\hat{t}} + \gamma^{N-t} V^{\pi}(s_N), \quad (1)$$

для Advantage функции, соответственно:

$$\Psi^{\text{MaxTrace}}(s_t, a_t) := y^{\text{MaxTrace}}(s_t, a_t) - V^{\pi}(s_t). \quad (2)$$

Generalized Advantage Estimation (GAE)

Решение дилеммы bias-variance trade-off подсказывает теория $TD(\lambda)$ оценки. Нужно применить формулу $TD(\lambda)$ и просто заансамблировать N -шаговые оценки разной длины:

Определение

GAE-оценкой Advantage-функции называется ансамбль многошаговых оценок, где оценка длины N берётся с весом λ^{N-1} , где $\lambda \in (0, 1)$ — гиперпараметр:

$$\Psi_{\text{GAE}}(s, a) := (1 - \lambda) \sum_{N=1}^{\infty} \lambda^{N-1} \Psi_{(N)}(s, a).$$

Как мы помним, при $\lambda = 0$ такая GAE-оценка соответствует одношаговой оценке; при $\lambda \rightarrow 1$ GAE-оценка соответствует Монте-Карло оценке Q -функции.

Generalized Advantage Estimation (GAE)

В текущем виде в формуле суммируются все N -шаговые оценки вплоть до конца эпизода. В реальности собранные роллауты могут прерваться в середине эпизода: допустим, для данной пары (s, a) через M шагов роллаут «обрывается». Тогда на практике используется чуть-чуть другим определением GAE-оценки: если мы знаем $s^{(M)}$, но после этого эпизод ещё не доигран до конца, мы пользуемся формулой TD(λ) и оставляем от суммы только «доступные» слагаемые:

$$\Psi_{\text{GAE}}(s, a) := \sum_{t=0}^{M-1} \gamma^t \lambda^t \Psi_{(1)}(s^{(t)}, a^{(t)}). \quad (3)$$

Generalized Advantage Estimation (GAE)

Утверждение

Формула (3) эквивалентна следующему ансамблю N -шаговых оценок:

$$\Psi_{\text{GAE}}(s, a) = (1 - \lambda) \sum_{N=1}^{M-1} \lambda^{N-1} \Psi_{(N)}(s, a) + \lambda^{M-1} \Psi_{(M)}(s, a).$$

В такой «обрезанной» оценке $\lambda = 1$ соответствует оценке максимальной длины (2), а $\lambda = 0$ всё ещё даст одношаговую оценку.

Generalized Advantage Estimation (GAE)

В коде формула (3) очень удобна для рекурсивного подсчёта оценки; также для практического алгоритма осталось учесть флаги done_t . Формулы подсчёта GAE-оценки для всех пар (s, a) из роллаута $s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_N$ приобретают такой вид:

$$\begin{aligned}\Psi_{\text{GAE}}(s_{N-1}, a_{N-1}) &:= \Psi_{(1)}(s_{N-1}, a_{N-1}) \\ \Psi_{\text{GAE}}(s_{N-2}, a_{N-2}) &:= \Psi_{(1)}(s_{N-2}, a_{N-2}) + \\ &\quad + \gamma \lambda (1 - \text{done}_{N-2}) \Psi_{\text{GAE}}(s_{N-1}, a_{N-1}) \\ &\vdots \\ \Psi_{\text{GAE}}(s_0, a_0) &:= \Psi_{(1)}(s_0, a_0) + \gamma \lambda (1 - \text{done}_0) \Psi_{\text{GAE}}(s_1, a_1)\end{aligned}$$

Заметим, что эти формулы очень похожи на расчёт кумулятивной награды за эпизод, где «наградой за шаг» выступает $\Psi_{(1)}(s, a)$.

Обучение критика

Воспользуемся идеей перехода к регрессии, которую мы обсуждали раньше в контексте DQN. Нам нужно просто решать методом простой итерации уравнение Беллмана:

$$V_{\phi_{k+1}}(s) \leftarrow \mathbb{E}_a [r + \gamma \mathbb{E}_{s'} V_{\phi_k}(s')].$$

Воспользуемся преимуществами on-policy режима и поймём, что мы можем поступить точно так же, как с оценкой Q-функции в формуле градиента: решать многошаговое уравнение Беллмана вместо одношагового. Например, можно выбрать любое N -шаговое уравнение и строить целевую переменную как

$$y := r + \gamma r' + \gamma^2 r'' + \dots + \gamma^N V_{\phi_k}(s^{(N)}). \quad (4)$$

Обучение критика

Тогда, если мы оцениваем Advantage как

$$\Psi(s, a) = y - V_{\phi}(s),$$

где y — некоторая оценка Q-функции, то y же является и таргетом для V-функции, и наоборот. Используя функцию потерь MSE с таким таргетом, мы как раз и учим среднее значение наших оценок Q-функции, то есть бэйзлайн.

Конечно же, мы можем использовать и GAE-оценку (3) Advantage, достаточно «убрать бэйзлайн»:

$$Q^{\pi}(s, a) = A^{\pi}(s, a) + V^{\pi}(s) \approx \Psi_{\text{GAE}}(s, a) + V_{\phi}(s).$$

Утверждение

Таргет $\Psi_{\text{GAE}}(s, a) + V_\phi(s)$ является несмещённой оценкой правой части «ансамбля» уравнений Беллмана:

$$V_\phi(s) = (1 - \lambda) \sum_{N=1}^{\infty} \lambda^{N-1} [\mathfrak{B}^N V_\phi](s),$$

где $\mathfrak{B}$ — оператор Беллмана для V -функции.

Доказательство:

по определению, поскольку $\Psi_{(N)}(s, a) + V(s)$ является несмещённой оценкой правой части N -шагового уравнения Беллмана (т. е. несмещённой оценкой $[\mathfrak{B}^N V^\pi](s)$), а

$$(1 - \lambda) \sum_{N=1}^{\infty} \lambda^{N-1} (\Psi_{(N)}(s, a) + V(s)) = \Psi_{\text{GAE}}(s, a) + V(s).$$

Обучение критика

Делаем несколько шагов взаимодействия со средой, собирая таким образом роллаут некоторой длины N ; считаем для каждой пары (s, a) некоторую оценку Q-функции $y(s, a)$, например, оценку максимальной длины (1); оцениваем Advantage каждой пары как $\Psi(s, a) := y(s, a) - V_\phi(s)$; далее по Монте-Карло оцениваем градиент по параметрам стратегии

$$\nabla_\theta J(\pi) \approx \frac{1}{N} \sum_{s,a} \nabla_\theta \log \pi_\theta(a | s) \Psi(s, a)$$

и градиент для оптимизации критика (допустим, критик — V-функция):

$$\text{Loss}^{\text{critic}}(\phi) = \frac{1}{N} \sum_{s,a} (y(s, a) - V_\phi(s))^2.$$

Advantage Actor-Critic (A2C)

Гиперпараметры: M — количество параллельных сред, N — длина роллаутов, $V_\phi(s)$ — нейросеть с параметрами ϕ , $\pi_\theta(a | s)$ — нейросеть для стратегии с параметрами θ , α — коэффициент масштабирования функции потерь критика, SGD оптимизатор.

Инициализировать (θ, ϕ) .

На каждом шаге:

- 1 в каждой параллельной среде собрать роллаут длины N , используя стратегию π_θ :

$$s_0, a_0, r_0, s_1, \dots, s_N;$$

Advantage Actor-Critic (A2C)

- 2 для каждой пары (s_t, a_t) из каждого роллаута посчитать оценку Q-функции максимальной длины, игнорируя зависимость оценки от ϕ :

$$Q(s_t, a_t) := \sum_{\hat{t}=t}^{N-1} \gamma^{\hat{t}-t} r_{\hat{t}} + \gamma^{N-t} V_{\phi}(s_N);$$

- 3 вычислить функцию потерь критика:

$$\text{Loss}^{\text{critic}}(\phi) := \frac{1}{MN} \sum_{s_t, a_t} (Q(s_t, a_t) - V_{\phi}(s_t))^2;$$

- 4 делаем шаг градиентного спуска по ϕ , используя $\nabla_{\phi} \text{Loss}^{\text{critic}}(\phi)$;

Advantage Actor-Critic (A2C)

5 вычислить градиент для актора:

$$\nabla_{\theta}^{\text{actor}} := \frac{1}{MN} \sum_{s_t, a_t} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (Q(s_t, a_t) - V_{\phi}(s_t)) ;$$

6 сделать шаг градиентного подъёма по θ , используя $\nabla_{\theta}^{\text{actor}}$.

Advantage Actor-Critic (A2C). Примеры

Достаточно интересно, что идея model-free алгоритмов, отказывающихся обучать модель функции переходов в том числе из соображений end-to-end схемы, пришла к тому, что мы иногда сводимся к обучению оценочных функций — промежуточных величин, вместо того, чтобы напрямую связывать состояния и действия, понимать, какие действия стоит выбирать чаще других. Вообще, интуиция подсказывает, что обучать актора проще, чем оценочную функцию: в реальных задачах человек редко когда думает в терминах будущей награды.

Advantage Actor-Critic (A2C). Примеры

Есть, однако, и ряд теоретических наблюдений, которые говорят, что эти задачи скорее эквивалентны по сложности. На это указывают формулы градиентов для обучения критика и актора: так, для актора мы идём по градиенту

$$\nabla_{\theta} \log \pi_{\theta}(a | s) \Psi(s, a),$$

а для критика мы идём по градиенту (продифференцируйте MSE, чтобы убедиться в этом):

$$\nabla_{\phi} V_{\phi}(s) \Psi(s, a).$$

Как видно, это как будто бы один и тот же градиент: он просто говорит увеличивать соответствующий выход нейронной сети, а кредит предоставляет скаляр, сообщающий масштаб изменения и, главное, знак.

Advantage Actor-Critic (A2C). Примеры

Пример

Представьте, что вы стоите перед кофеваркой и у вас есть два действия: получить кофе и не получить. Вы прекрасно знаете, какое действие лучше другого, но при этом не оцениваете, сколько кофе вы сможете выпить в будущем при условии, например, что сейчас вы выберете первый или второй вариант: то есть не строите в явном виде прогноз значения оценочной функции.

Advantage Actor-Critic (A2C). Примеры

Пример

Допустим, вы играете в видео-игру, и в начале обучения мало что умеете, всё время действуя примерно случайно и падая в первую же яму. Среда выдаёт вам всё время ноль, и вы продолжаете вести себя случайно. Вдруг в силу стохастичности стратегии вы перепрыгиваете первую яму и получаете монетку +1. В DQN этот ценнейший опыт будет сохранён в буфере, и постепенно критик выучит, какие действия привели к награде. В A2C же агент сделает один небольшой шаг изменения весов моделей и тут же выкинет все собранные данные в мусорку, потому что на следующих итерациях он никак не может переиспользовать их. Агенту придётся ждать ещё много-много сессий в самой игре, пока он не перепрыгнет яму снова, чтобы сделать следующий шаг обучения перепрыгиванию ям.