

Лекция 11

Обучение с подкреплением

Никита Юдин, iudin.ne@phystech.edu

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

16 апреля 2026



Deep Deterministic Policy Gradient (DDPG)

Схема DQN имела принципиальный недостаток: мы не могли работать с непрерывными пространствами действий в силу необходимости постоянно считать операторы максимума и аргмаксимума

$$\max_a Q_\theta(s, a)$$

как для жадного выбора действия, так и для построения таргета в задаче регрессии.

Единственная возможная архитектура модели — приём действий на вход вместе с состояниями, тогда поиск аргмаксимума проводить, в целом, можно, но дорого: инициализируем a^0 случайно, и устраиваем градиентный подъём по входу в модель:

$$a^{k+1} = a^k + \alpha \nabla_a Q_\theta(s, a)|_{a=a^k}.$$

Итак, пусть $\pi_\omega(s)$ принимает на вход состояние s и выдаёт аргмаксимум текущей аппроксимации Q-функции, то есть будем добиваться $\pi_\omega(s) \approx \underset{a}{\operatorname{argmax}} Q_\theta(s, a)$. Понятно, как обучать такую сеть:

$$Q_\theta(s, \pi_\omega(s)) \rightarrow \max_\omega.$$

Весь алгоритм DQN оставляем неизменным с единственной модификацией, что на каждом батче также нужно сделать шаг оптимизации ω . При этом каждый раз, когда в схеме необходимо считать максимум или аргмаксимум Q_θ , используется $\pi_\omega(s)$. В стандартном алгоритме DQN нам было необходимо считать $\max_{a'} Q_{\theta-}(s', a')$, и в дефолтной версии алгоритма использовалась таргет-сеть. Технически это означает, что для таргет-сети $Q_{\theta-}(s', a')$ нам тоже нужно знать аргмаксимум, поэтому можно хранить старую версию вспомогательной функции $\pi_{\omega-}(s)$.

Итого мы получили, что для жадного выбора действия используется $\pi_\omega(s)$ (отсюда такое обозначение этой «вспомогательной» функции — это фактически стратегия); а таргет для перехода $\mathbb{T} := (s, a, r, s')$ вычисляется по формуле

$$y(\mathbb{T}) := r + \gamma Q_{\theta^-}(s', \underset{a'}{\operatorname{argmax}} Q_{\theta^-}(s', a')) \approx r + \gamma Q_{\theta^-}(s', \pi_{\omega^-}(s)).$$

Такой алгоритм называется Deep Deterministic Policy Gradient (DDPG), и название может сбить с толку: а причём здесь policy gradient?

Теорема 1 — Deterministic Policy Gradient: В непрерывных пространствах действий в предположении дифференцируемости Q-функций по действиям:

$$\nabla_{\theta} J(\pi_{\theta}) = \frac{1}{1-\gamma} \mathbb{E}_{d \sim \pi_{\theta}(s)} (\nabla_{\theta} \pi_{\theta}(s))^{\top} \nabla_a Q^{\pi}(s, a)|_{a=\pi_{\theta}(s)}. \quad (1)$$

Доказательство.

$$\nabla_{\theta} V^{\pi_{\theta}}(s) = \{VQ \text{ уравнение}\} = \nabla_{\theta} \mathbb{E}_{a \sim \pi_{\theta}(s)} Q^{\pi_{\theta}}(s, a) = \nabla_{\theta} Q^{\pi_{\theta}}(s, \pi_{\theta}(s)) = (*).$$

Заметим, что в последнем выражении при малом изменении θ поменяется не только $\pi_{\theta}(s)$, но и сама оценочная функция $Q^{\pi_{\theta}}$. Считая, что якобиан функции $\mathbb{R}^n \rightarrow \mathbb{R}^m$ имеет размерность $n \times m$, и обозначая размерность действий как A , а размерность параметров θ буквой d , получаем следующие размерности матриц и векторов:

$$\nabla_{\theta} Q^{\pi_{\theta}}(s, a) \in \mathbb{R}^{d \times 1}, \quad \nabla_a Q^{\pi_{\theta}}(s, a) \in \mathbb{R}^{A \times 1}, \quad \nabla_{\theta} \pi_{\theta}(s) \in \mathbb{R}^{A \times d}.$$

Тогда продолжение вычисления выглядит так:

$$(*) = (\nabla_{\theta} \pi_{\theta}(s))^{\top} \nabla_a Q^{\pi}(s, a)|_{a=\pi_{\theta}(s)} + \nabla_{\theta} Q^{\pi_{\theta}}(s, a)|_{a=\pi_{\theta}(s)},$$

где последнее слагаемое — градиент $Q^{\pi_{\theta}}$ при фиксированном a по параметрам стратегии π_{θ} , которую он оценивает. Отдельно это слагаемое имеет вид:

$$\nabla_{\theta} Q^{\pi_{\theta}}(s, a) = \{ \text{QV уравнение} \} = \gamma \mathbb{E}_{s'} \nabla_{\theta} V^{\pi_{\theta}}(s').$$

Получаем рекурсивную формулу, аккуратно собирая которую, получим:

$$\nabla_{\theta} V^{\pi_{\theta}}(s) = \mathbb{E}_{\mathcal{T} \sim \pi | s_0=s} \sum_{t \geq 0} \gamma^t (\nabla_{\theta} \pi_{\theta}(s_t))^{\top} \nabla_a Q^{\pi}(s_t, a)|_{a=\pi_{\theta}(s_t)}.$$

Осталось только применить теорему об эквивалентной форме мат.ожидания по траекториям для

$$f(s, a) = (\nabla_{\theta} \pi_{\theta}(s))^{\top} \nabla_a Q^{\pi}(s, a)|_{a=\pi_{\theta}(s)}.$$



Сразу построим суррогатную функцию для такой формулы градиента:

$$\mathcal{L}_{\tilde{\pi}}(\theta) := \frac{1}{1 - \gamma} \mathbb{E}_{d_{\tilde{\pi}}(s)} Q^{\tilde{\pi}}(s, \pi_{\theta}(s)).$$

Действительно, если мы посчитаем градиент этой функции по θ , то мы просто получим формулу chain rule для оптимизации параметров стратегии через градиент Q-функции по действиям. Иными словами, градиент по параметрам детерминированной стратегии указывает просто проводить policy improvement: выбирать те действия, для которых Q-функция больше, используя её градиент по действиям. Если мы хотим построить Actor-Critic схему, воспользовавшись такой формулой, нам придётся аппроксимировать Q-функцию $Q_{\omega}(s, a) \approx Q^{\pi}(s, a)$ и явно использовать её градиент по действиям, надеясь на то, что $\nabla_a Q_{\omega}(s, a) \approx \nabla_a Q^{\pi}(s, a)$.

Итого, будем сэмплировать батч состояний из реплей буфера и делать шаг градиентного подъёма:

$$\theta \leftarrow \theta + \alpha \mathbb{E}_s (\nabla_{\theta} \pi_{\theta}(s))^{\top} \nabla_a Q^{\pi}(s, a)|_{a=\pi_{\theta}(s)},$$

где состояния s приходят из произвольного распределения (например, из реплей буфера). Это эквивалентно одному шагу градиентной оптимизации суррогатной функции:

$$\mathbb{E}_s Q^{\pi}(s, \pi_{\theta}(s)) \rightarrow \max_{\theta}. \quad (2)$$

Q -функцию $Q_{\omega}(s, a) \approx Q^{\pi}(s, a)$, необходимую для такой оптимизации, будем тоже учить в off-policy режиме с одношаговых оценок: ему для данной пары s, a требуется лишь сэмпл s' , поэтому такого критика можно обучать по переходам $\mathbb{T} := (s, a, r, s')$ из буфера на таргеты

$$y(\mathbb{T}) := r + \gamma Q_{\omega-}(s', \pi(s')).$$

Теорема

Предыдущие две схемы (вывод через DQN и через Policy Gradient) эквивалентны полностью.

Доказательство. Методом пристального взгляда. ■

В рассмотренной схеме из-за использования детерминированной стратегии, как и в DQN, возникает проблема exploration-exploitation-a. В непрерывных пространствах действий вместо ε -жадной стратегии возможно добавлять к выбранным стратегией действиям шум из нормального распределения:

$$a_t := \pi(s_t) + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2 I).$$

Пример

Если действия робота — это направление движения (например, поворот руля управляемой машины), а один шаг в среде это доля секунды, странно проводить исследования, случайно «поддёргиваясь» пару раз в секунду. Хочется целенаправленно смещать траекторию: если мы решили в целях исследования повернуть руль чуть правее, чем говорит наша детерминированная стратегия, следует сохранить это смещение руля вправо и в дальнейшем. Для моделирования этого шум должен быть скоррелированным: поэтому вместо независимого шума имеет смысл добавлять случайный процесс, колеблющийся вокруг нуля.

Определение

Шум Орнштейна — Уленбека (Ornstein–Uhlenbeck noise), в начале эпизода инициализированный нулём, задаётся рекурсивно как:

$\varepsilon_{t+1} := \alpha \varepsilon_t + \mathcal{N}(0, \sigma^2 I)$, где $\alpha \leq 1$ и σ — гиперпараметры.

Алгоритм 1: Deep Deterministic Policy Gradient (DDPG)

Гиперпараметры: B — размер мини-батчей, β — коэф. экспоненциального сглаживания для таргет-сеток, α, σ — параметры шума, $Q_\theta(s, a)$ — нейросетка с параметрами θ , $\pi_\omega(s)$ — детерминированная стратегия с параметрами ω , SGD-оптимизаторы, K — периодичность обновления весов таргета.

Инициализировать θ, ω произвольно

Положить $\theta^- := \theta$

Положить $\omega^- := \omega$

Инициализировать шум $\varepsilon := 0$

Пронаблюдать s_0

На очередном шаге t :

- 1 обновить шум $\varepsilon \leftarrow \alpha\varepsilon + \hat{\varepsilon}$, где $\hat{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I)$
- 2 выбрать $a_t := \pi_\omega(s_t) + \varepsilon$
- 3 пронаблюдать $r_t, s_{t+1}, \text{done}_{t+1}$
- 4 добавить пятёрку $(s_t, a_t, r_t, s_{t+1}, \text{done}_{t+1})$ в реплей буфер
- 5 засэмплировать мини-батч размера B из буфера

6 сделать один шаг градиентного подъёма по ω :

$$\frac{1}{B} \sum_{s \in B} Q_{\theta}(s, \pi_{\omega}(s)) \rightarrow \max_{\omega}$$

7 для каждого перехода $\mathbb{T} := (s, a, r, s', \text{done})$ посчитать таргет:

$$y(\mathbb{T}) := r + \gamma(1 - \text{done})Q_{\theta^-}(s', \pi_{\omega^-}(s'))$$

8 сделать один шаг градиентного спуска по θ :

$$\frac{1}{B} \sum_{\mathbb{T}} (Q_{\theta}(s, a) - y(\mathbb{T}))^2 \rightarrow \min_{\theta}$$

9 обновить таргет-сети, если $t \bmod K = 0$:

$$\theta^- \leftarrow (1 - \beta)\theta^- + \beta\theta$$

$$\omega^- \leftarrow (1 - \beta)\omega^- + \beta\omega$$

Алгоритм 2: Twin Delayed DDPG (TD3)

Гиперпараметры: B — размер мини-батчей, N — периодичность обновления весов стратегии, α, σ — параметры шума, $\hat{\sigma}, c$ — параметры шума для добавки к действиям для таргета, β — коэф. экспоненциального сглаживания для таргет-сеток, $Q_{\theta_1}(s, a), Q_{\theta_2}(s, a)$ — нейросетки с параметрами θ_1, θ_2 , $\pi_{\omega}(s)$ — детерминированная стратегия с параметрами ω , SGD-оптимизаторы.

Инициализировать $\theta_1, \theta_2, \omega$ произвольно

Инициализировать таргет-сетки $\theta_1^- := \theta_1, \theta_2^- := \theta_2, \omega^- := \omega$

Инициализировать шум $\varepsilon_0 := 0$

Пронаблюдать s_0

На очередном шаге t :

- 1 посчитать шум $\varepsilon_t := \alpha \varepsilon_{t-1} + \varepsilon$, где $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$
- 2 выбрать $a_t := \pi_{\omega}(s_t) + \varepsilon_t$
- 3 пронаблюдать $r_t, s_{t+1}, \text{done}_{t+1}$
- 4 добавить пятёрку $(s_t, a_t, r_t, s_{t+1}, \text{done}_{t+1})$ в реплей буфер
- 5 засэмплировать мини-батч размера B из буфера

6 для каждого перехода $\mathbb{T} := (s, a, r, s', \text{done})$ посчитать таргет:

$$\varepsilon' \sim \text{clip}(\mathcal{N}(0, \hat{\sigma}I), -c, c)$$

$$y(\mathbb{T}) := r + \gamma(1 - \text{done}) \min_{i \in \{1, 2\}} Q_{\theta_i^-}(s', \pi_{\omega^-}(s') + \varepsilon')$$

7 сделать один шаг градиентного спуска по θ_1 и θ_2 :

$$\frac{1}{B} \sum_{\mathbb{T}} (Q_{\theta_1}(s, a) - y(\mathbb{T}))^2 \rightarrow \min_{\theta_1}$$

$$\frac{1}{B} \sum_{\mathbb{T}} (Q_{\theta_2}(s, a) - y(\mathbb{T}))^2 \rightarrow \min_{\theta_2}$$

8 если $t \bmod N = 0$:

- сделать один шаг градиентного подъёма по ω :

$$\frac{1}{B} \sum_{s \in B} Q_{\theta_1}(s, \pi_{\omega}(s)) \rightarrow \max_{\omega}$$

- обновить таргет-сети:

$$\theta_1^- \leftarrow (1 - \beta)\theta_1^- + \beta\theta_1$$

$$\theta_2^- \leftarrow (1 - \beta)\theta_2^- + \beta\theta_2$$

$$\omega^- \leftarrow (1 - \beta)\omega^- + \beta\omega$$

Обучение стохастических политик

Определение

Скажем, что для параметризации $\pi_\theta(a \mid s)$ применим **репараметризационный трюк** (reparameterization trick), если сэмплирование $a \sim \pi_\theta(a \mid s)$ эквивалентно сэмплированию шума из некоторого не зависящего от параметров распределения $\varepsilon \sim p(\varepsilon)$ и его дальнейшего детерминированного преобразования $a = f_\theta(s, \varepsilon)$.

Обучение стохастических политик

Пример 1: Пусть наша стратегия параметризована нормальным распределением:

$$\pi_{\theta}(a \mid s) := \mathcal{N}(\mu_{\theta}(s), \sigma_{\theta}(s)^2 I).$$

Тогда для неё применим репараметризационный трюк: сэмплирование действий эквивалентно $a := \mu_{\theta}(s) + \varepsilon \odot \sigma_{\theta}(s)$, где $\varepsilon \sim \mathcal{N}(0, I)$, $\odot$ — поэлементное перемножение.

Пример

Семейство детерминированных стратегий $\pi_{\theta}(s)$ тоже можно считать таким «вырожденным» примером параметризаций, для которой можно проворачивать репараметризационный трюк: просто шум ε считаем «пустым».

Теорема

Если для $\pi_\theta(a \mid s)$ применим репараметризационный трюк, то:

$$\nabla_\theta J(\pi_\theta) = \frac{1}{1-\gamma} \mathbb{E}_{d_{\pi_\theta}(s)} \mathbb{E}_{\varepsilon \sim p(\varepsilon)} (\nabla_\theta f_\theta(s, \varepsilon))^\top \nabla_a Q^\pi(s, a)|_{a=f_\theta(s, \varepsilon)}. \quad (3)$$

Доказательство. Полностью полностью повторяет вывод теоремы 1. 


Таким образом, все идеи DDPG расширяются на этот случай. Убирая из формулы градиента частоты посещения состояний и переходя к policy iteration схеме, получаем следующий функционал:

$$\mathbb{E}_s \mathbb{E}_{a \sim \pi_\theta(a|s)} Q_\omega(s, a) \rightarrow \max_{\theta}, \quad (4)$$

где состояния берутся из буфера. В силу репараметризационного трюка мы легко справимся со взятием градиента на практике:


$$\nabla_{\theta} \mathbb{E}_{a \sim \pi_\theta(a|s)} Q_\omega(s, a) = \mathbb{E}_{\varepsilon \sim p(\varepsilon)} \nabla_{\theta} Q_\omega(s, f_\theta(s, \varepsilon)).$$

Пример 2: Представьте, что вы хотите объехать дерево. Вы можете объехать его справа, можете слева. Критик сообщает вам высокие значения и слева, и справа, и оптимизируя (4) в классе гауссиан, можно получить стратегию, которая с наибольшей вероятностью выбирает действие «врезаться в дерево».



Пример 3: Например, можно использовать смесь гауссиан. Тогда при использовании K компонент смеси актёр для данного состояния s выдаёт следующие величины: K суммирующихся в единицу чисел $w_i(s, \theta)$, а также K векторов $\mu_i(s, \theta), \sigma_i(s, \theta)$, где $i \in 1, 2, \dots, K$. Итоговое распределение полагается

$$\pi_{\theta}(a \mid s) := \sum_{i=1}^K w_i(s, \theta) \mathcal{N}(\mu_i(s, \theta), \sigma_i(s, \theta)^2 I).$$



Утверждение

Градиент (4) по параметрам актёра θ равен

$$\nabla_{\theta} = \mathbb{E}_{a \sim \pi_{\theta}(a|s)} \nabla_{\theta} \ln \pi_{\theta}(a | s) (Q_{\omega}(s, a) - b(s)) ,$$

где $b(s)$ — бэйзлайн, произвольная функция от состояний.

Теорема (Формула замены переменной в плотности)

Пусть $a := g(u)$, где $g: \mathbb{R}^A \rightarrow \mathbb{R}^A$, и $u \sim \mu_\theta(u \mid s)$. Тогда:

$$\ln \pi_\theta(a \mid s) = \ln \mu_\theta(u \mid s) - \ln |\det \nabla_u g|. \quad (5)$$

Без доказательства. ■

Определение

Энтропией распределения $\pi(a)$ называется

$$\mathcal{H}(\pi(a)) := -\mathbb{E}_{\pi(a)} \ln \pi(a). \quad (6)$$

Пример

Например, для функции $g(u) := \tanh(u)$ якобиан $\nabla_u g$ есть диагональная матрица (поскольку преобразование поэлементное), и его определитель равен покомпонентному произведению:

$$\begin{aligned}\det \nabla_u g(u) &= \prod_{i=1}^A \nabla_{u_i} \tanh(u_i) = \\ &= \{ \text{производная гиперболического тангенса} \} = \prod_{i=1}^A (1 - \tanh^2(u_i))\end{aligned}$$

Заметим, что все компоненты положительные ($\tanh(u_i) \leq 1$), поэтому модуль из формулы (5) брать не нужно. Подставляя в (5), получаем окончательно:

$$\ln \pi_{\theta}(a \mid s) = \ln \mu_{\theta}(u \mid s) - \sum_{i=1}^A \ln(1 - \tanh^2(u_i)).$$